

چند سال



دانشگاه اصفهان
دانشکده مهندسی کامپیوتر
گروه مهندسی نرم افزار

ارتقای سیستم گفتگوی وظیفه گرا از طریق تنظیم سریع و پرو فایل سازی کاربر

عارف یزدخواستی

استاد راهنما

دکتر افسانه فاطمی

فروردین ۱۴۰۴



دانشگاه اصفهان
دانشکده مهندسی کامپیوتر
گروه مهندسی نرم افزار

هیأت داوران پروژه کارشناسی آقای / خانم عارف یزدخواستی به شماره دانشجویی ۴۰۱۳۶۴۴۰۱۸
در رشته مهندسی نرم افزار را در تاریخ با عنوان «ارتقای سیستم گفتگوی وظیفه گرا از طریق تنظیم سریع
و پروفایل سازی کاربر» و نمره نهایی زیر ارزیابی کرد.

به عدد	به حروف

با نمره نهایی

نام و نام خانوادگی استاد داور:

تاریخ و امضا:

نام و نام خانوادگی استاد راهنما:

تاریخ و امضا:

تقديم به:

خانواده كه همواره پشتم و همه دردهايم را مرهم هستند

سپاس گزاری

سپاس و آفرین خداوندگار جان آفرین راست ، اوی که آدمی را به گوهر خرد آراست.
در آغاز دستان پدر و مادر نازنینم را به پاس مهر بیکرانیشان به گرمی می فشارم، و از استاد راهنما خود سرکار
خانم دکتر افسانه فاطمی بابت زمان و انرژی ای که گذاشتند سپاس گزاری می کنم.
و در پایان، سپاس گزاری می کنم از همه اعضای خانواده دانشکده مهندسی کامپیوتر اصفهان به ویژه دوستانم
که بهترین روز های زندگی من را رقم زدند.

عارف یزدخواستی

فروردین ۱۴۰۴

چکیده

سیستم‌های گفتگوی وظیفه‌محور به عنوان ابزاری کلیدی در تعامل انسان و هوش مصنوعی، نقش مهمی در ارائه خدمات شخصی‌سازی شده ایفا می‌کنند. با این حال، چالش‌هایی نظیر شخصی‌سازی ناکافی، مشکل شروع سرد و نگرانی‌های مربوط به حریم خصوصی، توسعه این سیستم‌ها را با مشکلاتی همراه کرده است. در این پژوهش، روشی تحت عنوان "MindMeld" ارائه شده است که با ترکیب تکنیک‌های شخصی‌سازی، نمایه‌سازی کاربر و رعایت حریم خصوصی، به حل این چالش‌ها می‌پردازد. این روش با بهره‌گیری از تنظیم سریع مدل، استفاده فیلتر مشارکتی مبتنی بر آیتم به همراه تحلیل احساسات، مشکلاتی نظیر شروع سرد و محدودیت داده‌های محدود کاربر را مدیریت کرده و تعاملات شخصی‌سازی شده‌ای را فراهم می‌کند که منجر به افزایش رضایت کاربر و عملکرد سیستم شده است.

یکی از ویژگی‌های این روش، پیاده‌سازی حق فراموشی در سیستم گفتگوی وظیفه‌محور است که به کاربران اجازه می‌دهد داده‌های خود را به صورت پویا حذف کنند بدون اینکه عملکرد کلی سیستم تحت تأثیر قرار گیرد. این رویکرد نه تنها اعتماد کاربر را افزایش می‌دهد، بلکه با قوانین جهانی حفظ حریم خصوصی هماهنگ است. علاوه بر این، ترکیب یادگیری چندشات و تنظیم سریع به سیستم اجازه می‌دهد تا حتی در سناریوهایی که داده‌های محدودی وجود دارد، عملکرد مناسبی از خود نشان دهد.

ارزیابی عملکرد با استفاده از معیارهای جامعی مانند گنجی، تمایز، میزان موفقیت، نرخ تکمیل کار و امتیاز تعامل کاربر انجام شده است. نتایج نشان می‌دهد که این روش در مقایسه با رویکردهای موجود، بهبودهای مناسبی در معیارهای مختلف داشته است. به طور خاص، میزان موفقیت کار در این روش نسبت به پژوهش‌های مشابه ۱۷ درصد افزایش یافته است. همچنین برای معیار تمایز، ۱۲ درصد بهبود نسبت به پژوهش مشابه مشاهده شده است.

واژگان کلیدی سیستم گفتگوی وظیفه‌محور، پروفایل کاربری، حق فراموشی، تنظیم سریع، فیلتر مشارکتی

فهرست مطالب

فهرست تصاویر

ج

فهرست جداول

چ

۱	پیش‌گفتار	فصل ۱:
۱	مقدمه	۱.۱
۲	بیان مسئله	۲.۱
۳	اهداف پژوهش	۳.۱
۴	فرضیه‌های پژوهش	۴.۱
۴	سوال‌های پژوهش	۵.۱
۵	نوآوری‌ها و سهم پژوهش	۶.۱
۷	ساختار پایان‌نامه	۷.۱
۹	مروری بر پژوهش‌های انجام‌شده	فصل ۲:
۹	مقدمه	۱.۲
۱۰	ادبیات پژوهش	۲.۲
۱۰	سیستم گفتگو	۱.۲.۲
۱۲	سیستم گفتگوی وظیفه‌گرا	۲.۲.۲
۱۲	تنظیم سریع	۳.۲.۲
۱۳	پروفایل‌سازی کاربر	۴.۲.۲
۱۳	شروع سرد	۵.۲.۲

۶.۲.۲	فیلترسازی مبتنی بر آیتم	۱۳
۷.۲.۲	تحلیل احساسات	۱۴
۸.۲.۲	حق فراموشی	۱۴
۹.۲.۲	یادگیری چند شات	۱۴
۱۰.۲.۲	یادگیری بدون شات	۱۴
۳.۲	مروری بر پیشینه پژوهش	۱۵
۱.۳.۲	سیستم‌های گفتگو	۱۵
۱.۱.۳.۲	سیستم‌های گفتگوی وظیفه‌گرا	۱۵
۲.۱.۳.۲	سیستم گفتگوی دامنه باز	۲۰
۲.۳.۲	تنظیم سریع و تکنیک‌های انطباق مدل	۲۳
۳.۳.۲	پروفایل کاربری	۳۲
۱.۳.۳.۲	تکنیک‌های پروفایل صریح و ضمنی	۳۲
۲.۳.۳.۲	تحلیل احساسات و فیلتر کردن مبتنی بر آیتم	۳۶
۳.۳.۳.۲	تکنیک‌های پروفایل‌سازی کاربر برای افزایش حریم خصوصی	۳۸
۴.۲	جمع‌بندی	۴۰
فصل ۳:	روش پیشنهادی	۴۲
۱.۳	مقدمه	۴۲
۲.۳	جمع‌آوری و آماده‌سازی داده‌ها	۴۳
۳.۳	معماری سیستم	۴۷
۱.۳.۳	مراحل تولید پاسخ	۴۷
۲.۳.۳	ویژگی‌های کلیدی پرداخته شده در معماری	۵۱
۴.۳	ماژول درک مکالمه	۵۱
۵.۳	ماژول تولید پاسخ	۵۴
۱.۵.۳	مدیریت تاریخچه تعاملات	۵۶
۲.۵.۳	فرآیند پاکسازی داده	۵۶

۵۶	واکنش‌های کاربر به پاسخ‌ها	۳.۵.۳
۵۷	منطق شخصی‌سازی	۶.۳
۵۷	پروفایل‌سازی ساده	۱.۶.۳
۵۸	تحلیل احساسات بر اساس برجستگی‌های کاربر	۲.۶.۳
۵۹	فیلتر مبتنی بر آیتم	۳.۶.۳
۶۱	ترکیب و فیلترسازی نهایی	۴.۶.۳
۶۱	مکانیزم بازخورد	۵.۶.۳
۶۲	نتیجه‌گیری	۷.۳
۶۳	ارزیابی و تحلیل نتایج	فصل ۴:
۶۳	مقدمه	۱.۴
۶۳	مجموعه داده‌های مورد استفاده	۲.۴
۶۴	مجموعه داده مووی لنز	۱.۲.۴
۶۵	رویکردهای ایجاد مجموعه داده	۲.۲.۴
۶۶	مجموعه داده تست	۳.۴
۶۶	ابریارامترها	۴.۴
۶۶	ابریارامترهای تنظیم سریع و تولید پاسخ	۱.۴.۴
۶۸	ابریارامترهای آموزشی	۲.۴.۴
۶۹	تعامل ابریارامترها	۳.۴.۴
۶۹	معیارهای ارزیابی	۵.۴
۷۰	معیار گنجی	۱.۵.۴
۷۰	معیار تمایز	۲.۵.۴
۷۱	معیار میزان موفقیت	۳.۵.۴
۷۱	معیار نرخ تکمیل	۴.۵.۴
۷۲	معیار امتیاز تعامل کاربر	۵.۵.۴
۷۳	مطابقت تنوع نمایه	۶.۵.۴

۶.۴	ارزیابی اعمال تغییرات بر روی معیارهای ارزیابی	۷۳
۱.۶.۴	تاثیر مازول پروفایل کاربری بر رضایت کاربران	۷۵
۱.۱.۶.۴	مازول تحلیل معنایی	۷۵
۲.۱.۶.۴	مازول فیلتر مشارکتی	۷۶
۳.۱.۶.۴	بدون هیچ گونه پروفایل کاربری	۷۶
۲.۶.۴	تاثیر کاهش طول بیشینه متن تولیدی توسط مدل	۷۶
۳.۶.۴	جمع‌بندی	۷۶
۷.۴	نتایج نهایی و مقایسه با کارهای موجود	۷۷
۱.۷.۴	نتایج نهایی	۷۷
۲.۷.۴	مقایسه با کارهای موجود	۷۷
۳.۷.۴	ارزیابی انسانی	۷۹
۴.۷.۴	رابط کاربری برای ارزیابی انسانی	۸۰
۸.۴	نتیجه‌گیری	۸۱
۸۴	فصل ۵: جمع‌بندی و پیشنهادهایی برای ادامه پژوهش	
۱.۵	مقدمه	۸۴
۲.۵	روش پیشنهادی	۸۵
۳.۵	نوآوری و دستاوردهای پژوهش	۸۵
۱.۳.۵	پیشرفت در شخصی‌سازی	۸۵
۲.۳.۵	حل مشکل شروع سرد	۸۶
۳.۳.۵	ادغام حق فراموشی و حریم خصوصی	۸۶
۴.۳.۵	سازگاری با دامنه‌های جدید	۸۷
۵.۳.۵	زمینه‌های فراگیر	۸۷
۴.۵	مشارکت و نوآوری	۸۸
۱.۴.۵	مشارکت‌های اصلی	۸۸
۱.۱.۴.۵	شخصی‌سازی در سیستم‌های گفتگو	۸۸

۸۹	۲.۱.۴.۵	حریم خصوصی و هوش مصنوعی اخلاقی
۸۹	۳.۱.۴.۵	معیارها و چارچوب ارزیابی
۸۹	۴.۱.۴.۵	تکنیک‌ها و روش‌های بدیع
۹۰	۵.۵	نتایج پژوهش
۹۰	۱.۵.۵	بهبود شخصی سازی
۹۱	۲.۵.۵	حل مشکل شروع سرد
۹۱	۳.۵.۵	ارزیابی جامع
۹۲	۶.۵	پیشنادهایی برای تحقیقات آینده
۹۲	۱.۶.۵	پیشبرد تکنیک‌های شخصی سازی
۹۲	۱.۱.۶.۵	پروفایل کاربری پیشرفته
۹۲	۲.۱.۶.۵	فیلتر مشارکتی و ترکیبی
۹۳	۲.۶.۵	گسترش چارچوب‌های ارزیابی
۹۳	۳.۶.۵	یکپارچه سازی مدل‌های پیشرفته
۹۴	۷.۵	محدودیت‌ها و چالش‌ها
۹۴	۱.۷.۵	محدودیت داده‌ها
۹۴	۲.۷.۵	محدودیت‌های محاسباتی
۹۵	۳.۷.۵	چالش‌های پروفایل کاربری
۹۵	۴.۷.۵	نگرانی‌های حفظ حریم خصوصی
۹۵	۵.۷.۵	چالش‌های ارزیابی
۹۶	۶.۷.۵	محدودیت‌های مدل
۹۶	۷.۷.۵	چالش‌های تنظیم سریع
۹۶	۸.۷.۵	شخصی سازی پاسخ پویا

فهرست تصاویر

۱۸	معماری سیستم InstructTODS [۶]	۱.۲
۲۴	معماری ایجاد یک سیستم گفتگوی شخصی با تنظیم سریع [۱۵]	۲.۲
۴۸	معماری سیستم	۱.۳
۷۴	پیکربندی مدل	۱.۴
۷۸	مقایسه مقادیر معیارهای ارزیابی با کارهای موجود	۲.۴
۸۳	رابط کاربری طراحی شده	۳.۴

فهرست جداول

۴۰	مقایسه پژوهش‌های انجام شده	۱.۲
۴۴	نمونه‌ای از داده‌های یکپارچه شده از مجموعه داده مووی لنز	۱.۳
۷۵	مطالعه فرسایشی	۱.۴
۷۷	معیارهای ارزیابی و مقادیر آنها	۲.۴
۸۰	مقایسه نتایج ارزیابی انسان و مدل	۳.۴

فصل ۱

پیش‌گفتار

۱.۱ مقدمه

سیستم‌های گفتگوی وظیفه‌گرا به عنوان یکی از مهم‌ترین ابزارهای تعامل انسان و ماشین، نقش اساسی در بهبود تجربه کاربری در حوزه‌هایی مانند سیستم‌های توصیه‌گر، خدمات مشتری و تجارت الکترونیک ایفا می‌کنند. این سیستم‌ها با درک پرسش‌های کاربران و ارائه پاسخ‌های متناسب، تجربه‌ای طبیعی‌تر و مؤثر را در تعاملات کاربران با سیستم فراهم می‌کنند. با این حال، چالش‌های زیادی از جمله نیاز به تنظیم دقیق مدل‌های زبانی، شخصی‌سازی پاسخ‌ها بر اساس ترجیحات کاربران، مشکل شروع سرد برای کاربران جدید و نگرانی‌های مربوط به حریم خصوصی همچنان به عنوان موانع اصلی در مسیر پیشرفت این فناوری‌ها مطرح هستند.

یکی از مهم‌ترین چالش‌های این حوزه، شخصی‌سازی پاسخ‌ها و انطباق‌پذیری سیستم با نیازهای خاص هر کاربر است. در بسیاری از روش‌های موجود، اطلاعات کاربر به صورت ایستا در سیستم ذخیره می‌شود، اما عدم تطبیق آن با تغییرات در رفتار و سلیقه کاربران باعث کاهش دقت توصیه‌ها و کاهش رضایت کاربر به مرور زمان می‌شود. علاوه بر این، مشکل شروع سرد، یعنی ناتوانی سیستم در ارائه پاسخ‌های دقیق به کاربران جدید که سابقه‌ای در سیستم ندارند، یکی از مسائل جدی در سیستم‌های توصیه‌گر و گفتگوی وظیفه‌گرا است. از سوی دیگر، حفظ حریم خصوصی کاربران یکی دیگر از چالش‌های کلیدی در این زمینه است؛ کاربران نیاز دارند که داده‌هایشان در صورت درخواست حذف شود، اما بسیاری از روش‌های سنتی قابلیت اجرایی مؤثری در این زمینه ندارند.

در کنار این چالش‌ها، روش‌های تنظیم دقیق مدل‌های زبانی، اگرچه باعث بهبود عملکرد سیستم‌های گفتگوی وظیفه‌گرا می‌شوند، اما به دلیل نیاز به منابع محاسباتی بسیار بالا و زمان طولانی پردازش، محدودیت‌هایی را ایجاد

می‌کنند. علاوه بر این، روش‌های سنتی تنظیم دقیق معمولاً نیازمند حجم وسیعی از داده‌های آموزش هستند که در بسیاری از موارد به‌راحتی در دسترس نیستند. به همین دلیل، در سال‌های اخیر استفاده از روش تنظیم سریع مورد توجه قرار گرفته است، چرا که این روش بدون نیاز به تغییر تمام پارامترهای مدل، امکان انطباق سریع‌تر و مؤثرتر را با دامنه‌های خاص فراهم می‌کند.

این پژوهش با هدف ارائه یک چارچوب جدید برای بهبود سیستم‌های گفتگوی وظیفه‌گرا، ترکیبی از تکنیک‌های تنظیم سریع و پروفایل‌سازی پویا را پیشنهاد می‌دهد. در این روش، ابتدا داده‌های مرتبط با کاربر از طریق ترکیب تحلیل احساسات برچسب‌های کاربر، فیلتر مشارکتی مبتنی بر آیتم، و تحلیل بازخورد کاربر استخراج شده و سپس با استفاده از تکنیک‌های تنظیم سریع و با استفاده از قدرت مدل‌های زبانی برای پاسخ‌گویی دقیق‌تر و شخصی‌سازی‌شده تنظیم می‌شود. این سیستم همچنین امکان حذف داده‌های کاربر را مطابق با حق فراموشی فراهم می‌کند تا از حریم خصوصی کاربران محافظت شود.

با توجه به این رویکرد نوآورانه، انتظار می‌رود که نتایج این تحقیق بتواند راه را برای پیشرفت‌های آینده در حوزه شخصی‌سازی سیستم‌های گفتگوی وظیفه‌گرا هموار کند و الگویی برای بهبود تعاملات کاربر-ماشین در حوزه‌های مختلف از جمله تجارت الکترونیک، خدمات مشتریان، و سیستم‌های یادگیری هوشمند فراهم آورد.

۲.۱ بیان مسئله

تحقیقات موجود در حوزه سیستم‌های گفتگوی وظیفه‌گرا به رغم پیشرفت‌های چشمگیر، همچنان دارای کاستی‌هایی هستند:

- نبود تمرکز بر حفظ حریم خصوصی کاربران: بسیاری از سیستم‌های موجود داده‌های کاربر را بدون امکان حذف یا اصلاح ذخیره می‌کنند، که می‌تواند منجر به نگرانی‌های امنیتی و اخلاقی شود.
 - پروفایل‌سازی ناکارآمد: روش‌های موجود در پروفایل‌سازی کاربران اغلب تنها به استفاده از یک تکنیک محدود هستند و از روش‌هایی مانند بازخورد موثر کاربران و پروفایل پویا برای به‌روزرسانی مدل‌ها استفاده نمی‌کنند.
 - نیاز به منابع سخت‌افزاری قدرتمند: تنظیم دقیق مدل‌های زبانی به منابع عظیم سخت‌افزاری نیاز دارد که اجرای آن را برای بسیاری از کاربران و سازمان‌ها دشوار می‌کند.
- روش‌های متعددی با استفاده از متدهای مختلف هم با و هم بدون استفاده از مدل‌های زبانی طی سال‌های اخیر ارایه شده است اما آنها نیز دارای کاستی‌هایی در کار خود هستند:

- نبود تنوع در روش‌های پروفایل‌سازی: تحقیقات فعلی عمدتاً به یک رویکرد محدود می‌شوند، در حالی که ترکیب روش‌های مختلف می‌تواند به دقت بیشتری در شخصی‌سازی پاسخ‌ها منجر شود که در نهایت به بهبود سیستم و افزایش کیفیت مکالمه و رضایت کاربر منجر می‌شوند.
- مشکلات شروع سرد: سیستم‌های موجود در مواجهه با کاربران جدید یا داده‌های ناکافی، عملکرد ضعیفی دارند.
- عدم امکان تنظیم سریع: بیشتر تحقیقات به تنظیم دقیق مدل وابسته هستند که نه تنها زمان‌بر و پرهزینه است، بلکه انعطاف‌پذیری کمتری نسبت به تنظیم سریع دارد.
- عدم رعایت حق فراموشی: کاربران نمی‌توانند داده‌های خود را حذف یا به‌روزرسانی کنند، که این مسئله اعتماد به سیستم را کاهش می‌دهد.

۳.۱ اهداف پژوهش

اهداف پژوهش باید منعکس‌کننده چالش‌های اصلی، گپ‌های موجود در ادبیات، و راه‌حل‌هایی باشد که تحقیق حاضر ارائه می‌دهد. در این بخش، اهداف پژوهش به دو دسته اصلی تقسیم می‌شوند: اهداف کلی و اهداف جزئی.

• اهداف کلی

هدف کلی این پژوهش، ارتقای عملکرد سیستم‌های گفتگوی وظیفه‌گرا از طریق استفاده از تکنیک‌های تنظیم سریع و پروفایل‌سازی کاربر است. در واقع ارائه یک روش مبتنی بر ترکیب تنظیم سریع و پروفایل‌سازی کاربر که منجر به بهبود عملکرد سیستم‌های گفتگوی وظیفه‌گرا شود.

• اهداف جزئی

۱. بررسی تأثیر تنظیم سریع بر عملکرد سیستم‌های گفتگوی وظیفه‌گرا:
بررسی نحوه استفاده از تنظیم سریع برای کاهش هزینه‌های محاسباتی و زمانی و ارزیابی تأثیر آن را بر دقت و کارایی سیستم.
۲. توسعه روش‌های پروفایل‌سازی کاربر برای بهبود تعامل و رفتار کاربران

شامل شناسایی داده‌های مرتبط با علائق و ترجیحات کاربران است که می‌تواند به عنوان ورودی برای سیستم‌های گفتگوی وظیفه‌گرا استفاده شود. همچنین، تأثیر این داده‌ها بر رفتار و تعامل کاربران مورد بررسی قرار می‌گیرد.

۳. شناسایی ویژگی‌ها و شاخص‌های کلیدی برای پروفایل‌سازی کاربر
پرداختن به تعیین ویژگی‌ها و شاخص‌هایی که باید در پروفایل‌سازی کاربر مورد توجه قرار گیرند. این ویژگی‌ها شامل ترجیحات شخصی، علائق احساسی و داده‌های تاریخی کاربران می‌شود.
۴. حل مشکل شروع سرد در سیستم‌های گفتگوی وظیفه‌گرا
بررسی روش‌هایی که می‌توانند به کاربران جدید خدمات معنادار و مناسب ارائه دهند، حتی زمانی که داده‌های کافی از آن‌ها وجود ندارد.

اهداف پژوهش فوق از آن جهت دارای اهمیت است که ترکیب پروفایل‌سازی چندگانه، تنظیم سریع، و رعایت حریم خصوصی باعث افزایش اثربخشی سیستم‌های توصیه‌گر می‌شود. همچنین این سیستم قابلیت استفاده در حوزه‌های مختلف مانند خدمات مشتری، آموزش، و تجارت الکترونیک را داراست. ارائه پاسخ‌های شخصی‌سازی شده و سریع باعث افزایش رضایت کاربران و در نهایت افزایش تعامل آن‌ها با سیستم می‌شود.

۴.۱ فرضیه‌های پژوهش

فرضیه اصلی پژوهش به صورت زیر است.
استفاده از روش ترکیبی پروفایل‌سازی کاربر به همراه تنظیم سریع در سیستم‌های گفتگوی وظیفه‌گرا می‌تواند به طور موثری منجر به ارتقای عملکرد آن‌ها در پاسخگویی به نیازهای کاربران گردد.
این فرضیه به صورت مستقیم به بررسی نحوه استفاده از پروفایل کاربر و تنظیم سریع برای بهبود معیارهایی چون رضایت کاربر، تعامل، و دقت پاسخ‌ها می‌پردازد. ترکیب این دو روش، با رویکردی جامع‌تر، مشکلاتی نظیر شروع سرد، حریم خصوصی و تعاملات بلندمدت کاربر را هدف قرار می‌دهد.

۵.۱ سوال‌های پژوهش

در این بخش، سوالات پژوهش بیان شده است. این فرضیات مبتنی بر شکاف‌های موجود در ادبیات پژوهشی و نیازهای سیستم‌های گفتگوی وظیفه‌گرا تدوین شده‌اند.

۱. استفاده از تنظیم سریع به چه صورت می‌تواند منجر به ارتقای سیستم گفتگوی وظیفه‌گرا شود؟
۲. استفاده از داده‌های پروفایل کاربر در سیستم‌های گفتگوی وظیفه‌گرا از چه راه‌هایی بر رفتار و تعامل کاربر تأثیر می‌گذارد و چگونه می‌توان از این اطلاعات برای بهبود عملکرد کلی سیستم گفتگو استفاده کرد؟
۳. چه ویژگی‌ها و شاخص‌هایی باید در پروفایل‌سازی کاربر در سیستم‌های گفتگوی وظیفه‌گرا مورد توجه قرار گیرند؟

۶.۱ نوآوری‌ها و سهم پژوهش

در این بخش، نوآوری‌ها و سهم علمی پژوهش حاضر با توجه به دستاوردها و ایده‌های منحصر به فرد ارائه می‌شود. این نوآوری‌ها در دو بعد اصلی تئوریک و عملی دسته‌بندی شده‌اند. نوآوری‌های تئوریک شامل موارد زیر است.

۱. معرفی رویکرد ترکیبی تنظیم سریع و پروفایل‌سازی کاربر
این پژوهش برای اولین بار استفاده از تنظیم سریع و پروفایل‌سازی پیشرفته کاربر را در سیستم‌های گفتگوی وظیفه‌گرا ترکیب کرده است. این روش نشان می‌دهد که چگونه ترکیب داده‌های شخصی‌سازی شده و تنظیم سریع می‌تواند به بهبود پاسخ‌دهی و رضایت کاربر منجر شود. همچنین یک مدل مفهومی برای ادغام داده‌های کاربر و تنظیم سریع ارائه می‌کند که قابلیت استفاده در دیگر حوزه‌های سیستم‌های توصیه‌گر را نیز دارد.
۲. تأکید بر حریم خصوصی کاربران از طریق پیاده‌سازی حق فراموشی
این پژوهش با ارائه مکانیزمی برای حذف داده‌های کاربران، یک رویکرد تئوریک برای تعامل بین حفظ حریم خصوصی و عملکرد سیستم پیشنهاد می‌کند.
۳. بررسی عمیق مشکلات شروع سرد
این پژوهش رویکردهای متنوعی مانند فیلتر مشارکتی و جمع‌آوری داده‌های اولیه از کاربران را برای حل مشکل شروع سرد در سیستم‌های توصیه‌گر تحلیل و عملیاتی کرده است. نوآوری‌های عملی نیز شامل موارد زیر است.

۱. پیاده‌سازی و ترکیب مکانیزم‌های مختلف مانند تحلیل احساسات و فیلتر مشارکتی مبتنی بر آیتم برای پروفایل‌سازی کاربر

با استفاده از مدل‌های از پیش آموزش‌دیده، تحلیل احساسات از برچسب‌های کاربران انجام شده و برای شناسایی ژانرها و فیلم‌های محبوب کاربر استفاده شده است. همچنین از فیلتر مشارکتی مبتنی بر آیتم جهت یافتن آیتم‌های مورد علاقه کاربر با توجه به سابقه علاقه بقیه کاربران به آیتم‌های مشابه استفاده شده است تا پروفایل کاربری غنی‌تر و بهتری ایجاد گردد.

۲. طراحی معماری چند ماژولی برای سیستم‌های گفتگوی وظیفه‌گرا

این معماری شامل ماژول درک گفتگو برای غنی‌سازی پرس‌وجوهای کاربران، ماژول تولید پاسخ با استفاده از مدل‌های تنظیم‌شده و همچنین ماژول پرفایل و شخصی‌سازی بر اساس داده‌های پروفایل کاربر و فیلترهای پویا است.

۳. ارزیابی عملکرد مدل با معیارهای متنوع

معیارهایی مانند نرخ موفقیت، نرخ تکمیل، و امتیاز تعامل کاربر و همچنین معیارهای خاص پروفایل کاربری مانند دقت توصیه شخصی و تطابق تنوع نمایه برای ارزیابی جامع سیستم معرفی و استفاده شدند. تفاوت‌ها و برتری‌ها نسبت به کارهای پیشین به شرح زیر است.

• حل مشکلات حریم خصوصی

در مقایسه با دیگر تحقیقات، این پژوهش به مسئله حفظ حریم خصوصی پرداخته و مکانیزم حذف داده‌ها را پیاده‌سازی کرده است.

• شخصی‌سازی پیشرفته

ترکیب سه رویکرد (پروفایل‌سازی ساده، تحلیل احساسات، و فیلتر مشارکتی) باعث شده است که پروفایل‌های کاربری دقیق‌تر و توصیه‌ها مرتبط‌تر شوند.

• کاهش نیاز به سخت‌افزار پیشرفته

با استفاده از تنظیم سریع به جای تنظیم دقیق، این پژوهش هزینه محاسباتی را کاهش داده و کارایی سیستم را بهبود بخشیده است.

• حل مشکل شروع سرد

راهکارهای ارائه‌شده، امکان تعامل موثر با کاربران جدید حتی در صورت عدم وجود داده‌های کافی را فراهم کرده‌است.

این پژوهش با ارائه یک رویکرد جدید ترکیبی و تأکید بر حریم خصوصی و شخصی‌سازی، سهم مهمی در پیشرفت سیستم‌های گفتگوی وظیفه‌گرا داشته و می‌تواند به عنوان الگویی برای سایر سیستم‌های توصیه‌گر استفاده شود.

۷.۱ ساختار پایان‌نامه

فصل دوم بررسی ادبیات پژوهش است که شامل مروری بر اهمیت سیستم‌های گفتگوی وظیفه‌محور و زمینه‌های مرتبط آن است.

مفاهیم اصلی شامل سیستم‌های گفتگوی وظیفه‌محور و انواع فرعی آن (به عنوان مثال، سیستم‌های وظیفه‌محور و دامنه‌باز)، تنظیم سریع و مزایای آن نسبت به تنظیم دقیق، تکنیک‌های پروفایل‌کاری، از جمله تجزیه و تحلیل احساسات و فیلترکردن مشارکتی و در نهایت چالش‌هایی مانند مسائل مربوط به شروع سرد و نگرانی‌های مربوط به حریم خصوصی مورد بررسی قرار خواهد گرفت.

در ادامه به بررسی آثار مرتبط مقایسه تفصیلی تحقیقات قبلی با تمرکز بر اثربخشی تنظیم سریع در پردازش زبان طبیعی، نقش شخصی‌سازی در سیستم‌های گفتگوی وظیفه‌محور و محدودیت‌های رویکردهای موجود در راه‌حل‌های حریم خصوصی و شروع سرد پرداخته شده‌است.

این بخش با شناسایی شکاف‌هایی به پایان می‌رسد که چارچوب پیشنهادی به دنبال رفع آن است. فصل سوم روش‌شناسی است که در ابتدا رویکرد کلی و طرح تحقیق را توضیح می‌دهد. جمع‌آوری و آماده‌سازی داده‌ها و جزئیات استفاده از مجموعه داده‌های مووی‌لنز و تبدیل آن به داده‌های مکالمه مانند به تفصیل شرح داده شده‌است.

در ادامه معماری سیستم و توضیح به تفکیکی برای هر ماژول (به عنوان مثال، درک گفتگو، منطق شخصی‌سازی)، جریان پرسه از زمان ورود به سیستم و پردازش آن در معماری فوق آورده شده‌است.

پیاده‌سازی‌های خاص ماژول مانند درک گفتگو استخراج موجودیت و اصلاح پرس و جو، ماژول تولید پاسخ با بهره‌گیری تنظیم سریع و انطباق با حق فراموشی و همچنین منطق شخصی‌سازی یعنی روش‌های پروفایل‌سازی کاربر، تجزیه و تحلیل احساسات، و فیلترکردن مشارکتی ارائه شده‌است.

فصل چهارم شامل نتایج ارزیابی نهایی سیستم است.

در ابتدا به بررسی اجمالی مجموعه‌داده مووی‌لنز و پیش‌پردازش آن پرداخته شده‌است.

نتایج ارزیابی برای معیارهای مختلف ارایه شده و تجزیه و تحلیل یافته‌ها به همراه آنالیز حساسیت هر بخش سیستم مانند تاثیر پروفایل کاربری بر کیفیت پاسخ نقش مکانیسم های حق فراموشی در اعتماد کاربر و عملکرد سیستم شرح داده شده است.

فصل پنجم بحث و نتیجه گیری است که اهداف و روش تحقیق را بیان می‌کند.

یافته های کلیدی مانند بهبود عملکرد سیستم های گفتگوی وظیفه محور با تنظیم سریع و پروفایل کاربری، افزایش تعامل کاربر از طریق توصیه های شخصی شده، استفاده از حق فراموشی و پرداختن به مسائل مربوط به شروع سرد و حریم خصوصی شرح داده شده است.

در ادامه به محدودیت ها و چالش های برخورد شده در مسیر پژوهش مانند محدودیت های سخت افزاری که اندازه مدل و قابلیت های تنظیم دقیق را محدود می‌کند و چالش های ایجاد مجموعه داده و مقیاس پذیری پرداخته شده است.

همچنین در مورد کار آینده و کاوش در روش های پیشرفته پروفایل و مجموعه داده های غنی تر به همراه گسترش چارچوب به حوزه های دیگر فراتر از توصیه های فیلم صحبت شده است.

فصل ۲

مروری بر پژوهش‌های انجام شده

۱.۲ مقدمه

فصل دوم پایان‌نامه به بررسی پیشینه^۱ و ادبیات پژوهش^۲ اختصاص دارد که هدف آن ایجاد یک دیدگاه جامع و منسجم نسبت به موضوع پژوهش است. در بخش ۲.۲، به مرور ادبیات پژوهش پرداخته شده و مفاهیم کلیدی مرتبط با سیستم‌های گفتگو به خصوص سیستم‌های گفتگو وظیفه‌گرا، تنظیم سریع مدل‌ها، و پروفایل‌سازی کاربر معرفی شده است. این بخش، زمینه‌ساز درک بهتر پژوهش‌های پیشین و نوآوری‌های مطرح شده در این حوزه است. در بخش ۳.۲، پیشینه پژوهش بررسی می‌شود که شامل تحلیل و مقایسه مقالات علمی مرتبط در قالب دسته‌بندی‌های زیر است:

- سیستم‌های گفتگو:
سیستم‌های گفتگوی وظیفه‌گرا: به بررسی مدل‌ها و تکنیک‌هایی پرداخته شده است که برای تعامل هدفمند با کاربران طراحی شده‌اند.
سیستم‌های گفتگوی دامنه‌باز: این بخش به سیستم‌هایی می‌پردازد که قابلیت تعامل با کاربران در موضوعات متنوع و غیرمحدود را دارند.
- تنظیم سریع و تکنیک‌های انطباق مدل:
این بخش روش‌هایی را بررسی می‌کند که برای بهبود عملکرد مدل‌های زبانی بدون نیاز به تنظیم دقیق

¹Background Research

²Literature Review

گسترده استفاده می‌شوند.

- پروفایل‌سازی کاربر:

پروفایل صریح و ضمنی: تکنیک‌های مرتبط با جمع‌آوری داده‌های صریح (مانند اطلاعات جمعیت‌شناختی) و داده‌های ضمنی (مانند رفتار کاربران) بیان شده است.

تحلیل احساسات و فیلتر کردن مبتنی بر آیت: تکنیک‌هایی که از تحلیل رفتار کاربران برای ارائه پیشنهادهای شخصی‌سازی شده استفاده می‌کنند.

تکنیک‌های پروفایل‌سازی با تمرکز بر حریم خصوصی: روش‌هایی که به منظور افزایش حریم خصوصی در پروفایل‌سازی به ویژه حق فراموشی در سیستم‌های گفتگو استفاده می‌شود بیان شده است.

این فصل تلاش می‌کند از طریق این دسته‌بندی‌ها، به شناسایی و تحلیل نقاط قوت، ضعف و شکاف‌های موجود در پژوهش‌های پیشین بپردازد و زمینه‌ای برای ارائه نوآوری‌های پژوهشی فراهم کند.

۲.۲ ادبیات پژوهش

۱.۲.۲ سیستم گفتگو

سیستم‌های گفتگو^۱، به سامانه‌های مبتنی بر هوش مصنوعی گفته می‌شود که توانایی برقراری ارتباط طبیعی با کاربران از طریق زبان گفتاری یا نوشتاری را دارند. این سیستم‌ها هدف اصلی‌شان کمک به کاربران در انجام وظایف خاص یا ارائه اطلاعات مورد نیاز است. در سیستم‌های گفتگو، کاربران می‌توانند درخواست‌هایی را به زبان طبیعی مطرح کنند، و سیستم با درک ورودی کاربر، پاسخ‌های مرتبط و دقیق را ارائه می‌دهد. سیستم‌های گفتگو را می‌توان به دو دسته کلی تقسیم کرد:

۱. سیستم‌های گفتگو وظیفه‌گرا^۲: این سیستم‌ها به منظور انجام وظایف خاص طراحی شده‌اند، مانند رزرو بلیط، پرسش و پاسخ‌های پشتیبانی مشتری و خرید آنلاین. در این سیستم‌ها، هدف اصلی رسیدن به یک نتیجه خاص است که با دریافت اطلاعات از کاربر و تعامل در مسیر هدف، به کاربر کمک می‌کند تا به هدف مورد نظر برسد.

۲. سیستم‌های گفتگو آزاد^۳: این نوع سیستم‌ها به گفتگوهای آزاد و عمومی پاسخ می‌دهند و محدود به موضوع خاصی نیستند. آن‌ها بیشتر برای تعاملات اجتماعی و گفتگوی آزاد به کار می‌روند و به نوعی

¹Dialogue System

²Task-Oriented Dialogue Systems

³Open-Domain Dialogue Systems

طراحی شده‌اند که توانایی پاسخگویی به سوالات متنوع کاربران را داشته باشند. برای مثال، سیستم‌های چت‌بات‌های اجتماعی یا ربات‌های پاسخ‌گویی در شبکه‌های اجتماعی نمونه‌هایی از این دسته هستند.

اجزای اصلی سیستم‌های گفتگو

سیستم‌های گفتگو معمولاً از سه مؤلفه اصلی تشکیل شده‌اند:

۱. درک زبان طبیعی^۱: این بخش مسئول تجزیه و تحلیل و تفسیر ورودی‌های کاربر به زبان طبیعی است. درک زبان طبیعی وظیفه‌ی شناسایی قصد کاربر و موجودیت‌ها را بر عهده دارد و کمک می‌کند سیستم مفهوم پرسش کاربر را درک کند.

۲. مدیریت گفتگو^۲: این بخش بر اساس داده‌های ورودی و خروجی‌های پیشین تصمیم‌گیری می‌کند. در سیستم‌های گفتگوی وظیفه‌گرا، مدیریت گفتگو به کاربر کمک می‌کند تا در مسیر دستیابی به هدف هدایت شود و درخواست‌های کاربر را برای رسیدن به هدف نهایی مدیریت می‌کند.

۳. تولید زبان طبیعی^۳: این مؤلفه وظیفه تولید پاسخ مناسب برای کاربر را بر عهده دارد. در این مرحله، اطلاعات پردازش‌شده توسط سیستم به زبان طبیعی تبدیل می‌شود تا کاربر بتواند به‌صورت خوانا و قابل فهم به پاسخ خود دست یابد.

روش‌های توسعه سیستم‌های گفتگو

در توسعه سیستم‌های گفتگو، روش‌های متفاوتی به کار می‌رود که هر کدام دارای مزایا و معایب خود هستند:

- سیستم‌های مبتنی بر قواعد: این روش به قوانین از پیش تعریف‌شده متکی است و برای گفتگوهای ساده و وظیفه‌محور مناسب است.
- سیستم‌های مبتنی بر یادگیری ماشین: از تکنیک‌های یادگیری ماشین برای آموزش سیستم استفاده می‌شود و این روش امکان توسعه سیستم‌های پیچیده‌تر را فراهم می‌کند. در این سیستم‌ها، داده‌های گذشته برای یادگیری و بهبود تعاملات آینده به کار می‌رود.
- مدل‌های مبتنی بر زبان بزرگ^۴: استفاده از مدل‌های زبان بزرگ مانند جی‌پی‌تی که توانایی پردازش و تولید زبان طبیعی را دارند، باعث بهبود دقت و طبیعی بودن سیستم‌های گفتگو شده‌است. این مدل‌ها به‌طور خاص در سیستم‌های گفتگوی آزاد و گسترده کاربرد دارند.

^۱Natural Language Understanding (NLU)

^۲Dialogue Management (DM)

^۳Natural Language Generation (NLG)

^۴LLM

کاربردهای سیستم‌های گفتگو

سیستم‌های گفتگو در حوزه‌های مختلفی کاربرد دارند، از جمله:

- پشتیبانی مشتری: پاسخ به سوالات متداول، راهنمایی مشتریان و رفع مشکلات آن‌ها.
- دستیارهای مجازی: ارائه پیشنهادهای شخصی‌سازی شده به کاربران و کمک به انجام وظایف روزمره.
- سیستم‌های آموزشی: ایجاد تعاملات یادگیری برای آموزش زبان، مهارت‌های جدید و مانند آن.
- توصیه‌گرهای هوشمند: ارائه پیشنهادهای شخصی مانند فیلم، موسیقی یا کتاب بر اساس ترجیحات کاربر.

۲.۲.۲ سیستم گفتگوی وظیفه‌گرا

سیستم‌های گفتگوی وظیفه‌گرا^۱ به سیستم‌هایی اطلاق می‌شوند که هدف آن‌ها کمک به کاربر در انجام وظایف خاص است. این سیستم‌ها معمولاً در کاربردهایی مانند رزرو بلیط، پشتیبانی مشتری و توصیه‌گری محتوا استفاده می‌شوند. آن‌ها با دریافت ورودی از کاربر، قصد کاربر را شناسایی کرده و اطلاعات مرتبط را از پایگاه دانش استخراج و به کاربر ارائه می‌دهند.

سیستم‌های گفتگوی وظیفه‌محور را می‌توان به طور کلی به دو دسته طبقه‌بندی کرد که شامل رویکردهای خط لوله^۲ و رویکردهای انتها به انتها^۳ است. رویکرد خط لوله از چندین ماژول برای ایجاد پاسخ‌های سیستم استفاده می‌کند. در حالی که رویکرد انتها به انتها مستقیماً پاسخ‌هایی را از ورودی کاربر و پایگاه دانش^۴ به صورت انتها به انتها تولید می‌کند. [۶]

۳.۲.۲ تنظیم سریع

تنظیم سریع^۵ روشی است که برای بهینه‌سازی مدل‌های زبان بزرگ به منظور ارائه پاسخ‌های مناسب و شخصی‌سازی شده بر اساس ورودی‌های کاربر به کار می‌رود. این روش به جای تغییر پارامترهای داخلی مدل، یک ورودی^۶ ثابت را به عنوان بخشی از ورودی تعریف می‌کند تا پاسخ‌دهی مدل به شیوه‌ای خاص هدایت شود. تنظیم سریع روشی برای بهینه‌سازی خودکار یک پرامپت بدون ایجاد آن توسط کار دستی است. [۱۵]

^۱Task-Oriented Dialogue System

^۲Pipeline

^۳End-to-end

^۴Knowledge Base (KB)

^۵Prompt-Tuning

^۶Prompt

۴.۲.۲ پروفایل‌سازی کاربر

پروفایل‌سازی کاربر^۷ شامل جمع‌آوری اطلاعاتی از کاربران و تحلیل آن‌ها به منظور شخصی‌سازی تجربه کاربری است. این پروفایل‌ها شامل ترجیحات، تاریخچه و تعاملات گذشته کاربر با سیستم است و به سیستم کمک می‌کند تا پاسخ‌های بهتری ارائه دهد [۲۴].

انواع پروفایل کاربری به شرح زیر است.

- پروفایل کاربری صریح^۱: شامل اطلاعاتی است که کاربر به طور مستقیم در اختیار سیستم قرار می‌دهد، مانند انتخاب ژانر فیلم مورد علاقه.
- پروفایل کاربری ضمنی^۲: شامل اطلاعاتی است که سیستم از تعاملات و رفتار کاربر استنتاج می‌کند، مانند ژانرهای فیلمی که کاربر بیشتر به آن‌ها علاقه نشان داده است. سیستم اطلاعات کاربر را از طریق رفتار و تعاملات او با سیستم به صورت غیرمستقیم جمع‌آوری می‌کند. برای مثال، سیستم از طریق تاریخچه جستجوی کاربر می‌تواند ژانرهای طرفداری که کاربر به آن‌ها علاقه دارد را شناسایی کند.

۵.۲.۲ شروع سرد

در سیستم‌های توصیه‌گر، مشکل شروع سرد^۳ زمانی رخ می‌دهد که سیستم داده‌های کافی از کاربر جدید برای ارائه توصیه‌های مناسب در اختیار ندارد. راه‌حل‌های مختلفی برای حل این مشکل وجود دارد، از جمله استفاده از ترجیحات عمومی یا دریافت اطلاعات اختصاصی از کاربر [۲۸].

۶.۲.۲ فیلترسازی مبتنی بر آیتم

فیلترسازی مبتنی بر آیتم^۴، یک روش در سیستم‌های توصیه‌گر است که به شباهت بین آیتم‌ها برای پیشنهاد موارد جدید به کاربر تکیه می‌کند. در این روش، اگر کاربری یک آیتم را دوست داشته باشد، آیتم‌های مشابه به او پیشنهاد می‌شود. این رویکرد به ویژه برای ایجاد پیشنهادها بر اساس الگوهای مشترک بین آیتم‌ها بسیار کاربردی است [۱].

^۷User Profiling

^۱Explicit User Profile

^۲Implicit User Profile

^۳Cold Start

^۴Item-Based Collaborative Filtering

۷.۲.۲ تحلیل احساسات

تحلیل احساسات^۵ فرآیندی است که به شناسایی و طبقه‌بندی احساسات موجود در متن‌های کاربران می‌پردازد. این روش در سیستم‌های گفتگو کاربرد زیادی دارد، زیرا به سیستم این امکان را می‌دهد که پاسخ‌های بهتری بر اساس حالت روحی و احساسی کاربر ارائه دهد. برای مثال، اگر کاربر از عباراتی با احساسات منفی استفاده کند، سیستم می‌تواند پاسخ‌های همدلانه‌تری ارائه دهد [۲۰].

۸.۲.۲ حق فراموشی

حق فراموشی^۱ به کاربران امکان می‌دهد که اطلاعات خود را از سیستم حذف کنند. در سیستم‌های گفتگو، این ویژگی به کاربران اطمینان می‌دهد که می‌توانند داده‌های شخصی خود را در هر زمانی از سیستم پاک کنند و پس از آن دیگر دیتاهای کاربر در دسترسی کسی قرار نگیرد. [۲۹] این مفهوم برای حفظ حریم شخصی کاربر در سیستم‌های گفتگو امری ضروری است.

۹.۲.۲ یادگیری چند شات

در یادگیری چند شات^۲، مدل تنها با چند مثال محدود آموزش داده می‌شود و سپس می‌تواند وظایف مشابه را با داده‌های کمی انجام دهد. این رویکرد برای تنظیم سریع مدل‌ها بدون نیاز به مجموعه داده‌های بزرگ استفاده می‌شود [۵].

۱۰.۲.۲ یادگیری بدون شات

در یادگیری شات صفر^۳، مدل توانایی انجام وظایف جدید را بدون نیاز به دیدن داده‌های نمونه‌ای از آن وظیفه دارد. این روش برای تعمیم‌پذیری مدل‌ها و سازگاری با وظایف جدید بسیار مهم است [۵].

⁵Sentiment Analysis

¹Right to be Forgotten

²Few-Shot Learning

³Zero-Shot Learning

۳.۲ مروری بر پیشینه پژوهش

۱.۳.۲ سیستم‌های گفتگو

۱.۱.۳.۲ سیستم‌های گفتگوی وظیفه‌گرا

در پژوهش گفتگوی وظیفه‌گرا با یادگیری درون‌متنی [۳]، نویسندگان یک رویکرد ترکیبی را ارائه می‌دهند که مدل‌های زبانی بزرگ را برای سیستم‌های گفتگوی وظیفه‌گرا با منطق تجاری^۴ از پیش تعریف‌شده ترکیب می‌کند. این سیستم از مدل‌های زبانی بزرگ برای تبدیل مکالمات طبیعی به یک زبان دامنه خاص^۵ استفاده می‌کند، و سپس از این زبان دامنه خاص برای اجرای وظایف مبتنی بر منطق تجاری استفاده می‌شود. این رویکرد از معماری‌های سنتی مبتنی بر هدف در درک زبان طبیعی فاصله گرفته و با بهره‌گیری از یادگیری درون‌متنی، توسعه و مقیاس‌پذیری سیستم‌های پیچیده گفتگو را تسهیل می‌کند.

پژوهش فوق‌محدودیت‌های سیستم‌های سنتی درک زبان طبیعی مبتنی بر هدف را نقد می‌کند. چالش‌هایی که در مقیاس‌بندی و مدیریت صدها هدف در سیستم‌های وظیفه‌گرا وجود دارد، موجب می‌شود که فرآیند اشکال‌زدایی و بازخوردگیری به مراتب پیچیده‌تر شود. همچنین، سیستم‌های مبتنی بر درک زبان طبیعی معمولاً نمی‌توانند به‌خوبی تغییرات طبیعی در عبارات کاربر را مدیریت کنند و این می‌تواند منجر به از دست رفتن اطلاعات حساس و پاسخ‌های کمتر مؤثر شود.

رویکرد ارائه‌شده در این پژوهش بر استفاده از مدل‌های زبانی بزرگ برای ترجمه گفتگوهای طبیعی به زبان دامنه خاص تمرکز دارد. این ترجمه به سیستم اجازه می‌دهد تا بدون نیاز به اهداف از پیش تعریف‌شده، عبارات کاربر را پردازش کند. مدل‌های زبانی بزرگ زمینه مکالمه را ضبط کرده و آن را به شکلی تبدیل می‌کند که توسط سیستم مدیریت گفتگو برای انجام وظایف استفاده شود. این فرآیند نیاز به تعریف مقاصد به‌صورت صریح را از بین می‌برد و مقیاس‌پذیری و انعطاف‌پذیری سیستم را افزایش می‌دهد.

این رویکرد در برابر روش‌های سنتی درک زبان طبیعی مبتنی بر هدف آزمایش شده و نتایج نشان می‌دهند که روش پیشنهادی به تلاش توسعه‌دهنده کمتری نیاز دارد. به‌ویژه در شرایطی که تعداد وظایف افزایش می‌یابد، عملکرد بهتری در مدیریت گفتگوهای پیچیده دارد. علاوه بر این، انعطاف‌پذیری سیستم بدون نیاز به بازآموزی یا تعاریف پیچیده اهداف افزایش یافته‌است.

روش ارائه‌شده در این رساله بر شخصی‌سازی و نمایه‌سازی کاربر در سیستم‌های گفتگوی وظیفه‌گرا متمرکز است. در حالی که پژوهش [۳] بر مقیاس‌پذیری تمرکز دارد، روش ارائه‌شده با تنظیم سریع به دنبال بهبود تجربه

⁴Business Logic

⁵Domain specific language (DSL)

شخصی‌سازی‌شده کاربران است. همچنین، مدیریت شروع سرد و حریم خصوصی کاربران از و استفاده از رویکردهای پروفایل‌سازی دقیق نیز پرداخته شده است درحالی‌که پژوهش فوق‌صحتی از این موارد نکرده است. معماری ارائه شده شامل سه عنصر اصلی منطق تجاری، درک گفتگو، و تعمیر مکالمه است که با هم کار می‌کنند تا یک سیستم گفتگوی وظیفه‌گرا یکپارچه، پاسخگو و تطبیقی را ایجاد کنند. در اینجا یک تفکیک دقیق از هر مؤلفه و نحوه تعامل آنها برای مدیریت مؤثر تعاملات کاربر آورده شده است:

۱. مازول درک گفتگو

- هدف: پیام‌های دریافتی کاربر را تفسیر می‌کند و با ترجمه مکالمه در حال انجام و پیام فعلی کاربر به یک قالب ساختاریافته، اغلب به صورت مجموعه‌ای از دستورات، زمینه گفتگو را حفظ می‌کند.
- فرآیند

(آ) آخرین پیام کاربر را دریافت می‌کند و آن را در زمینه مکالمه فعلی ارزیابی می‌کند.

(ب) مقاصد، موجودیت‌ها و نشانه‌های متنی مرتبط مورد نیاز برای به‌روزرسانی حالت مکالمه را تجزیه و تحلیل و استخراج می‌کند.

(ج) دستورات خاصی را ایجاد می‌کند که می‌تواند مراحل بعدی مکالمه را اطلاع دهد. این دستورات ممکن است شامل اهداف سطح بالا (مانند ثبت سفارش یا لغو اشتراک) و اقدامات سطح پایین (مانند تأیید هویت یا درخواست تأیید) باشد.

۲. مدیر گفتگو

- هدف: به عنوان کنترل‌کننده اصلی جریان گفتگو، مدیریت وضعیت مکالمه و تأیید دستورات تولید شده توسط مازول درک گفتگو^۱ عمل می‌کند.
- فرآیند

(آ) اعتبارسنجی فرمان^۲: مدیر گفتگو بررسی می‌کند که آیا دستورات تولیدشده با قوانین مکالمه فعلی و وضعیت گفتگو مطابقت دارند یا خیر.

(ب) مدیریت حالت: وضعیت مکالمه را بر اساس دستورات معتبر به‌روزرسانی می‌کند و اطمینان حاصل می‌کند که درک دستیار گفتگو از مکالمه به‌روز است.

¹Dialogue Understanding

²Command Validation

- (ج) تعمیر مکالمه^۳: اگر درک گفتگو ناهماهنگی‌ها یا خرابی‌ها را در مکالمه تشخیص دهد (به عنوان مثال، قصد مبهم کاربر یا اطلاعات اذست‌رفته)، الگوهای تعمیر راه‌اندازی می‌شوند و در حالت مکالمه ادغام می‌شوند.
- (د) اجرای منطق تجاری^۱ مدیریت گفتگو با تعامل با مازول منطق تجاری دستورات معتبر را اجرا می‌کند. به طور قطعی اقدامات و الگوهای تعمیر را پردازش می‌کند تا زمانی که ورودی کاربر جدید برای ادامه مورد نیاز باشد.

۳. اجرای منطق کسب و کار

- هدف: عملکردهای تجاری اصلی دستیار را اجرا می‌کند و دستورات تأیید شده توسط مدیر گفتگو را پیاده‌سازی می‌کند.
- فرآیند

- (آ) مؤلفه منطق تجاری بر اساس وضعیت به‌روزشده و دستورات معتبر، اقداماتی را مانند بازیابی اطلاعات، پردازش یک درخواست، یا به‌روزرسانی پایگاه‌داده انجام می‌دهد.
- (ب) اگر الگوهای تعمیر مورد نیاز است (به عنوان مثال، اگر نیاز به توضیح کاربر باشد)، منطق تجاری این الگوها را ادغام می‌کند و اطمینان می‌دهد که سیستم نیازهای کاربر را بدون قطع شدن جریان مکالمه برآورده می‌کند.
- (ج) چرخه تکرار: به اجرای اقدامات ادامه می‌دهد تا زمانی که به حالتی برسد که در آن ورودی اضافی کاربر لازم است، پس از آن منتظر دستورالعمل‌های بیشتر از کاربر است.

در این معماری، درک مکالمه^۲ ورودی کاربر را تفسیر می‌کند و دستورات ساخت یافته را تولید می‌کند. مدیر گفتگو وضعیت مکالمه را به‌روز، تعمیرهای مورد نیاز را مدیریت و دستورات را تأیید می‌کند. منطق تجاری اقدامات عملکردی دستیار را انجام می‌دهد و چرخه کار را قبل از انتظار برای ورودی بیشتر تکمیل می‌کند. این معماری جریان گفتگوی پویا و انعطاف‌پذیر را تضمین می‌کند، وقفه‌ها را در مکالمه به حداقل و وضوح و پاسخگویی را به حداکثر می‌رساند.

از مزایای سیستم ارائه‌شده در این پژوهش می‌توان به راحتی مقیاس‌بندی در چندین وظیفه و دامنه، کاهش نیاز به مدیریت دستی اهداف و حل پیچیدگی سیستم‌های مبتنی بر درک زبان طبیعی اشاره کرد. همچنین این سیستم توانایی پردازش گفتگوهای پیچیده و چندنوبتی را نیز دارد.

³Repair conversation

¹Business Logic Execution

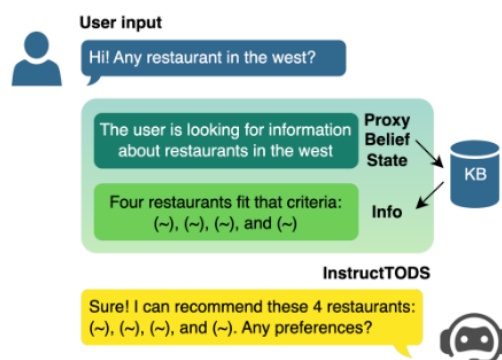
²Dialogue Understanding

یکی از محدودیت‌های این سیستم، وابستگی به مدل‌های زبانی بزرگ است که ممکن است برای پردازش در زمان واقعی یا در مقیاس وسیع، به منابع سخت‌افزاری قوی‌تری نیاز داشته باشد. همچنین، اگر سیستم برای یک حوزه خاص طراحی شده باشد، ممکن است در موقعیت‌هایی که قواعد و نیازهای مشخصی برای آن تعریف نشده‌اند، انعطاف‌پذیری آن کاهش یابد.

با وجود مزایای ارائه‌شده این سیستم، تفاوت‌های بارزی با رویکرد این پژوهش در زمینه شخصی‌سازی و مدیریت حریم خصوصی وجود دارد. در مجموع، رویکرد ارائه‌شده برای سیستم‌های وظیفه‌گرا با مقیاس بزرگ مناسب است، اما در بخش‌هایی مانند تجربه کاربری شخصی‌سازی‌شده، به اندازه روش ارائه‌شده این رساله انعطاف‌پذیر نیست.

سیستم‌های گفتگوی وظیفه‌محور به طور سنتی نیاز به داده‌های خاص دامنه و تنظیم دقیق مدل‌ها^۱ دارند تا بتوانند به طور مؤثر مکالمات را مدیریت کنند. با این حال، این رویکردها به دلیل نیاز به داده‌های گسترده و منابع محاسباتی زیاد، ناکارآمد هستند. پژوهش InstructTODS مدل‌های زبان بزرگ برای سیستم‌های گفتگوی وظیفه‌گرا تنها به انتها [۶]، به این مسئله پرداخته و یک چارچوب صفر شات ارائه می‌دهد که بدون نیاز به تنظیم دقیق و استفاده از داده‌های خاص وظیفه، قادر به تطبیق با پایگاه‌های دانش متنوع است و مکالمات را به طور مؤثر هدایت می‌کند. این روش، نیاز به استفاده از مقادیر شکاف و هستی‌شناسی‌های^۲ از پیش تعریف شده را حذف می‌کند و با تولید حالت باور انعطاف‌پذیر از ورودی کاربر، این ورودی‌ها را به جستارهای پویا تبدیل می‌کند [۱۷]

معماری سیستم ارائه‌شده در پژوهش InstructTODS در شکل ۱۰۲ آورده شده است.



شکل ۱۰۲: معماری سیستم InstructTODS [۶]

در این پژوهش، نویسندگان از مدل‌های زبانی بزرگ تنظیم شده با دستورالعمل برای ایجاد حالت باور استفاده می‌کنند که به عنوان نماینده نیت‌های کاربر عمل می‌کند و پایگاه‌های دانش را به صورت پویا در زبان طبیعی

^۱Fine Tuning

^۲Ontologies

جستجو می‌کند. سپس اطلاعات بازیابی شده برای تولید پاسخ استفاده می‌شود. بر خلاف سیستم‌های سنتی وظیفه‌گرا که به مولفه‌های مجزا مانند طبقه‌بندی هدف و ردیابی وضعیت باور نیاز دارند، InstructTODS این فرایندها را از طریق مدل‌های زبان بزرگ ادغام می‌کند و پاسخ‌ها را مستقیماً از ورودی‌های کاربر تولید می‌کند. ارزیابی‌های جامع روی وظایف فرعی سیستم‌های گفتگو وظیفه‌گرا شامل ردیابی حالت گفتگو، طبقه‌بندی نیت، و تولید پاسخ نشان می‌دهد که InstructTODS عملکرد مشابهی با سیستم‌های کاملاً تنظیم‌شده^۳ دارد و حتی در شرایط صفر شات قادر است مکالمات را به طور مؤثر هدایت کند. همچنین، ارزیابی‌های انسانی نشان داده که از نظر مفید بودن، طبیعی بودن، و آموزنده بودن، InstructTODS از مدل‌های پیشرفته سیستم‌های گفتگو وظیفه‌گرا برتر است [۱۷].

جوانب مثبت پژوهش فوق به شرح زیر است:

- قابلیت صفر شات: بدون نیاز به تنظیم دقیق یا داده‌های خاص وظیفه می‌توان از این سیستم استفاده کرد.
 - تطبیق‌پذیری: توانایی کار با پایگاه‌های دانش متنوع بدون نیاز به مقادیر شکاف یا هستی‌شناسی‌های از پیش تعریف شده.
 - کاهش هزینه‌های منابع: این رویکرد نسبت به سیستم‌های سنتی سیستم‌های گفتگو وظیفه‌گرا منابع کمتری نیاز دارد و کارایی را افزایش می‌دهد.
 - گفتگوی طبیعی‌تر: بر اساس ارزیابی‌های انسانی، پاسخ‌های تولید شده طبیعی‌تر و مفیدتر هستند.
- همچنین جوانب منفی این پژوهش نیز به شرح زیر است:
- محدودیت‌های مدل‌های زبانی بزرگ: استفاده از مدل‌های زبانی بزرگ نیازمند منابع محاسباتی زیادی است که ممکن است در برخی موارد چالش‌برانگیز باشد.
 - مشکلات بالقوه تعمیم: با اینکه روش صفر شات انعطاف‌پذیر است، ممکن است در وظایف خاص دامنه‌ای دچار مشکل شود.
 - موارد شکست: در برخی از وظایف پیچیده‌تر، مدل ممکن است به درک زمینه‌ای بیشتری نیاز داشته باشد و شکست بخورد.

در [۱۷]

^۳Fully fine-tuned

، تمرکز بر شخصی‌سازی و نمایه‌سازی کاربر است تا سیستم‌های گفتگوی وظیفه‌محور به طور پویا بر اساس ترجیحات کاربر سازگار شوند. همچنین به چالش‌هایی مانند شروع سرد، حریم خصوصی، و امتیاز تعامل کاربر پرداخته شده است. برخلاف InstructTODS که بیشتر بر سازگاری عمومی و یادگیری صفر شات تمرکز دارد، رویکرد این تحقیق به شخصی‌سازی عمیق‌تر و تعامل کاربر با سیستم توجه ویژه‌ای دارد. استفاده از پروفایل کاربر به سیستم اجازه می‌دهد که پاسخ‌ها را با دقت بیشتری به نیازهای کاربر تنظیم کند، در حالی که InstructTODS بیشتر بر کارایی و سازگاری با پایگاه‌های دانش عمومی تکیه دارد. در حالی که هر دو سیستم به کاهش پیچیدگی در سیستم‌های گفتگو وظیفه را کمک می‌کنند، تفاوت اساسی در نحوه رسیدگی به نیازهای کاربران وجود دارد. رویکرد رساله فوق با تمرکز بر پروفایل کاربر، تجربه کاربر را بهینه می‌کند، در حالی که InstructTODS به انعطاف‌پذیری عمومی در تنظیمات مختلف توجه دارد.

۲.۱.۳.۲ سیستم گفتگوی دامنه باز

سیستم‌های گفتگوی دامنه باز برای درگیر شدن در گفتگو در مورد طیف گسترده‌ای از موضوعات بدون هدف یا هدف خاصی طراحی شده‌اند. برخلاف سیستم‌های وظیفه‌محور، که هدفشان دستیابی به یک نتیجه خاص (مانند رزرو پرواز یا ارائه پشتیبانی مشتری) است، سیستم‌های دامنه باز بر حفظ یک مکالمه طبیعی و روان تمرکز می‌کنند.

در [۱۷] ربات چند شات^۱: یادگیری مبتنی بر پرامپت برای سیستم‌های گفتگو، سیستمی معرفی شده که بر مبنای یادگیری مبتنی بر پرامپت و چند شات طراحی شده است و به کمک چند نمونه مکالمه می‌تواند پاسخ‌های گفتگو محور را تولید کند. این سیستم بدون نیاز به تنظیم دقیق مدل و تنها با استفاده از پرامپت‌های محدود، قادر به مدیریت مکالمات مختلف است. این پژوهش به بررسی کاربردهای مختلف این رویکرد پرداخته و از جمله وظایف گفتگو، تولید پاسخ، پردازش مکالمات، و ایجاد پرسونا را ارزیابی کرده است. روش‌های مبتنی بر پرامپت به مدل‌های زبانی این امکان را می‌دهند که با بهره‌گیری از حداقل داده، عملکردی نزدیک به مدل‌های کاملاً آموزش‌دیده داشته باشند.

سهم اصلی این پژوهش، معرفی سیستم ربات چند شات است که از یادگیری چند شات مبتنی بر پرامپت بهره می‌برد تا به جای تنظیم دقیق و پرهزینه مدل‌های بزرگ زبانی، از چند نمونه مکالمه برای آموزش استفاده کند. این سیستم از توانایی یادگیری از طریق پرامپت‌ها بهره‌برده و با استفاده از مکانیزم انتخاب‌گر مهارت^۲، بهترین پاسخ را بر اساس تاریخچه مکالمات انتخاب می‌کند و از این طریق می‌تواند با جستجو در پایگاه‌های دانش پاسخ‌های طبیعی و مرتبط ارائه دهد.

¹Few-Shot Bot

²Skill Selector

دو چالش اصلی که در [۱۷] به آن‌ها پرداخته شده عبارت‌اند از:

۱. هزینه بالای تنظیم و آموزش مدل‌های بزرگ زبانی: این مدل‌ها به منابع محاسباتی قابل توجهی نیاز دارند که باعث افزایش هزینه‌های عملیاتی و زمان‌بری فرایند آموزش می‌شود. این پژوهش تلاش کرده با استفاده از یادگیری چند شات مبتنی بر پرامپت، رویکردی کم‌هزینه و کارآمد ارائه دهد.

۲. نبود بنچمارک‌های رسمی برای ارزیابی روش‌های مبتنی بر پرامپت در سیستم‌های گفتگو: در این پژوهش، نویسندگان با بررسی یازده مجموعه داده مرتبط با مکالمات، یک بنچمارک رسمی برای یادگیری مبتنی بر پرامپت ارائه کرده‌اند که به ارزیابی عملکرد و مقایسه با روش‌های متداول کمک می‌کند.

نویسندگان برای توسعه ربات چند شات از رویکردی استفاده کرده‌اند که در آن مدل‌های زبانی با نمونه‌های کوچک و بهینه‌شده هدایت می‌شوند. این سیستم از پرامپت‌های چند شات استفاده می‌کند و قادر است مکالمات متنوعی را مدیریت کرده و پاسخ‌های مناسبی ارائه دهد. از سوی دیگر، یک انتخاب‌گر مهارت به سیستم اضافه شده که بر اساس داده‌های ورودی، بهترین مهارت مورد نیاز یک مکالمه را برای هر سوال انتخاب می‌کند. در این رویکرد، از هیچگونه تنظیم دقیق برای بهینه‌سازی مدل استفاده نمی‌شود و تنها پرامپت‌های کوتاه و ساده هدایتگر مدل هستند.

ارزیابی و نتایج پژوهش با استفاده از چندین معیار ارزیابی، از جمله تولید پاسخ‌های دقیق، پردازش پرسونا و ارزیابی‌های انسانی، نشان داده که ربات چند شات در بسیاری از موارد توانسته است به عملکردی مشابه یا بهتر از مدل‌های کاملاً تنظیم‌شده دست یابد. نتایج حاکی از آن است که این سیستم بدون نیاز به تنظیم دقیق و تنها با بهره‌گیری از پرامپت‌های چند شات، قادر به تولید پاسخ‌های طبیعی و مرتبط است که این رویکرد برای محیط‌هایی که نیاز به تنظیم دقیق و منابع زیاد ندارند، مناسب است.

از جمله مزایای اصلی این رویکرد، کاهش چشمگیر هزینه‌های محاسباتی است. به دلیل عدم نیاز به تنظیم دقیق و استفاده تنها از پرامپت‌ها، هزینه‌ها به میزان قابل توجهی کاهش یافته و این روش سازگاری مناسبی با وظایف مختلف مانند چت آزاد، تولید پاسخ‌های مبتنی بر دانش و پردازش اطلاعات دارد. همچنین، استفاده از انتخاب‌گر مهارت و یادگیری مبتنی بر پرامپت، باعث افزایش دقت پاسخ‌ها و تناسب آن‌ها با نیازهای کاربر می‌شود. از معایب این روش می‌توان به نیاز به طراحی دقیق پرامپت‌ها اشاره کرد که برای هر وظیفه نیازمند تخصص است. همچنین، در تعاملات پیچیده و شرایط خاص دامن، این روش ممکن است دقت کمتری نسبت به مدل‌های کاملاً تنظیم‌شده داشته باشد.

پژوهش: XDAI: چارچوبی بدون تنظیم برای بهره‌برداری از مدل‌های زبانی از پیش آموزش‌دیده در تولید گفتگوی مبتنی بر دانش [۲۷] چارچوبی بدون نیاز به تنظیم دقیق ارائه می‌دهد که برای ایجاد سیستم‌های گفتگوی مبتنی بر دانش طراحی شده است. این سیستم از مدل‌های زبانی از پیش آموزش‌دیده استفاده می‌کند و تلاش می‌کند

تا چالش‌های موجود در ساخت چنین سیستم‌هایی، از جمله گردآوری منابع دانش و نیاز به تنظیم مدل‌ها، را کاهش دهد. با استفاده از XDAI، توسعه‌دهندگان می‌توانند به سرعت سیستم‌های گفتگوی عمومی یا خاص دامنه ایجاد کنند.

مهم‌ترین نوآوری [۲۷] ارائه چارچوب XDAI است که شامل ویژگی‌های زیر است:

۱. شروع سریع: ارائه یک سرویس گفتگوی مبتنی بر دانش که از منابع آماده برای دامنه عمومی استفاده می‌کند.

۲. استنتاج کارآمد: استفاده از الگوهای پرسشی جدید که کیفیت دیالوگ‌ها را بدون نیاز به تنظیم دقیق مدل بهبود می‌بخشند.

۳. استقرار سفارشی: امکان استفاده از افزونه‌های قابل تغییر برای جمع‌آوری خودکار منابع دانش خاص دامنه.

۴. تغییرات افزایشی: ابزارهایی برای توسعه و شخصی‌سازی تدریجی سیستم فراهم می‌کند.

در [۲۷] آزمایش‌های گسترده‌ای شامل ارزیابی‌های آنلاین و آزمون تورینگ انجام داده‌است و نتایج نشان می‌دهد که عملکردی رقابتی با مدل‌های پیشرفته کاملاً تنظیم‌شده ارائه می‌دهد. همچنین قابلیت استفاده در دامنه‌های مختلف را با هزینه محاسباتی کمتر فراهم می‌کند.

از مزایای سیستم [۲۷] می‌توان به عدم نیاز به تنظیم دقیق و کاهش هزینه‌های محاسباتی و زمانی اشاره کرد. همچنین انعطاف‌پذیری بالا، قابلیت شخصی‌سازی و استفاده در دامنه‌های مختلف از نقاط قوت دیگر این سیستم است. علاوه بر موارد ذکر شده این سیستم از شروع سرد پشتیبانی می‌کند که استفاده از قابلیت‌های شات صفر برای پاسخ‌دهی بدون نیاز به داده‌های اولیه آنرا میسر کرده است.

پژوهش ارائه‌شده در [۲۷] بر شخصی‌سازی، پروفایل‌سازی کاربران و همچنین ملاحظات حریم خصوصی تأکید دارد. در حالی که XDAI با تمرکز بر یادگیری بدون تنظیم دقیق و تزریق دانش با پرامپت‌ها عملکردی کارآمدی ارائه می‌دهد، پژوهش رساله فوق‌قابلیت‌های بیشتری در زمینه تطبیق با کاربران و استفاده از پروفایل‌های کاربری برای تولید پاسخ‌های شخصی‌سازی شده دارد.

از معایب سیستم [۲۷] می‌توان به کیفیت محدود پرامپت‌ها اشاره کرد. طراحی بهینه پرامپت‌ها برای وظایف پیچیده نیازمند تخصص است. همچنین عدم شخصی‌سازی عمیق را نیز می‌توان به عنوان عیب دیگری از این سیستم نام برد. در XDAI، تمرکز بیشتر بر بهره‌وری عمومی مدل‌ها و نه بر شخصی‌سازی عمیق پروفایل کاربر بوده است.

۲.۳.۲ تنظیم سریع و تکنیک‌های انطباق مدل

۱. تنظیم سریع برای کارایی سیستم گفتگو

سیستم گفتگوی شخصی‌سازی‌شده با استفاده از تکنیک تنظیم سریع [۱۵] از روش‌های بهینه‌سازی بردارهای تعبیه‌شده^۱ برای پیش‌برد گفتگوها استفاده می‌کند. هدف اصلی این سیستم، ارائه پاسخ‌های گفتگو محوری است که هم از نظر پرسونا^۲ (شخصیت از پیش تعریف شده) منسجم باشد و هم هزینه محاسباتی اندکی داشته باشد. این سیستم توانسته با به حداقل رساندن تغییرات در پارامترهای اصلی مدل زبانی، کارایی مطلوبی از نظر منابع ارائه دهد.

این پژوهش به‌طور دقیق به چالش‌های سیستم‌های گفتگوی چند نوبتی^۳ پرداخته و راه‌حلی برای بهبود شخصی‌سازی پاسخ‌ها بدون نیاز به داده‌های زیاد و قدرت محاسباتی ارائه می‌دهد. از جمله مشکلات اصلی که سیستم‌های چند نوبته با آن مواجه هستند، تناقض در پاسخ‌ها است؛ به عنوان مثال، ممکن است یک سیستم در مکالمه‌های مختلف مکان‌های متفاوتی را به عنوان محل سکونت خود اعلام کند. از طرف دیگر، سیستم‌های سنتی برای تعبیه اطلاعات شخصی در ورودی مدل، نیاز به طول ورودی زیادی دارند که کارایی را کاهش می‌دهد.

رویکرد [۱۵] بر استفاده از تنظیم سریع تأکید دارد که با مسدود کردن پارامترهای مدل از پیش‌آموزش‌دیده و افزودن یک پرامپت با طول ثابت قبل از توالی ورودی، اطلاعات شخصیتی کاربر (پرسونا) را جاسازی می‌کند.

این تکنیک از چند مولفه کلیدی تشکیل شده است:

- مدل‌های زبانی از پیش‌آموزش‌دیده: استفاده از مدل‌های مبتنی بر معماری جی‌پی‌تی که از قبل قابلیت‌های گفتگوی عمومی دارند.
- تنظیم سریع: تنظیم تعداد کمی از بردارهای تعبیه‌شده که به خوبی می‌توانند اطلاعات شخصیت را ضبط و بهینه کنند.
- جاسازی اطلاعات شخصیت: این سیستم با استفاده از تعبیه‌های بهینه‌شده، اطمینان حاصل می‌کند که پاسخ‌ها با شخصیت خاص کاربر سازگار باشند.

کاساهارا و همکاران [۱۵] دو نوع ارزیابی خودکار و دستی را برای بررسی کیفیت سیستم ارائه داده‌اند. نتایج به زبان‌های انگلیسی و ژاپنی بررسی شده و نشان داده است که سیستم توانسته پاسخ‌هایی منسجم و


¹Embedding Vectors

²Persona

³multi-turn dialogue system

طبیعی ارائه دهد. همچنین، کارایی محاسباتی سیستم در مقایسه با تنظیم دقیق کامل مدل به مراتب بالاتر است و نیاز به منابع محاسباتی کمتری دارد. مهم‌ترین معیارها در این ارزیابی‌ها شامل انسجام پاسخ‌ها بر اساس پرسونا، طبیعی بودن دیالوگ‌ها و کارایی محاسباتی بود که نتایج مطلوبی ارائه شد.

معماری روش پیشنهادی [۱۵] از چند لایه اصلی تشکیل شده است. ابتدا یک مدل زبانی از پیش‌آموزش‌دیده به عنوان هسته اصلی سیستم استفاده می‌شود. در این سیستم، پارامترهای مدل اصلی دست‌نخورده باقی می‌مانند و در عوض، یک پرامپت ثابت به ورودی مدل اضافه می‌شود که شامل اطلاعات مرتبط با شخصیت کاربر است. تنظیم سریع تنها بردارهای تعبیه‌شده مرتبط با پرامپت را بهینه می‌کند، بدون آنکه پارامترهای مدل اصلی تغییر کند. این رویکرد باعث می‌شود که سیستم بتواند با کمترین منابع، پاسخ‌هایی با توجه به شخصیت از پیش تعریف‌شده ارائه دهد. معماری این سیستم در شکل ۲.۲ آورده شده است.



شکل ۲.۲: معماری ایجاد یک سیستم گفتگوی شخصی با تنظیم سریع [۱۵]

مزایا و معایب سیستم به شرح زیر است.

• مزایا:

- کارایی محاسباتی بالا: به دلیل عدم نیاز به تغییر پارامترهای اصلی مدل، تنظیم سریع نسبت به تنظیم دقیق کامل منابع کمتری مصرف می‌کند.
- شخصی‌سازی با داده‌های اندک: با استفاده از داده‌های محدود (چند صد جفت گفتار-پاسخ)، سیستم می‌تواند پاسخ‌های شخصی ارائه دهد.
- اثربخشی بین‌المللی: سیستم در چندین زبان از جمله انگلیسی و ژاپنی عملکرد مطلوبی نشان داده است و از نظر زبانی قابل تطبیق است.
- سازگاری پرسونا: این سیستم توانسته به یکی از چالش‌های اصلی یعنی ثبات در پاسخ‌های شخصیتی به خوبی پاسخ دهد و از تضاد در مکالمات جلوگیری کند.

• معایب:

- پیچیدگی در طراحی پرامپت: طراحی صحیح پرامپت‌ها برای هر شخصیت نیاز به تخصص دارد و اگر طراحی بهینه نباشد، ممکن است کیفیت دیالوگ کاهش یابد.
- محدودیت در انطباق‌پذیری: در حالی که این سیستم برای وظایف تعریف‌شده شخصیت محور عملکرد مطلوبی دارد، انعطاف‌پذیری آن در برخورد با شخصیت‌های متعدد یا وظایف پیچیده‌تر ممکن است محدود باشد.
- نبود مکانیزم شروع سرد: در این پژوهش به‌صراحت به مشکل شروع سرد اشاره‌ای نشده است؛ هرچند این تکنیک از طریق تنظیم سریع ممکن است برخی از مشکلات کمبود داده را کاهش دهد.

پژوهش ارائه‌شده، رویکردی کارآمد برای ایجاد سیستم گفتگوی شخصی‌سازی‌شده با استفاده از تنظیم سریع ارائه می‌دهد. این سیستم با حفظ ثبات شخصیت و مصرف حداقل منابع، توانسته است کارایی مطلوبی در چندین زبان ارائه دهد. در مقابل، تحقیقات رساله فوق به دنبال ارائه گفتگوهای هدف‌گرا و پروفایل‌سازی کاربر است که بتواند تجربه‌ای شخصی‌تر و مبتنی بر وظایف به کاربران ارائه دهد. این دو رویکرد می‌توانند در کنار یکدیگر مکمل باشند و بهبودهایی در زمینه شخصی‌سازی و انطباق‌پذیری گفتگوی هوشمند فراهم کنند.

۲. تنظیم دقیق و رویکردهای ترکیبی

دیالیت^۱ توسعه سبک و چندزبانه و ارزیابی سیستم‌های گفتگوی وظیفه‌محور با مدل‌های زبانی بزرگ [۱۳] ، یک جعبه‌ابزار^۲ برای توسعه و ارزیابی سیستم‌های گفتگوی وظیفه‌محور چندزبانه ارائه می‌کند. این جعبه‌ابزار قابلیت مقایسه بین سیستم‌های مبتنی بر تنظیم دقیق مدل‌های زبانی از پیش آموزش دیده و سیستم‌های جدیدتر مبتنی بر مدل‌های زبانی بزرگ را دارد. دیالیت به کاربران این امکان را می‌دهد که علاوه بر ارزیابی‌های خودکار، از ارزیابی‌های انسانی دقیق در سطوح مختلف از جمله سطح گفتگو و سطح جمله نیز بهره‌مند شوند. همچنین این جعبه‌ابزار از یک معماری مبتنی بر میکروسرویس استفاده می‌کند که به مقیاس‌پذیری و کارایی بهتر کمک می‌کند [۱۳]

مشکل اصلی که در این پژوهش به آن پرداخته شده، چالش ارزیابی و توسعه‌ی کارآمد سیستم‌های گفتگوی وظیفه‌محور چندزبانه است. سیستم‌های کنونی عمدتاً بر مدل‌های زبانی از پیش آموزش دیده با تنظیم دقیق

¹DIALIGHT

²Tool box

تکیه دارند که دقت بالاتری در تطبیق با وظایف خاص دارند، اما این مدل‌ها نیازمند زمان و منابع زیادی برای تنظیم هستند. از طرف دیگر، سیستم‌های مبتنی بر مدل‌های زبانی بزرگ از قابلیت تولید پاسخ‌های متنوع‌تر و طبیعی‌تر بهره‌مند هستند، اما مشکلاتی در اجرای دقیق دستورالعمل‌ها و تولید پاسخ‌های چندزبانه دارند. [۱۳]

دیالیت با ارائه‌ی یک جعبه‌ابزار جامع برای ارزیابی این دورویکرد، شکاف موجود را برطرف می‌کند. رویکرد اصلی دیالیت به شرح زیر است:

- تنظیم دقیق مدل‌های مدل‌های زبانی از پیش آموزش‌دیده: دیالیت امکان تنظیم دقیق مدل‌های زبانی از پیش آموزش‌دیده برای تطبیق آن‌ها با وظایف خاص را فراهم می‌کند. این فرایند بر اساس آموزش مدل‌ها بر روی داده‌های مکالمه‌ی وظیفه‌محور انجام می‌شود.
 - یادگیری درون‌زمینه^۱ و بدون شات: سیستم‌های مبتنی بر مدل‌های زبان بزرگ بدون نیاز به تنظیم دقیق می‌توانند مکالمات وظیفه‌محور را در حالت‌های شات صفر و چندشات تولید کنند، اگرچه محدودیت‌هایی در تطابق دقیق با وظایف خاص دارند.
 - پلتفرم چندزبانه: دیالیت امکان ارزیابی سیستم‌های گفتگو را در زمینه‌های تک‌زبانه، چندزبانه و حتی بین‌زبانی فراهم می‌کند و این یک قابلیت مهم برای توسعه‌ی سیستم‌های گفتگوی چندزبانه است.
- ارزیابی‌ها نشان دادند که این روش منجر به دقت بالاتر و انسجام بیشتر در پاسخ‌ها می‌شود. اگرچه این سیستم‌ها خروجی‌های متنوعی تولید می‌کنند، اما در پیروی از دستورالعمل‌های خاص کار و ایجاد پاسخ‌های دقیق چندزبانه محدودیت‌هایی دارند. این مشکلات نشان‌دهنده نیاز به تحقیقات بیشتر در این حوزه است.
- مزایای این سیستم به شرح زیر است.
- پشتیبانی از یادگیری بدون شات و درون‌زمینه: سیستم‌های مدل‌های زبانی بزرگ می‌توانند بدون نیاز به تنظیم دقیق، پاسخ‌های مورد انتظار در حالت‌های شات صفر و چندشات تولید کنند.
 - ارزیابی چندزبانه و بین‌زبانی: دیالیت می‌تواند به‌صورت یکپارچه سیستم‌های گفتگوی وظیفه‌محور را در زبان‌های مختلف و حتی میان‌زبانی ارزیابی کند، که این یک نیاز مهم در توسعه سیستم‌های گفتگوی چندزبانه است.

¹In-Context Learning

- معماری مقیاس‌پذیر: استفاده از میکروسرویس‌ها امکان مقیاس‌پذیری بالا و کارایی بهتر را در ارزیابی‌ها فراهم می‌کند.

- ارزیابی جامع انسانی و خودکار: دیالیت با ترکیب ارزیابی‌های انسانی و خودکار دید جامعی از عملکرد سیستم‌ها ارائه می‌دهد.

همچنین از معایت دیالیت می‌توان به موارد زیر اشاره کرد.

- مشکلات مدل‌های زبانی بزرگ در تطبیق با وظایف خاص: سیستم‌های مدل‌های زبانی بزرگ با چالش‌هایی در پای‌بندی دقیق به وظایف خاص و تولید پاسخ‌های منسجم مواجه هستند.

- مصرف منابع محاسباتی زیاد: استفاده از مدل‌های زبانی بزرگ برای سیستم‌های گفتگوی وظیفه‌محور منابع محاسباتی بالایی نیاز دارد.

- پیچیدگی تنظیم دقیق مدل‌های زبانی از پیش آموزش‌دیده: فرایند تنظیم دقیق مدل‌های زبانی از پیش آموزش‌دیده نیازمند منابع زیاد است، اما در مقایسه با مدل‌های زبانی بزرگ منجر به دقت و انسجام بیشتری در پاسخ‌ها می‌شود.

در مقایسه با روش ارائه‌شده رساله فوق، که بر شخصی‌سازی سیستم‌های گفتگو و حل مشکلات شروع سرد و حق فراموشی تمرکز دارد، دیالیت بیشتر به ارزیابی عملکرد سیستم‌های گفتگوی وظیفه‌گرا در زبان‌های مختلف و مقایسه بین روش‌های تنظیم دقیق مدل‌های زبانی از پیش آموزش‌دیده و مدل‌های زبان بزرگ پرداخته است. رساله فوق علاوه بر اینکه به یادگیری شات صفر و شخصی‌سازی مکالمات توجه دارد، به مشکلات حریم خصوصی و حق فراموشی نیز می‌پردازد که در دیالیت به‌طور خاص به آن پرداخته نشده است.

در [۲۲] با عنوان «شبیه‌سازی گفتگوهای وظیفه‌گرا با استفاده از نمودارهای انتقال حالت و مدل‌های زبان بزرگ»، به معرفی سینتود^۱ پرداخته است. این چارچوب نوآورانه برای تولید داده‌های مصنوعی طراحی شده که به توسعه و ارتقاء سیستم‌های گفتگوی وظیفه‌گرا کمک می‌کند. با استفاده از نمودارهای انتقال حالت^۲ و مدل‌های زبانی بزرگ، سینتود مکالمات ساختاریافته‌ای را شبیه‌سازی می‌کند. مهم‌ترین ویژگی این چارچوب توانایی آن در تولید مجموعه داده‌های مصنوعی متنوع و غنی برای آموزش سیستم‌های گفتگو است که به مشکل کمبود داده‌های متنوع، که یکی از چالش‌های اصلی در آموزش مدل‌های گفتگو محور

¹SynTOD

²State Transition Graphs (STGs)

محسوب می‌شود، رسیدگی می‌کند. در این پژوهش، سینتود به عنوان راه‌حلی برای تولید داده‌های مصنوعی معرفی شده که از جمع‌آوری داده‌های دنیای واقعی بی‌نیاز است. این چارچوب با استفاده از نمودارهای انتقال حالت به سیستم اجازه می‌دهد تا مکالمات را در قالب مسیرهای مشخص هدایت کند و سپس مدل‌های زبانی بزرگ این مسیرها را دنبال کرده و مکالمات وظیفه‌گرا تولید کنند. این مکالمات مصنوعی به بهبود عملکرد سیستم‌های گفتگویی، به ویژه در وظایف پیچیده نظیر طبقه‌بندی هدف، پر کردن شکاف و تولید پاسخ کمک می‌کنند.

یکی از چالش‌های اساسی که در طراحی سیستم‌های گفتگو وظیفه‌گرا مطرح است، کمبود داده‌های متنوع و باکیفیت برای آموزش این سیستم‌ها است. مدل‌های موجود به دلیل محدودیت‌های مرتبط با داده‌ها اغلب در انجام وظایف پیچیده مانند پاسخ‌دهی به سؤالات کاربران و دسته‌بندی مقاصد کاربران دچار مشکل هستند. روش‌های سنتی جمع‌آوری داده‌ها، مانند جمع‌سپاری، معمولاً پرهزینه و زمان‌بر هستند و نمی‌توانند حجم کافی از داده‌های لازم را برای توسعه سیستم‌های قوی فراهم کنند. به علاوه، مدل‌های زبانی بزرگ که صرفاً برای تولید مکالمات استفاده می‌شوند، غالباً در ایجاد تنوع در مکالمات ناکام هستند و داده‌های تولید شده توسط آنها، پیچیدگی و عمق کافی برای انجام وظایف گوناگون را ندارند. سینتود با تولید مجموعه‌های داده مصنوعی از طریق ترکیب نمودارهای انتقال حالت و مدل‌های زبانی بزرگ، به این مشکل رسیدگی کرده و امکان تولید مکالمات متنوع و چندبعدی را فراهم می‌کند که در دامنه‌های مختلف وظیفه‌گرا قابل استفاده هستند.

سینتود با استفاده از نمودارهای انتقال حالت و پیاده‌روی‌های تصادفی^۳ برای شبیه‌سازی مکالمات وظیفه‌گرا یک رویکرد جامع و ساختاریافته ارائه می‌دهد. مراحل این رویکرد به شرح زیر است:

- نمودار انتقال حالت: در این بخش از سیستم، ساختار و جریان کلی مکالمه تعریف می‌شود. نمودار انتقال حالت نشان می‌دهد که یک کاربر از طریق مقاصد و نیازهای مختلف چگونه می‌تواند با سیستم تعامل کند. این نمودار جریان‌های مکالمه و پاسخ‌های سیستم به کاربران را در قالب حالات مختلف و گذرها به تصویر می‌کشد. نمودارهای انتقال حالت کمک می‌کنند تا مکالمات منطقی و پیش‌بینی‌پذیر طراحی شوند.
- پیاده‌روی‌های تصادفی: سینتود از پیاده‌روی‌های تصادفی برای پیمایش نمودارهای انتقال حالت استفاده می‌کند. این کار باعث می‌شود که سیستم بتواند مکالمات متنوع و چندگانه را تولید کند. هر بار که سیستم از یک نمودار عبور می‌کند، حالت‌های جدیدی در مکالمه به وجود می‌آیند که منجر به تولید مسیرهای متفاوت و متنوع می‌شود. این امر به سیستم امکان می‌دهد تا بتواند در

³Random Walks

شرایط مختلف، عملکردهای متفاوتی را به نمایش بگذارد.

- شبیه‌سازی پاسخ با مدل‌های زبان بزرگ: در مرحله نهایی، از مدل‌های زبان بزرگ تنظیم‌شده برای تولید پاسخ‌های طبیعی در مکالمات استفاده می‌شود. برخلاف روش‌های ساده که تنها به تولید یک پاسخ بر اساس یک ورودی می‌پردازند، در اینجا مدل‌های زبانی بزرگ از طریق شبیه‌سازی مکالمات در مسیرهای مختلف، پاسخ‌های ساختاریافته و مبتنی بر مکالمه تولید می‌کنند.

سینتود در دو دامنه مختلف مورد ارزیابی قرار گرفته است: کمک آشپزی و تجارت الکترونیک. در هر دو حوزه، عملکرد سینتود از طریق ارزیابی‌های خودکار و ارزیابی‌های انسانی مورد بررسی قرار گرفت. ارزیابی‌های خودکار شامل معیارهایی نظیر دقت و یادآوری بود که عملکرد سیستم را در انجام وظایف مختلف مانند طبقه‌بندی هدف و پر کردن شکاف‌ها بررسی کردند.

در کنار ارزیابی‌های خودکار، ارزیابی‌های انسانی نیز انجام شد تا کیفیت و انسجام مکالمات تولید شده توسط سیستم بررسی شود. نتایج نشان داد که سینتود قادر است مکالمات غنی‌تر و متنوع‌تری نسبت به مدل‌های ساده مبتنی بر یک ورودی ایجاد کند. به‌ویژه، مکالمات تولید شده توسط سینتود نسبت به مکالمات تک‌ورودی که توسط مدل‌های زبانی بزرگ تولید شده‌اند، بهبود قابل ملاحظه‌ای در عملکرد وظایف نشان دادند.

از مزایای سینتود می‌توان به‌تولید داده‌های مصنوعی بدون نیاز به جمع‌آوری داده‌های واقعی اشاره کرد. یکی از بزرگ‌ترین مزیت‌های سینتود این است که نیازی به جمع‌آوری داده‌های واقعی و پرهزینه ندارد. با استفاده از مدل‌های زبان بزرگ و نمودارهای انتقال حالت، می‌توان داده‌های مصنوعی متنوع و با کیفیت بالا تولید کرد که در آموزش سیستم‌های گفتگو مورد استفاده قرار می‌گیرند.

همچنین مکالمات تولید شده توسط سینتود از نظر پیچیدگی و تنوع نسبت به مکالمات جمع‌آوری‌شده یا تولید‌شده توسط مدل‌های ساده‌تر، بسیار غنی‌تر هستند. این ویژگی به سیستم‌های گفتگو امکان می‌دهد تا در موقعیت‌های پیچیده عملکرد بهتری از خود نشان دهند. علاوه بر این سینتود توانایی انطباق با دامنه‌های مختلف وظیفه‌محور را نشان داده است و در حوزه‌هایی نظیر تجارت الکترونیک و کمک آشپزی عملکرد موفقی داشته است.

از معایب سینتود می‌توان به وابستگی به طراحی نمودار انتقال حالت اشاره کرد. کیفیت گفتگوهای تولید‌شده به میزان زیادی به طراحی دقیق نمودارهای انتقال حالت وابسته است. این به معنای آن است که برای هر دامنه، باید نمودارهای اختصاصی و متناسب طراحی شود که ممکن است نیاز به تنظیمات دستی و زمان‌بر داشته باشد.

در حالی که سینتود توانسته است در حوزه‌های محدود عملکرد موفقی از خود نشان دهد، گسترش این

رویکرد به حوزه‌های متنوع‌تر و وسیع‌تر ممکن است چالش‌برانگیز باشد. به‌خصوص، مقیاس‌پذیری این رویکرد در دامنه‌های پیچیده‌تر نیاز به بررسی و آزمایش بیشتر دارد.

سینتود یک چارچوب نوآورانه است که با استفاده از نمودارهای انتقال حالت و مدل‌های زبان بزرگ، امکان تولید داده‌های مصنوعی غنی و متنوع برای آموزش سیستم‌های گفتگورا فراهم می‌کند. این رویکرد به‌ویژه در زمینه‌هایی که جمع‌آوری داده‌های واقعی دشوار است، بسیار مفید است. با این حال، شخصی‌سازی و پروفایل‌سازی کاربر در این چارچوب به‌صورت مستقیم مورد توجه قرار نگرفته است. در مقایسه، در تحقیقات این رساله، به‌طور خاص بر روی مسائل مربوط به شخصی‌سازی و مدیریت هویت گوینده تمرکز شده و تلاش می‌شود با استفاده از یادگیری چندشات و صفرشات و همچنین توسعه سیستم‌های گفتگوی وظیفه‌گرای یکی از چالش‌های اصلی در هوش مصنوعی است که هدف آن، طراحی سیستم‌هایی است که بتوانند به‌صورت دقیق و هوشمندانه به تعاملات کاربران در انجام وظایف خاص پاسخ دهند. با این حال، کمبود داده‌های متنوع و باکیفیت برای آموزش این سیستم‌ها، یکی از موانع بزرگ در بهبود عملکرد آنهاست. به همین دلیل، روش‌های جدید برای تولید داده‌های مصنوعی برای توسعه و آموزش این سیستم‌ها اهمیت ویژه‌ای پیدا کرده است.

سکوویچ و همکاران [۲۳] در پژوهش شبیه‌ساز کاربر مبتنی بر مدل‌های زبانی بزرگ قابل اعتماد برای سیستم‌های گفتگوی وظیفه‌گرا، به معرفی شبیه‌ساز کاربر آگاه از دامنه^۱ می‌پردازد. شبیه‌ساز کاربر آگاه از دامنه یک شبیه‌ساز مولد برای سیستم‌های گفتگوی وظیفه‌گرا است که از مدل‌های زبانی بزرگ استفاده می‌کند و با تنظیم دقیق آن‌ها بر داده‌های مکالمه‌ای خاص هر دامنه، به بهبود شبیه‌سازی کاربر می‌پردازد. هدف اصلی پژوهش، کاهش مشکلات مربوط به توهّمات در شبیه‌سازی‌های کاربر و ایجاد تعاملات منسجم‌تر و مرتبط‌تر است که باعث افزایش دقت در شبیه‌سازی کاربران واقعی می‌شود. در نتیجه، شبیه‌ساز کاربر آگاه از دامنه ارزیابی و توسعه سیستم‌های گفتگو وظیفه‌گرا را به‌ویژه در تشخیص خطاها و دستیابی کاربران شبیه‌سازی‌شده به اهداف مشخص‌شده تسهیل می‌کند.

این پژوهش به مسئله عدم قابلیت اطمینان و ناسازگاری شبیه‌سازهای کاربر موجود می‌پردازد. روش‌های موجود معمولاً به سیستم‌های مبتنی بر قوانین سفت و سخت یا داده‌های حاشیه‌نویسی شده تکیه می‌کنند که منجر به تعاملات شبیه‌سازی‌شده نادرست و نامربوط می‌شوند. چالشی اصلی، توهّمات شبیه‌ساز است که در آن سیستم محتوای نامرتبط یا متناقض تولید می‌کند. شبیه‌ساز کاربر آگاه از دامنه با کاهش توهّمات و افزایش انسجام شبیه‌ساز با اهداف کاربر، به رفع این چالش می‌پردازد. روش پیشنهادی شبیه‌ساز کاربر آگاه از دامنه شامل موارد زیر است:

¹Domain-aware user simulator

- تنظیم دقیق بر داده‌های دامنه‌محور: مدل‌های زبان بزرگ از طریق تنظیم دقیق بر روی مکالمات خاص دامنه‌ای، توانایی حفظ انسجام و مرتبط بودن مکالمات را افزایش می‌دهند.
 - شبیه‌سازی مبتنی بر اهداف کاربر: شبیه‌ساز کاربر آگاه از دامنه با شروع از اهداف مشخص شده برای کاربر، با سیستم‌های گفتگوی وظیفه‌گرا تعامل می‌کند و دیالوگ‌های چندنوبتی ایجاد می‌کند.
 - کاهش توهّمات: تنظیم دقیق شبیه‌ساز کاربر آگاه از دامنه بر داده‌های خاص هر دامنه به کاهش توهّمات کمک می‌کند و پاسخ‌های مرتبط‌تر و با دقت بیشتری را تولید می‌کند.
 - تشخیص خطا: شبیه‌ساز کاربر آگاه از دامنه برای شناسایی خطاهای رایج در سیستم‌های گفتگوی وظیفه‌گرا طراحی شده است، که این امر باعث بهبود دقت و عملکرد سیستم می‌شود.
- شبیه‌ساز کاربر آگاه از دامنه با استفاده از دو معیار معتبر در ارزیابی سیستم‌های گفتگوی وظیفه‌گرا مورد آزمایش قرار گرفته است. نتایج نشان می‌دهند که تنظیم دقیق مدل‌های زبانی بزرگ بر روی داده‌های خاص دامنه‌ای، انسجام بیشتری با اهداف کاربران فراهم می‌کند و توهّمات را کاهش می‌دهد.
- دستاوردهای کلیدی ارزیابی شامل موارد زیر است:
- بهبود تحقق اهداف کاربر: شبیه‌ساز کاربر آگاه از دامنه منجر به تعاملات موفق‌تری شد که در آن کاربران شبیه‌سازی شده به اهداف تعیین‌شده خود رسیدند.
 - کاهش توهّمات: مدل‌های زبانی بزرگ تنظیم شده کمتر مستعد تولید پاسخ‌های نامرتب و نامنسجم بود.
 - تنوع واژگانی: شبیه‌ساز کاربر آگاه از دامنه با ارائه تنوع زبانی در دیالوگ‌های شبیه‌سازی شده، اما در مقایسه با روش‌های یادگیری درون‌زمینه‌ای، کمی تنوع کمتری دارد.
- از مزایای این سیستم می‌توان به انطباق ویژه دامنه اشاره کرد. تنظیم دقیق بر روی داده‌های دامنه‌محور، مکالمات منسجم‌تر و مرتبط‌تری را تولید می‌کند. همچنین تمرکز شبیه‌ساز کاربر آگاه از دامنه بر انسجام مکالمات باعث کاهش توهّمات می‌شود و پاسخ‌های قابل اعتمادتر و دقیق‌تری ارائه می‌دهد. شبیه‌ساز کاربر آگاه از دامنه نیازی به دسترسی به عملکرد داخلی یا سیاست‌های سیستم ندارد، که آن را به یک راه‌حل منعطف تبدیل می‌کند. این شبیه‌ساز قادر به تشخیص خطاهای رایج در سیستم‌های گفتگوی وظیفه‌گرا است و به بهبود عملکرد کلی سیستم کمک می‌کند.
- از معایب سیستم [۲۳] می‌توان به پیچیدگی محاسباتی اشاره کرد. تنظیم دقیق مدل‌های زبان بزرگ به قدرت محاسباتی زیادی نیاز دارد و ممکن است هزینه‌بر باشد. همچنین تنوع واژگانی محدود از دیگر

نقاط ضعف آن است. اگرچه شبیه‌ساز کاربر آگاه از دامنه تنوع زبانی را فراهم می‌کند، اما در مقایسه با روش‌های یادگیری درون‌زمینه‌ای، تنوع کمتری دارد. شبیه‌ساز کاربر آگاه از دامنه بر اهداف وظیفه‌محور متمرکز است و از نمایه‌سازی کاربر یا شخصی‌سازی استفاده نمی‌کند.

در مقایسه با روش ارائه‌شده در این رساله که بر شخصی‌سازی، نمایه‌سازی کاربر و حل مشکل شروع سرد تأکید دارد، تمرکز [۲۳] شبیه‌ساز کاربر آگاه از دامنه بر کاهش توهمات و شبیه‌سازی وظیفه‌محور است. در حالی که هر دو از مدل‌های زبانی بزرگ استفاده می‌کنند، شبیه‌ساز کاربر آگاه از دامنه بر تنظیم دقیق دامنه‌محور تمرکز دارد، در حالی که روش رساله فوق بر تنظیم سریع و استفاده از یادگیری چندشات برای افزایش انطباق سیستم بدون نیاز به تنظیم دقیق گسترده تأکید دارد.

۳.۳.۲ پروفایل کاربری

۱.۳.۳.۲ تکنیک‌های پروفایل صریح و ضمنی

پروفایل صریح به اطلاعاتی اشاره دارد که به‌صورت واضح و مستقیم از کاربران جمع‌آوری می‌شود. این اطلاعات معمولاً شامل وابستگی‌ها، علایق و نیازهای کاربر است که به‌طور مستقیم از طریق پرسشنامه‌ها، نظرسنجی‌ها یا تنظیمات حساب کاربری به‌دست می‌آید. اطلاعات به‌دست آمده، مستقیماً مربوط به خواسته‌ها و نظرات کاربر است لذا به آسانی قابل اندازه‌گیری هستند [۱۴].

پروفایل ضمنی به اطلاعاتی اشاره دارد که به‌طور غیرمستقیم از رفتارها و فعالیت‌های کاربران در پلتفرم‌ها جمع‌آوری می‌شود. این اطلاعات از مرور رفتار کاربر، کلیک‌ها و تعاملات او به‌دست می‌آید. این داده‌ها از طریق رفتار کاربری مانند تاریخچه جستجو و خریدها جمع‌آوری می‌شود [۱۴].

بوکلش و همکاران [۲]، یک رویکرد مبتنی بر یادگیری ماشینی برای پروفایل کاربر را با تجزیه و تحلیل داده‌های رسانه‌های اجتماعی آنلاین برای شناسایی اولویت‌ها، جزئیات جمعیت‌شناختی و رفتارهای کاربران بررسی می‌کند. ایده اولیه این پژوهش مدلی است که از تکنیک‌های رگرسیون برای استخراج پروفایل‌های کاربر بر اساس سن، جنسیت و سایر ویژگی‌ها و پیش‌بینی معیارهای تعامل، مانند تعداد لایک‌های پست، بر اساس فعالیت کاربر در پلتفرم‌های رسانه‌های اجتماعی مانند فیس‌بوک استفاده می‌کند. این مدل با تجزیه و تحلیل داده‌های صریح (سن، جنسیت) و ضمنی (پست‌ها، لایک‌ها، اشتراک‌گذاری‌ها) به ایجاد بینش کاربر کمک می‌کند.

پروفایل‌سازی کاربر که بر اساس تجزیه و تحلیل رسانه‌های اجتماعی انجام می‌شود، چالش‌هایی را در مدیریت و تحلیل مؤثر داده‌های گسترده و بدون ساختار این پلتفرم‌ها به همراه دارد. با افزایش حجم اطلاعات تولید شده توسط کاربران، پیش‌پردازش داده‌ها و شناسایی الگوهای رفتاری کاربران برای ایجاد پروفایل‌های دقیق،

به‌ویژه در زمینه‌هایی مانند سیستم‌های توصیه‌گر و بازاریابی هدفمند، ضروری است. در این مدل، استفاده از تکنیک‌های رگرسیون برای تحلیل روابط میان داده‌های جمعیت‌شناختی و رفتارهای اجتماعی کاربر (مانند لایک کردن یا اشتراک‌گذاری) به منظور پیش‌بینی معیارهای تعامل و همچنین ایجاد پروفایل‌های شخصی به کار گرفته می‌شود.

سهم اصلی [۲] توسعه یک مدل یادگیری ماشینی برای پروفایل کردن کاربران بر اساس فعالیت‌های رسانه‌های اجتماعی آن‌ها است که در درجه اول بر داده‌های فیس‌بوک تمرکز دارد. با استفاده از تجزیه و تحلیل داده‌های رسانه‌های اجتماعی، هدف نویسندگان پیش‌بینی تعامل و ترجیحات کاربر، پرداختن به چالش استخراج بینش ارزشمند از داده‌های گسترده، پویا و بدون ساختار در شبکه‌های اجتماعی است. این وظیفه در زمینه‌هایی مانند سیستم‌های توصیه‌کننده، بازاریابی هدفمند و تجزیه و تحلیل احساسات مرکزی است. چالش در مدیریت و تجزیه و تحلیل موثر داده‌ها در دسته‌های مختلف، زیرمجموعه‌ها و تعاملات کاربر، مانند پست‌ها، لایک‌ها و اشتراک‌گذاری‌ها در مقیاس بزرگ است. با توجه به حجم و تنوع داده‌های اجتماعی، پیش‌پردازش و شناسایی نمایش‌های دقیق کاربر بر اساس داده‌های صریح (مانند سن، جنسیت) و داده‌های ضمنی (مانند رفتار کاربر) برای استخراج نمایه‌های دقیق و جامع کاربر حیاتی است.

رویکرد پیشنهادی شامل استفاده از یک مدل رگرسیون به عنوان یک ابزار پیش‌بینی است که رفتار کاربران را بر اساس سن، جنسیت و سایر عوامل جمعیت‌شناختی ارزیابی می‌کند. داده‌های فیس‌بوک، به‌ویژه تعاملات کاربر (لایک کردن، اشتراک‌گذاری، نظر دادن)، برای ایجاد یک مدل نمایه کاربر استفاده شد. این مطالعه از تجزیه و تحلیل داده‌های اکتشافی و تکنیک‌های رگرسیون استفاده می‌کند و یک رگرسیون تولید می‌کند که معیارهای تعامل مانند تعداد لایک‌هایی که ممکن است پست‌های کاربر دریافت کند را پیش‌بینی می‌کند. این مدل با استفاده از خطای آر-اسکورد^۱ برای تعیین دقت و اثربخشی پیش‌بینی آن ارزیابی می‌شود.

عملکرد پیش‌بینی مدل با استفاده از معیار خطای آر-اسکورد سنجیده شده است و نتیجه نرخ خطای ۰.۱۹۹ به دست آمد. این عدد نشان می‌دهد که مدل تا حدی قابل قبول عمل کرده است، اما همچنان جای پیشرفت وجود دارد. بررسی نتایج نشان می‌دهد که استفاده از پروفایل‌های مبتنی بر رگرسیون می‌تواند بینش‌های مفیدی درباره الگوهای رفتار کاربران از طریق داده‌های موجود در فعالیت‌های رسانه‌های اجتماعی ارائه دهد. به بیان ساده‌تر، این مدل می‌تواند به ما کمک کند الگوها و رفتارهای کلی کاربران را بهتر درک کنیم.

اما در این مسیر، چالش‌هایی نیز وجود دارد. به عنوان مثال، درک دقیق احساسات کاربران یا تشخیص سطوح ظریف تعامل آن‌ها کار ساده‌ای نیست. این نوع الگوها اغلب پیچیده‌تر هستند و نیازمند رویکردهای پیشرفته‌تری برای تحلیل دقیق‌تر هستند [۲]. بنابراین، هرچند مدل فعلی می‌تواند نقطه شروع خوبی باشد، اما برای رسیدن به

¹R-squared

دقت بالاتر، توسعه روش‌های جدید و بهینه‌سازی بیشتر ضروری به نظر می‌رسد.

مزایای [۲] به شرح زیر است.

- کارایی در تولید پروفایل: این مدل می‌تواند به سرعت پروفایل‌هایی را بر اساس داده‌های اولیه جمعیت‌شناختی و رفتاری ایجاد کند و از وظایفی مانند بازاریابی هدفمند و تحلیل احساسات پشتیبانی کند.
- قابلیت اجرا در سراسر دامنه‌ها: پروفایل کاربری از طریق این مدل کاربردهای بالقوه‌ای در زمینه‌های مختلف دارد، مانند نظارت بر سلامت روان، بازاریابی شخصی و تجزیه و تحلیل رفتار مجرمانه.
- پروفایل صریح و ضمنی: این رویکرد داده‌های جمعیتی صریح را با بینش‌های مبتنی بر رفتار ضمنی ترکیب می‌کند، که اجازه می‌دهد تا نمایه کاربر دقیق‌تری داشته باشد.

از معایب این روش می‌توان به موارد زیر اشاره کرد.

- پیچیدگی محدود: اتکای مدل به رگرسیون ساده ممکن است ظرفیت آن را برای ثبت روندهای رفتاری متفاوت، به ویژه در تطبیق داده بالا، محدود کند.
- وابستگی به داده‌های رسانه‌های اجتماعی: این مدل به شدت به دقت و در دسترس بودن داده‌های رسانه‌های اجتماعی متکی است، که ممکن است همیشه برای نمایه‌سازی جامع قابل اعتماد یا کافی نباشد.

در مقایسه با [۲]، تحقیقات پژوهش فوق بر توسعه یک سیستم گفتگوی شخصی متمرکز است که از پروفایل کاربر برای توصیه‌ها و تعاملات متناسب استفاده می‌کند. مولفه پروفایل کاربری همچنین شامل نمایه‌سازی ضمنی و صریح است، اما فراتر از داده‌های جمعیت‌شناختی ثابت است و شامل تجزیه و تحلیل احساسات پویا و روش‌های فیلتر مشارکتی، مانند فیلتر مشارکتی مبتنی بر آیتم می‌شود. علاوه بر این، سیستم فوق بر حل مشکل شروع سرد با ایجاد نمایه‌های کاربر اولیه بر اساس داده‌های تعامل محدود و ارائه یک تجربه شخصی از طریق تنظیم سریع با کمک یک مدل زبان بزرگ تأکید می‌کند.

در حالی که هر دو رویکرد از نمایه‌سازی استفاده می‌کنند، روش پیشنهادی رساله فوق با ادغام اصل حق فراموشی فراتر می‌رود و به کاربران اجازه می‌دهد تا درخواست حذف داده‌های خود را از سیستم کنند. این با مقررات حفظ حریم خصوصی مطابقت دارد، که به طور مستقیم در مدل پروفایل کاربری از تجزیه و تحلیل رسانه‌های اجتماعی به آن پرداخته نمی‌شود. علاوه بر این، تحقیق فوق به جای تکیه بر پیش‌بینی‌های مبتنی بر رگرسیون، از تنظیم دقیق و یادگیری چند شات برای بهبود سازگاری مدل و مدیریت تعاملات شخصی در یک محیط گفتگوی وظیفه‌محور استفاده می‌کند.

به طور خلاصه، در حالی که نمایه‌سازی کاربر از طریق تجزیه و تحلیل رسانه‌های اجتماعی بینش‌های ارزشمندی را در مورد نمایه‌سازی اولیه کاربر از داده‌های اجتماعی ارائه می‌دهد، هدف تحقیق فوق‌گسترش این قابلیت‌ها با شخصی‌سازی پیچیده، رعایت حریم خصوصی، و تعاملات سازگار با کاربر با استفاده از تکنیک‌های پیشرفته یادگیری ماشینی است.

نگ و همکاران [۱۹]، به بررسی چگونگی تحلیل و ایجاد پروفایل کاربران از داده‌های متنی چندزبانه که در رسانه‌های اجتماعی منتشر می‌شوند، می‌پردازد. هدف اصلی این مطالعه، توسعه مدلی برای تحلیل و پروفایل‌سازی کاربران بر اساس زبان‌ها و موضوعات مختلفی است که در این پلتفرم‌ها استفاده می‌شود. روش پیشنهادی با بهره‌گیری از تکنیک‌های مختلف پردازش زبان طبیعی و استفاده از منابع دانش‌بنیان همچون وردنت^۱، تلاش می‌کند که احساسات و موضوعات پنهان در پس متون چندزبانه را شناسایی و تحلیل کند.

مشکل اصلی در [۱۹]، تحلیل و شناسایی احساسات و موضوعات مرتبط با متن‌های چندزبانه است. کاربران در پلتفرم‌های اجتماعی از زبان‌های مختلفی برای ابراز نظرات خود استفاده می‌کنند، که تحلیل این متن‌ها و شناسایی اطلاعات مرتبط را برای ماشین‌ها به چالش می‌کشد. چالش دیگر، دسترسی به منابع و پایگاه‌های داده مرتبط و آماده‌سازی آن‌ها برای استفاده در مدل یادگیری ماشین است. رویکرد پیشنهادی شامل سه مرحله اصلی است:

۱. تشخیص زبان: در مرحله اول، زبان هر کلمه با استفاده از مقایسه یونیکد^۲ و فهرستی از زبان‌های مختلف شناسایی می‌شود. سپس کل متن به زبان هدف (در این آزمایش، انگلیسی) ترجمه می‌شود.

۲. تحلیل احساسات: در این مرحله، با استفاده از مجموعه داده‌ای شامل کلمات با بار معنایی مثبت و منفی، احساسات متن شناسایی می‌شود. این مجموعه داده شامل ۴۰۰۰ کلمه مثبت و ۴۰۰۰ کلمه منفی از پایگاه داده کگل^۳ جمع‌آوری شده است.

۳. شناسایی موضوع: در مرحله نهایی، موضوع متن با استفاده از آرشیو روزنامه و وردنت شناسایی می‌شود. این آرشیو با استفاده از منابع آنلاین و سلسله‌مراتب واژگان وردنت ایجاد می‌شود که به شناسایی کلمات مرتبط با موضوعات مختلف تا سطح سوم کمک می‌کند.

این مدل بر روی ۲۰۰ پیام در ده زبان مختلف آزمایش شده است. نتایج نشان داد که مدل پیشنهادی با دقت قابل قبولی می‌تواند احساسات و موضوعات متون را در زبان‌های مختلف شناسایی کند. هرچند، چالش‌هایی همچون

^۱WordNet

^۲UNICODE

^۳Kaggle - <https://www.kaggle.com/>

پیچیدگی ترجمه‌های چندزبانه و نیاز به داده‌های آموزشی بیشتر برای بهبود عملکرد مدل نیز ذکر شده‌است.

این مدل می‌تواند احساسات و موضوعات را در چندین زبان تحلیل کند که آن را برای پروفایل‌سازی کاربران در محیط‌های چندزبانه مناسب می‌سازد. همچنین این مدل با استفاده از وردنت و آرشیو روزنامه‌ها و استفاده از منابع دانش بنیان برای استخراج موضوعات متن، به بهبود تحلیل کمک می‌کند. از معایت این روش نیاز باید به پردازش و پیش‌پردازش پیچیده اشاره کرد. فرآیند پیش‌پردازش داده‌ها و ترجمه متون چندزبانه نیازمند زمان و منابع است. همچنین ترجمه اتوماتیک به زبان هدف (انگلیسی) ممکن است معانی دقیق را در برخی از متون از دست بدهد که دقت تحلیل را تحت تاثیر قرار می‌دهد. در مقایسه با پژوهش این رساله، [۱۹] تمرکز بیشتری بر پروفایل‌سازی بر اساس داده‌های چندزبانه دارد و از منابع خارجی همچون وردنت و داده‌های خبری برای شناسایی موضوعات استفاده می‌کند. در تحقیق این رساله، پروفایل‌سازی کاربر فراتر از اطلاعات صریح و احساسات متنی کاربران است و با استفاده از تحلیل احساسات و فیلترسازی مشارکتی، نمایه‌سازی دقیق‌تر و شخصی‌سازی شده‌ای از کاربران برای تعاملات گفتگو محور ارائه می‌شود.

۲.۳.۳.۲ تحلیل احساسات و فیلتر کردن مبتنی بر آیتم

تحلیل احساسات و فیلتر کردن مبتنی بر آیتم دو تکنیک مهم در سیستم‌های توصیه‌گر و پروفایل‌سازی کاربر هستند که به کمک آن‌ها می‌توان به طور مؤثری به پیش‌بینی تعاملات کاربران و ارائه پیشنهادها مناسب پرداخت. تحلیل احساسات فرآیندی است که به شناسایی و استخراج احساسات و نظرات کاربران از متون می‌پردازد. این متون می‌توانند شامل نظرات، نقدها، توییت‌ها و دیگر اشکال ارتباطی باشند. همچنین فیلتر کردن مبتنی بر آیتم یک روش برای پیشنهاد دادن آیتم‌ها به کاربران بر اساس تعاملات قبلی آن‌ها با آیتم‌های مشابه است. پترسون و همکاران [۲۱]، یک رویکرد متمرکز بر افزایش روش‌های پروفایل کاربر برای بهبود توصیه‌ها در سیستم‌های توصیه‌گر ارائه می‌کند. این بر اهمیت پروفایل‌های پویا و دقیق کاربر در مقابله با اضافه بار اطلاعات تاکید می‌کند، چالشی رو به رشد زیرا پلتفرم‌های بیشتری حجم زیادی از محتوا را ارائه می‌دهند. این پژوهش دوروش کلیدی پروفایل را بررسی می‌کند: یک چارچوب پروفایل کاربری سلسله مراتبی و یک رویکرد پروفایل کاربر مبتنی بر برجسب که از نظریه بازی برای متعادل کردن ویژگی‌ها در نمایش پروفایل استفاده می‌کند. سهم اصلی [۲۱]، بررسی رویکردهای نوآورانه پروفایل کاربر در سیستم‌های توصیه‌گر برای بهبود دقت توصیه است. پروفایل کاربری برای سیستم‌های توصیه‌گر برای ایجاد توصیه‌های مرتبط که تجربه کاربر را غنی می‌کند و اضافه بار اطلاعات را کاهش می‌دهد بسیار مهم است. این کار در درجه اول به چالش ایجاد نمایه‌های کاربری قوی می‌پردازد که به طور دقیق علایق کاربر را در سطوح چندگانه منعکس می‌کند، و سیستم‌های توصیه‌گر را قادر

می‌سازد تا محتوای متناسب و مرتبط را به طور کارآمد ارائه دهند.

مشکل بر روی ساختن پروفایل‌هایی متمرکز است که نه تنها علایق کاربر را به طور دقیق منعکس می‌کند، بلکه به صورت پویا با تغییرات رفتار کاربر تنظیم می‌شود. سیستم‌های توصیه‌گر سنتی اغلب با ایجاد پروفایل‌هایی که جزئیات و کلیات را متعادل می‌کند، مشکل دارند و بر ظرفیت آنها برای ارائه توصیه‌های مناسب تأثیر می‌گذارد. تمرکز این پژوهش بر چارچوب‌های پروفایل سلسله‌مراتبی و مبتنی بر برجسب، بینش‌هایی را برای دستیابی به این تعادل ارائه می‌دهد.

پترسون و همکاران در [۲۱] دوروش اصلی برای پروفایل کاربری را بررسی می‌کنند:

- چارچوب پروفایل کاربری سلسله‌مراتبی: این رویکرد نشان‌دهنده علایق کاربر در سطوح مختلف جزئیات است. این یک ساختار لایه‌ای برای علایق کاربر ایجاد می‌کند و به سیستم‌های توصیه‌گر اجازه می‌دهد اولویت‌های کاربر را از دسته‌های گسترده تا موارد خاص درک کند. این چارچوب انعطاف‌پذیری را افزایش می‌دهد و سیستم را قادر می‌سازد تا توصیه‌هایی را در دسته‌های مختلف و جزئیات ارائه دهد.

- پروفایل کاربری مبتنی بر برجسب با استفاده از تئوری بازی: در این روش، تئوری بازی برای مدیریت مبادله بین ویژگی و عمومیت در پروفایل‌های کاربر استفاده می‌شود. برجسب‌های مرتبط با تعاملات کاربر وزن می‌شوند تا ارتباط آنها را منعکس کنند، بنابراین نمایه را اصلاح می‌کنند. تئوری بازی برای بهینه‌سازی این فرآیند استفاده می‌شود و اطمینان حاصل می‌کند که پروفایل‌ها نه خیلی وسیع و نه بیش از حد جزئی هستند و به توصیه‌های کارآمد و دقیق اجازه می‌دهند.

پترسون و همکاران [۲۱] اثربخشی این روش‌ها را با تجزیه و تحلیل توانایی آنها در بهبود دقت توصیه‌ها و رضایت کاربر ارزیابی می‌کند. چارچوب سلسله‌مراتبی نشان داده شده است که انعطاف‌پذیری در سیستم‌های توصیه‌گر را فراهم می‌کند و با زمینه‌های مختلف توصیه‌سازگار می‌شود. در همین حال، تکنیک پروفایل‌سازی مبتنی بر برجسب دقت بهبود یافته‌ای را در تطبیق علایق کاربر با موارد موجود نشان می‌دهد. هر دو رویکرد در نهایت به یک فرآیند توصیه اصلاح‌شده کمک می‌کنند، و به طور موثر به مسئله اضافه بار اطلاعات رسیدگی می‌کنند.

از جوانب مثبت [۲۱] باید به انعطاف‌پذیری و دقت این روش اشاره کرد. ساختار سلسله‌مراتبی اجازه می‌دهد تا توصیه‌هایی در سطوح مختلف دانه‌بندی ارائه شود و سازگاری با نیازهای کاربر بهبود یابد. همچنین روش پروفایل‌سازی مبتنی بر نظریه بازی تضمین می‌کند که پروفایل‌ها نه بیش از حد عمومی هستند و نه خیلی خاص، که منجر به توصیه‌های مرتبط‌تر می‌شود. هر دو رویکرد به سیستم‌های توصیه‌گر اجازه می‌دهند تا به علایق کاربر در حال تکامل پاسخ دهند و پروفایل‌ها را به‌روز و موثر نگه دارند.

از معایب [۲۱] می‌توان به پیچیدگی پیاده‌سازی آن اشاره کرد. توسعه یک چارچوب سلسله‌مراتبی چند سطحی و اجرای نظریه بازی برای وزن‌دهی برجسب می‌تواند از نظر محاسباتی پیچیده باشد. همچنین پتانسیل

ایجاد نویز در برچسب‌ها زیاد است. روش مبتنی بر برچسب به ارتباط دقیق برچسب متکی است و تگ‌های پرسروصدا یا نامربوط می‌توانند بر دقت پروفایل تأثیر بگذارند.

در مقایسه با تمرکز تحقیقاتی فعلی، که شامل پروفایل کاربری در سیستم‌های گفتگو می‌شود، رویکرد پترسون و همکاران بیشتر بر روی سیستم‌های توصیه‌گر برای مدیریت اضافه بار اطلاعات متمرکز است. در حالی که تحقیقات موجود بر شخصی‌سازی و نمایه‌سازی کاربر نیز تأکید می‌کند، تکنیک‌های اضافی مانند فیلترکردن مشارکتی و تجزیه و تحلیل احساسات را که به‌ویژه برای سیستم‌های گفتگو طراحی شده است، در خود جای داده است.

در تحقیقات سیستم گفتگو، شخصی‌سازی نه تنها از طریق نمایه‌سازی، بلکه از طریق تولید پاسخ پویا بر اساس تاریخچه تعامل کاربر و بازخورد ضمنی حاصل می‌شود که در پژوهش متمرکز بر سیستم‌های توصیه‌گر کمتر بر آن تأکید شده است. علاوه بر این، سیستم گفتگو حق فراموش شدن را در اولویت قرار می‌دهد و به حفظ حریم خصوصی و حفظ داده‌ها می‌پردازد - حوزه‌هایی که در این پژوهش پوشش داده نمی‌شوند. به طور خلاصه، روش‌های نمایه‌سازی در [۲۱]، دقت توصیه‌ها و تجربه کاربر را با تأکید بر نمایش منافع چند سطحی و تعادل بهینه در استفاده از برچسب، افزایش می‌دهد. در مقابل، تحقیق فعلی بر ادغام پروفایل کاربر با شخصی‌سازی گفتگوی بلادرنگ تمرکز دارد و شامل یک چارچوب قوی برای حفظ حریم خصوصی داده‌ها است که آن را به یک رویکرد جامع‌تر برای سیستم‌های تعامل کاربر محور تبدیل می‌کند.

۳.۳.۳.۲ تکنیک‌های پروفایل‌سازی کاربر برای افزایش حریم خصوصی

ژنگ و همکاران [۲۹] به بررسی و تحلیل مفهوم حق فراموشی در زمینه مدل‌های زبانی بزرگ پرداخته است. حق فراموشی به عنوان یکی از مفاد مهم حفاظت از داده‌های شخصی، ابتدا در قوانین حریم خصوصی اروپا^۱ تعریف و شناخته شد و سپس با توسعه سریع مدل‌های زبانی بزرگ و کاربردهای آن‌ها در زمینه‌هایی نظیر سیستم‌های گفتگو به چالشی جدید تبدیل شد. برخلاف موتورهای جستجو که بر پایه ایندکس‌سازی و ساختارهای ساده‌تر به ذخیره و بازیابی اطلاعات می‌پردازند، مدل‌های زبانی بزرگ اطلاعات را به روش‌های پیچیده‌تر و در ساختارهای عصبی ذخیره و پردازش می‌کنند که اجرای حق فراموشی در آن‌ها نیازمند راهکارهای فنی پیشرفته است. یکی از چالش‌های اصلی پیاده‌سازی حق فراموشی در مدل‌های زبانی بزرگ به چگونگی حذف کامل و دقیق داده‌های حساس از حافظه مدل‌ها برمی‌گردد. این امر به دلیل ساختار عمیق شبکه‌های عصبی و نحوه ذخیره‌سازی داده‌ها به صورت غیرمستقیم و پیچیده، بسیار دشوار است. به علاوه، به دلیل عدم وجود ساختارهای مشخص و قابل مشاهده برای ذخیره داده‌ها در مدل‌های زبانی بزرگ، فرآیند حذف داده‌ها به صورت جامع‌تر و دقیق‌تری نیاز دارد تا بتواند به سطحی از حریم خصوصی که با قوانین حریم خصوصی اروپا سازگار است، دست یابد.

¹ General Data Protection Regulation (GDPR)

[۲۹] با بررسی چالش‌های فنی حق فراموشی در مدل‌های زبانی بزرگ، چندین راه‌حل بالقوه را پیشنهاد کرده است که به ترتیب زیر خلاصه می‌شوند:

۱. عدم یادگیری ماشین^۱: در این رویکرد، تلاش می‌شود که مدل به شکلی بازآموزی شود که به‌طور خاص هیچ اثری از داده‌های حذف‌شده باقی نماند. این روش به ویژه در شرایطی که کاربر درخواست حذف کامل داده‌ها را دارد، می‌تواند مناسب باشد.

۲. ویرایش مدل^۲: در این روش، پارامترهای مدل به نحوی تغییر داده می‌شوند که داده‌های حساس به‌طور خاص از بین بروند. در ویرایش مدل، هدف این است که مدل به گونه‌ای اصلاح شود که دیگر نیازی به مراجعه به داده‌های حذف‌شده نداشته باشد.

۳. حفاظت از حریم خصوصی تفاضلی^۳: این روش با استفاده از تکنیک‌های آماری و داده‌کاوی، میزان دسترسی به داده‌های حساس را به‌طور قابل توجهی کاهش داده و همزمان عملکرد مدل را حفظ می‌کند. این رویکرد به عنوان راهکاری موثر برای حفاظت از داده‌های کاربر و انطباق با اصول حریم خصوصی شناخته می‌شود.

در [۲۹] تأثیرات استفاده از این رویکردها در عملکرد و دقت مدل‌های زبانی بزرگ ارزیابی شده است. نتایج نشان می‌دهد که ویرایش مدل و عدم یادگیری می‌تواند به کاهش چالش‌های حق فراموشی در مدل‌های زبانی بزرگ کمک کند. به‌علاوه، استفاده از حفاظت از حریم خصوصی تفاضلی به عنوان راهکاری موثر شناخته شده است که به مدل‌ها اجازه می‌دهد داده‌های کاربران را حذف کرده و در عین حال، سازگاری با قوانین حریم خصوصی را حفظ کنند.

مزایا و محدودیت‌های پیاده‌سازی حق فراموشی در مدل‌های زبانی بزرگ به شرح زیر است.

- مزایا: اجرای حق فراموشی در مدل‌های زبانی بزرگ، مزایایی نظیر افزایش حفاظت از حریم خصوصی کاربران و انطباق بیشتر با قوانین حریم خصوصی مانند قوانین حریم خصوصی اروپا را به همراه دارد.
- محدودیت‌ها: از معایب این راهکارها می‌توان به هزینه‌های محاسباتی بالا و کاهش احتمالی کارایی مدل‌ها پس از حذف داده‌ها اشاره کرد.

حق فراموشی در عصر مدل‌های زبانی بزرگ [۲۹]، راه‌حل‌های مناسبی را برای اجرای حق فراموشی در سیستم‌های مبتنی بر مدل زبانی بزرگ ارائه می‌دهد که می‌تواند به حفاظت از حریم خصوصی کاربران کمک کند.

¹Machine Unlearning

²Model Editing

³Differential Privacy

پژوهش حاضر در زمینه سیستم‌های گفتگو وظیفه‌گرا که به حذف داده‌های کاربران و حفظ حریم خصوصی توجه می‌کند، می‌تواند از این تکنیک‌ها بهره‌برد. این روش‌ها به پژوهش شما این امکان را می‌دهند که بدون کاهش کارایی سیستم، امکان حذف داده‌های حساس را فراهم کند و به اصول حریم خصوصی پایبند بماند. در جدول ۱۰۲ مقایسه جامعی بین مقالات بررسی‌شده و روش ارائه‌شده در پژوهش حاضر آورده شده‌است.

جدول ۱۰۲: مقایسه پژوهش‌های انجام‌شده

پژوهش	سیستم گفتگوی وظیفه‌گرا	شخصی‌سازی	شرح‌سرد	پروفایل کاربری	استفاده از مدل زبانی	تنظیم سریع	تنظیم دقیق	حق فراموشی	یادگیری چند شات	یادگیری بدون شات
Bocklisch, ۲۰۲۴ [۳]	✓	✗	✗	✗	✓	✗	✗	✗	✓	✓
Chung, ۲۰۲۴ [۶]	✓	✗	✓	✗	✓	✗	✗	✗	✗	✓
Hu, ۲۰۲۴ [۱۳]	✓	✗	✓	✗	✓	✗	✓	✗	✗	✓
Sekuli, ۲۰۲۴ [۲۳]	✓	✗	✗	✗	✓	✗	✓	✗	✗	✓
Samarinas, ۲۰۲۴ [۲۲]	✓	✗	✓	✗	✓	✗	✓	✗	✗	✓
Yu, ۲۰۲۲ [۲۷]	✓	✗	✓	✗	✓	✗	✗	✗	✗	✓
Kasahara, ۲۰۲۲ [۱۵]	✗	✓	✗	✓	✓	✓	✗	✗	✓	✗
Madotto, ۲۰۲۱ [۱۷]	✗	✓	✓	✗	✓	✓	✗	✗	✓	✗
Zhang, ۲۰۲۴ [۲۹]	✗	✓	✓	✓	✗	✗	✗	✗	✗	✗
Nag, ۲۰۲۳ [۱۹]	✗	✓	✗	✓	✗	✗	✗	✗	✗	✗
Peterson, ۲۰۲۱ [۲۱]	✗	✓	✗	✓	✗	✗	✗	✗	✗	✗
تحقیق فوق	✓	✓	✓	✓	✓	✓	✗	✓	✓	✗

۴.۲ جمع‌بندی

در این فصل، تلاش شد تا مروری جامع بر مفاهیم، پژوهش‌ها، و تکنیک‌های مرتبط با موضوع رساله فوق ارائه شود. ابتدا، در بخش سیستم‌های گفتگو، بررسی‌ها نشان دادند که سیستم‌های گفتگوی وظیفه‌گرا به دلیل ساختار هدف‌محور خود، کارآمدتر و دقیق‌تر عمل می‌کنند و بیشتر مناسب کاربردهای خاص مانند سیستم‌های رزرواسیون و سیستم‌های پیشنهاددهنده هستند. از سوی دیگر، سیستم‌های گفتگوی دامنه‌باز به دلیل انعطاف‌پذیری در

موضوعات گسترده، مناسب تعاملات آزادتر با کاربران می‌باشند، اما همچنان در مدیریت انسجام و دقت چالش‌هایی دارند.

در بخش تنظیم سریع، روش‌های جدیدی مانند یادگیری چند شات و استفاده از پرامپت‌های هوشمند معرفی شدند که بدون نیاز به تنظیم دقیق گسترده، توانسته‌اند عملکرد سیستم‌ها را در شرایط محدود داده ارتقاء دهند. این تکنیک‌ها، علاوه بر کاهش هزینه‌های محاسباتی، امکان بهره‌برداری از مدل‌های زبانی بزرگ را برای توسعه‌دهندگان با منابع محدود فراهم می‌کنند.

در حوزه پروفایل‌سازی کاربر، سه دسته اصلی از تکنیک‌ها تحلیل شدند: پروفایل صریح و ضمنی: ترکیب داده‌های صریح (مانند سن یا علایق شخصی) و داده‌های ضمنی (مانند رفتار کاربران) به‌عنوان یک راهکار جامع برای درک ترجیحات کاربران پیشنهاد شد. تحلیل احساسات و فیلتر کردن مبتنی بر آیتم: این روش‌ها نشان دادند که تحلیل الگوهای رفتاری و احساسی کاربران می‌تواند به توصیه‌های دقیق‌تر و شخصی‌تر منجر شود.

تکنیک‌های پروفایل‌سازی با تمرکز بر حریم خصوصی: به دلیل اهمیت روزافزون حریم خصوصی، روش‌هایی که کاربران را قادر به مدیریت داده‌های شخصی خود کنند، به‌عنوان راهکاری اساسی مورد توجه قرار گرفتند.

این فصل علاوه بر مرور پژوهش‌های پیشین، شکاف‌های موجود را نیز شناسایی کرد. برای مثال، چالش‌هایی مانند عدم انسجام در گفتگوی دامنه‌باز، هزینه‌های بالای تنظیم دقیق مدل‌ها، و عدم رعایت کامل حریم خصوصی در برخی تکنیک‌های پروفایل‌سازی، فرصت‌های تحقیقاتی جدیدی را برجسته می‌کنند.

با تحلیل جامع این پژوهش‌ها، روشن شد که برای توسعه سیستم‌های گفتگو مدرن و کارآمد، نیاز به ترکیبی از تکنیک‌های بهینه‌سازی (مانند تنظیم سریع)، بهره‌گیری از مدل‌های زبانی بزرگ، و تأکید بر حریم خصوصی کاربران وجود دارد. این فصل نه تنها بستری علمی برای ادامه تحقیق فراهم کرد، بلکه ابزارهایی را برای طراحی نوآوری‌های عملی در حوزه سیستم‌های گفتگو و پروفایل‌سازی کاربر ارائه داد.

فصل ۳

روش پیشنهادی

۱.۳ مقدمه

در این فصل، روش پیشنهادی مورد استفاده برای توسعه و ارزیابی سیستم گفتگوی وظیفه‌گرا با رویکرد شخصی‌سازی مورد بررسی قرار می‌گیرد. این روش شامل طراحی معماری سیستم با تمرکز بر حل چالش‌های اساسی نظیر مشکل شروع سرد، شخصی‌سازی مبتنی بر نمایه کاربر، بهره‌گیری از مدل‌های زبانی بزرگ، و تضمین حق فراموشی است. همچنین به مراحل پیش‌پردازش داده‌ها، استفاده از تکنیک‌های تنظیم سریع و استخراج موجودیت‌های کلیدی از ورودی کاربران پرداخته می‌شود. در نهایت، مکانیزم‌های جمع‌آوری بازخورد و ارزیابی عملکرد سیستم توضیح داده خواهند شد تا نقش آن‌ها در بهبود پویای سیستم مشخص شود.

نام روش پیشنهادی فوق MindMeld است. MindMeld در واقع ادغام هوشیارانه ذهن و ماشین برای گفتگوهای شخصی‌سازی شده است.

ادغام هوشیارانه در واقع بیانگر ترکیب دقیق و هدفمند داده‌ها و الگوریتم‌هاست. ذهن و ماشین نشان‌دهنده تعامل بین کاربر (ذهن) و سیستم هوش مصنوعی (ماشین) است که در قلب رویکرد فوق قرار دارد. همچنین گفتگوهای شخصی‌سازی شده به هدف اصلی که پاسخ‌های سفارشی شده و منطبق با نیازهای کاربر است.

۲.۳ جمع‌آوری و آماده‌سازی داده‌ها

این بخش به فرآیند آماده‌سازی داده‌ها برای توسعه سیستم گفتگوی وظیفه‌محور را توضیح می‌دهد. هدف این است که داده‌های خام از منابع مختلف، از جمله مجموعه‌داده مووی لنز^۱، به داده‌های گفتگو‌محور تبدیل شوند که مناسب برای انجام تنظیم سریع یا یادگیری درون‌متنی^۲ هستند.

۱. انتخاب و بررسی مجموعه‌داده مووی لنز

برای تحلیل اولیه و ایجاد مجموعه‌داده مکالمه‌محور، از مجموعه داده مووی لنز ۲۵ میلیون استفاده شده است. این مجموعه داده به طور گسترده در حوزه‌های مختلف از جمله سیستم‌های توصیه‌گر و فیلتر مشارکتی استفاده می‌شود. منبع این مجموعه داده سایت کگل است که حاوی بیش از ۲۵ میلیون رتبه‌بندی، ۱ میلیون برنامه برچسب و ابرداده برای ۶۲۰۰۰ فیلم است. همچنین این مجموعه داده بیش از ۲۰ میلیون رتبه‌بندی فیلم و برچسب گذاری‌های کاربران است که از سال ۱۹۹۵ جمع‌آوری کرده است.

ویژگی‌های کلیدی این مجموعه داده به شرح زیر است.

- امتیازات کاربران: داده‌های صریح شامل رتبه‌بندی کاربران برای فیلم‌ها (۱ تا ۵ ستاره).
- تگ‌ها: عبارات یا کلمات کلیدی مرتبط با فیلم که توسط کاربران اعمال می‌شوند.
- ژانرها: دسته‌بندی‌های فیلم، از جمله ژانرهای اکشن، کمدی، درام و غیره.
- اطلاعات زمانی: مهر زمانی مربوط به تعاملات کاربران با فیلم‌ها.

در این پژوهش، از دیتاست مووی لنز به عنوان یک مثال کاربردی استفاده شده است. همانطور که ذکر شد، این دیتاست شامل اطلاعات مربوط به علایق کاربران در حوزه فیلم‌ها و امتیازدهی به آن‌ها است. با این حال، روش پیشنهادی این پژوهش تنها محدود به این حوزه نیست و می‌تواند برای دیتاست‌های دیگر در حوزه‌های مختلف مانند موسیقی، کتاب، محصولات خرید آنلاین، یا حتی خدمات آموزشی تطبیق داده شود. این انعطاف‌پذیری به دلیل طراحی عمومی الگوریتم‌ها و عدم وابستگی به ویژگی‌های خاص دیتاست است.

جزئیات روش پیشنهادی که به طور کامل در بخش ۳.۳ بیان خواهد شد شامل مراحل است که مستقل از نوع داده‌ها عمل می‌کنند.

^۱MovieLens

^۲In-Context Learning

به عنوان مثال، در حوزه فیلم‌ها، داده‌های ورودی شامل امتیازهای کاربران به فیلم‌ها و ژانرهای مورد علاقه آن‌ها است. اما این ورودی‌ها می‌توانند به راحتی با داده‌های دیگری مانند امتیازهای کاربران به آهنگ‌ها یا کتاب‌ها جایگزین شوند. در ادامه، با استفاده از دیتاست مووی لنز، نحوه عملکرد این روش را در قالب یک مثال کاربردی شرح می‌دهیم.

۲. ترکیب و یکپارچه‌سازی مجموعه داده

برای ایجاد یک مجموعه داده منسجم و مناسب سیستم گفتگو نیاز به داده‌هایی داریم که دارای ماهیت مکالمه‌محور باشند یا به بیان دیگر این داده‌ها باید به صورت جفت مقدارهای پرسه و پاسخ باشند تا بتوان مدل زبانی خود را با استفاده از این داده‌ها آموزش داد.

در وهله اول جهت ایجاد یک مجموعه داده متشکل از فیلم‌ها، نظرات و امتیازات کاربران و غیره به صورت یکجا، فایل‌های امتیازات کاربران، تگ‌های آنها که به فیلم‌های مختلف داده‌اند را بر اساس ستون‌های مشترک مانند آیدی فیلم و آیدی کاربران ادغام کرده و یک مجموعه داده شامل ۱۲۶ هزار کورد ایجاد نمودیم.

خروجی نهایی این مجموعه داده شامل ستون‌های زیر است:

- آیدی کاربر: شناسه یکتای هر کاربر.
- آیدی فیلم: شناسه یکتای هر فیلم.
- رتبه‌بندی: امتیاز داده‌شده توسط کاربر.
- تگ‌ها: برچسب‌های کاربران برای هر فیلم.
- ژانرها: دسته‌بندی‌های فیلم.

جدول ۱.۳: نمونه‌ای از داده‌های یکپارچه شده از مجموعه داده مووی لنز

tags	genres	title	rating	movieId	userId
travel time	Adventure، Fantasy	(۱۹۹۵) Jumanji	۳.۵	۲	۱۶۲۹

۳. ایجاد مجموعه داده پیام‌های مکالمه‌محور:

برای آماده‌سازی مجموعه داده به فرم پرسش و پاسخ‌های گفتگو محور مراحل زیر انجام شد:

• محاسبه شباهت کسینوسی:

- تگ‌های فیلم‌ها به صورت ماتریس برداری با استفاده از CountVectorizer تبدیل شدند.
 - شباهت کسینوسی بین بردارهای تگ محاسبه شد تا فیلم‌های مشابه شناسایی شوند.
 - فیلم‌هایی با شباهت بالای ۹۰٪ به عنوان موارد پیشنهادی برای همان فیلم در نظر گرفته شدند.
- فرمت‌دهی داده‌ها به صورت مکالمه‌ای:

از داده‌های شناسایی شده، ساختارهایی با پرسش و پاسخ ایجاد شد.
نمونه پرسش:

Recommend movies similar to Harry Potter and the Philosopher's
Stone

نمونه پاسخ:

"Harry Potter and the Chamber of Secrets" for its Hogwarts sequel,
"The Lord of the Rings: The Fellowship of the Ring" for its fantasy
adventure and "Percy Jackson The Olympians: The Lightning Thief"
for its mythological adventure

۴. محاسبه شباهت کسینوسی: برای شناسایی شباهت بین فیلم‌ها و ایجاد جفت‌های پرسش و پاسخ مناسب، از شباهت کسینوسی استفاده شد. رابطه شباهت کسینوسی برای دو بردار متنی A و B به صورت رابطه‌ی ۱.۳ تعریف می‌شود:

$$\text{شباهت کسینوسی} = \frac{\sum_{i=1}^n A_i \cdot B_i}{\sqrt{\sum_{i=1}^n A_i^2} \cdot \sqrt{\sum_{i=1}^n B_i^2}} \quad (1.3)$$

که در آن مقادیر A_i و B_i مقدار ویژگی i در بردارهای A و B هستند. همچنین مقدار n برابر با تعداد ویژگی‌ها (کلمات کلیدی یا تگ‌های فیلم‌ها در اینجا) هستند.

این رابطه تضمین می‌کند که شباهت بین دو بردار بر اساس جهت آن‌ها و نه اندازه‌شان محاسبه شود. شباهت کسینوسی معمولاً برای داده‌های متنی و برداری در تحلیل‌های پردازش زبان طبیعی و مدل‌های توصیه‌گر به کار می‌رود.

روش پیاده‌سازی این رابطه به صورت فوق است:

- تبدیل تگ‌ها به بردارها: با استفاده از تکنیک CountVectorizer، تگ‌های متنی مربوط به فیلم‌ها به بردارهای عددی تبدیل شدند. این تکنیک بسته کلمات^۱ برای نمایه‌سازی متنی استفاده می‌شود.
- محاسبه شباهت: شباهت کسینوسی بین بردارهای مربوط به فیلم‌ها محاسبه شد. همانطور که بیان شد، فیلم‌هایی که شباهت آن‌ها بیش از ۹۰٪ بود، به عنوان فیلم‌های مشابه در نظر گرفته شدند.

جهانگیر و همکاران [۲۵] با استفاده از تکنیک فوق، الگوریتم‌هایی توسعه داده شده‌اند که از داده‌های مشابه مووی لنز برای شناسایی فیلم‌های مشابه استفاده می‌کنند. برای مثال، با بهینه‌سازی عبارات کلیدی و اضافه کردن وزن به ژانرها، دقت مدل‌ها افزایش یافته است.

۵. گسترش تنوع پرسش و پاسخ:

با استفاده از فیلم مرجع و فیلم‌هایی که شباهت کسینوسی بالایی نسبت به فیلم فوق داشته‌اند، مجموعه‌ای از فیلم‌ها به همراه فیلم‌های مشابه با آن‌ها را در دسترس خواهیم داشت که می‌تواند در ادامه ایجاد مجموعه داده مکالمه‌محور کمک کند.

برای شباهت بیشتر داده‌ها به گفتگوهای روزمره، ۵۰ قالب مختلف برای پرسش و ۵۰ قالب برای پاسخ طراحی شد.

به عنوان مثال فیلم Die Hard را در نظر بگیرید، یک نمونه پرسه به فرم زیر خواهد بود:

Looking for hidden gems like 'Die Hard ۱۹۸۸' in the action genre

برای فیلم‌های با ژانرهای مختلف یکی از ژانرها به تصادف برای ایجاد مجموعه داده استفاده می‌شود. همچنین یک نمونه پاسخ کاندید به صورت زیر خواهد بود:

Finding more action films similar to 'Die Hard ۱۹۸۸.' How about: Hell-

boy ۲۰۰۴

۶. ایجاد مجموعه داده نهایی:

ساختار مجموعه داده نهایی به سبک زیر خواهد بود

- ورودی: شامل سوالات کاربران در قالب طبیعی
- خروجی: لیست فیلم‌های پیشنهادی
- نام فیلم: فیلم ذکر شده در سوال

¹Bag of Words (BoW)

- سال: سال انتشار فیلم

- ژانر: ژانرهای فیلم.

با این روش، مجموعه داده‌ای شامل ۲۱۰ هزار ردیف مکالمه‌ای ایجاد شد که برای مراحل بعدی در توسعه سیستم گفتگوی وظیفه‌محور مورد استفاده قرار گرفت.

۳.۳ معماری سیستم

۱.۳.۳ مراحل تولید پاسخ

این معماری برای تقویت تعامل کاربر با سیستم گفتگو وظیفه‌گرا و با توجه به چالش‌های کلیدی مانند مسائل شروع سرد، شخصی‌سازی، استفاده از مدل‌های بازی تنظیم شده و رعایت حق فراموشی طراحی شده است. هر ماژول و اجزای آن برای بهبود سازگاری سیستم، رضایت کاربر و عملکرد خاص دامنه مورد نظر طراحی شده‌اند. در ادامه کلیت معماری پیاده‌سازی شده توضیح داده شده و در بخش‌های آتی، هر قسمت به صورت مجزا و مفصل تر مورد بحث قرار خواهد گرفت.


جهت سهولت درک توضیحات شکل ۱.۳ شماره‌گذاری در قسمت‌های مختلف آن انجام شده است که در هنگام توضیح هر قسمت، شماره آن نیز رو به رو آن آورده شده است.

۱. لایه ورودی

- ورودی کاربر (بخش ۱): این ماژول نقطه شروع دسترسی کاربر جهت پرسش سوال خود است. در این سیستم گفتگو، پرسه‌های مبتنی بر متن از کاربر پذیرفته می‌شود.
- پیش پردازش (بخش ۲): در مرحله پیش‌پردازش، داده‌های خام تمیز شده و ویژگی‌های ناقص یا نویزی حذف می‌شوند. اولین مرحله از پیش‌پردازش پرسه کاربر، عادی سازی^۱ (بخش ۳) است. در این مرحله سیستم قالب متن ورودی به عنوان مثال، حروف کوچک و علامت‌گذاری را استاندارد می‌کند.
- توکن‌بندی کردن^۲ (بخش ۴): متن به واحدهای قابل مدیریت (کلمات یا عبارات) شکسته می‌شود.

^۱Normalization

^۲Tokenization



شکل ۱.۳: معماری سیستم

- استانداردسازی فرمت^۳ (بخش ۵) که سازگاری با ماژول‌های پردازش مراحل بعدی را تضمین می‌کند.

فرآیندهای مرحله پیش‌پردازش به طور کلی مستقل از حوزه کاربرد است و می‌تواند برای هر نوع داده‌ای اعمال شود. به عنوان مثال، در دیتاست مووی لنز، این شامل حذف رکوردهای ناقص امتیازدهی کاربران به فیلم‌ها می‌شود. اما در یک دیتاست مربوط به خرید آنلاین، این مرحله می‌تواند شامل حذف محصولاتی باشد که توضیحات ناقص دارند.

۲. ماژول درک گفتگو (بخش ۶)

- استخراج موجودیت^۱ (بخش ۷): موجودیت‌های کلیدی مانند نام فیلم و ژانرها را در پرسه کاربر

^۳format standardization

^۱Entity Extraction

را شناسایی می‌کند. اما این رویکرد به هیچ وجه محدود به فیلم‌ها نیست و می‌تواند برای استخراج ویژگی‌های دیگری مانند قیمت، برند، یا رنگ محصولات در دیتاست‌های خرید آنلاین استفاده شود.

- تولیدکننده سوال بعدی^۱ (بخش ۹): برای روشن کردن ورودی‌های مبهم یا ناقص کاربر، درخواست‌های بعدی ایجاد می‌کند.

- غنی‌سازی پرس‌وجو^۲ (بخش ۸): داده‌های ورودی را به صورت پویا تنظیم و اصلاح می‌کند تا درک و زمینه سیستم را بهبود بخشد. به عنوان مثال به مدل زبانی پرسه کامل به همراه فراداده‌هایی چون ژانر موردنظر کاربر و فیلم مورد بحث را به همراه پرسه اصلی کاربر به ورودی مدل جهت انجام عملیات تنظیم سریع بعدی ارسال می‌کند.

۳. ماژول پروفایل کاربری (بخش ۱۰)

- رسیدگی به مشکل شروع سرد (بخش ۳۲):

زمانی که حداقل داده‌های کاربر در دسترس نباشد، ماژول از یک تا پنج ژانرهای مورد علاقه کاربر را از وی دریافت می‌کند و علاوه بر آن با به کارگیری فیلتر مشارکتی مبتنی بر آیتم، ترجیحات کاربر را استنتاج و استفاده می‌کند.

- منطق شخصی‌سازی (بخش ۱۱):

- تطابق نمایه کاربر (بخش ۱۲): از داده‌های موجود کاربر، مانند امتیازات وی، تگ‌ها یا ژانرهای مورد علاقه (مانند استفاده از مجموعه داده مووی لنز) استفاده می‌کند.

- تحلیل احساسات مبتنی بر برچسب (بخش ۱۴): لحن و اولویت درخواست کاربر را بر اساس داده‌های برچسب‌گذاری‌شده تجزیه و تحلیل می‌کند و آیتم‌هایی که وی به آنها تگ‌هایی با لحن مثبت و خوب داده است را استخراج می‌کند.

- استفاده از فیلتر مشارکتی مبتنی بر آیتم جهت استخراج ژانرها و فیلم‌هایی که کاربر احتمالاً به آنها علاقه دارند (بخش ۱۳).

- تولید داده‌های پویا و تولید پرامپت (بخش ۱۵): رفتار سیستم را در زمان واقعی با استفاده از داده‌های نمایه کاربر تطبیق و شخصی می‌کند و یک پرسه شخصی‌سازی‌شده را به مدل ارسال می‌کند.

۴. ماژول مهندسی پرامپت (بخش ۱۶)

¹Follow-up question

²Query Enrichment

- تنظیم سریع: تنظیم دقیق پارامترهای کارآمد^۳ (بخش ۲۰) برای کاهش منابع مورد نیاز و در عین حال تنظیم مدل‌های پایه برای ویژگی خاص دامنه پیاده‌سازی در این قسمت اجرایی می‌شوند. این قسمت پیام‌های چند سطحی را ایجاد می‌کند که به صورت پویا بر اساس پروفایل‌ها و تنظیمات کاربر تطبیق می‌یابد.

- یکپارچه‌سازی بازخورد (بخش ۱۹): رتبه‌بندی کاربران (پسندیدن/نپسندیدن/خنثی) را در پاسخ‌های سیستم جمع‌آوری می‌کند و به طور مکرر درخواست‌ها را به روز می‌کند تا بهتر با انتظارات کاربر هماهنگ شود.

۵. ماژول تولید پاسخ (بخش ۲۱)

- استفاده از مدل زبانی (بخش ۲۲): با یک مدل زبانی که با دستورات مخصوص دامنه تنظیم شده است تا پاسخ‌های مرتبط و منسجمی ایجاد کند.

- حق فراموشی (بخش ۲۳): با ناشناس کردن ورودی‌های کاربر و حذف داده‌هایی که مدل با استفاده از آنها برای یک کاربر خاص شخصی‌سازی شده است در صورت درخواست، حریم خصوصی کاربر را تضمین می‌کند.

- آموزش چند شات (بخش ۲۴): به سرعت با ورودی‌های جدید با استفاده از نمونه‌های چند شات بدون نیاز به بازآموزی گسترده سازگار می‌شود و از پاسخگویی به سناریوهای جدید اطمینان می‌دهد.

۶. جمع‌آوری و ارزیابی بازخورد

- بازخورد کاربر (بخش ۲۶): بازخورد کاربر (پسندیدن/نپسندیدن/خنثی) برای هر یک از پاسخ‌های سیستم را از کاربران جمع‌آوری می‌کند.
- تنظیم تکراری^۱: به طور مداوم عملکرد سیستم را بر اساس بازخورد جمع‌آوری شده کاربران اصلاح می‌کند.

۷. لایه خروجی (بخش ۳۰)

خروجی‌های متن تولید شده، پاسخ‌های ساختارمند و مبتنی بر متن را ارائه می‌دهد که برای سیستم گفتگو مبتنی بر چت بهبود یافته‌اند.

^۳Parameter Efficient Fine Tuning (PEFT)

^۱Iterative Tuning

۲.۳.۳ ویژگی‌های کلیدی پرداخته شده در معماری

در معماری ارائه شده در شکل ۱.۳، به مشکلات زیر پرداخته است.

۱. مشکل شروع سرد: از طریق فیلتر مشارکتی مبتنی بر آیتم و تنظیم دقیق مدل با استفاده از تنظیمات پیش فرض و ترجیحات دریافت شده انجام می‌شود.

۲. حق فراموشی: حق فراموشی یکی از اصول مهم حفظ حریم خصوصی کاربران است. این حق به کاربران اجازه می‌دهد تا درخواست حذف اطلاعات شخصی خود را از پلتفرم‌ها ارائه دهند. این شامل اطلاعات حساس مانند علایق، سابقه جستجو، یا حتی کل حساب کاربری است.

سازگاری با ورودی‌های جدید: سیستم از تکنیک‌های پیشرفته‌ای مانند یادگیری چند شات استفاده می‌کند تا بتواند به راحتی با سناریوهای جدید سازگار شود. این تکنیک به سیستم اجازه می‌دهد تا با مشاهده تنها چند نمونه جدید، به سرعت عملکرد خود را بهبود بخشد. علاوه بر این، تنظیم سریع مجدد نیز به کار گرفته می‌شود. این فرآیند شامل به‌روزرسانی مدل بدون نیاز به آموزش مجدد کامل است. به این ترتیب، سیستم می‌تواند به سرعت به تغییرات محیطی یا نیازهای جدید کاربران پاسخ دهد و کارایی خود را حفظ کند.

این رویکردها، سیستم را انعطاف‌پذیرتر و کاربرپسندتر می‌کنند.

۴.۳ ماژول درک مکالمه

ماژول درک مکالمه^۱ (بخش ۶) به نحوه پردازش پرسش‌های کاربر برای آماده‌سازی داده‌های ورودی مناسب جهت استفاده در مدل می‌پردازد. این ماژول به‌عنوان نقطه شروع تعاملات کاربر با سیستم عمل کرده و با تجزیه و تحلیل ورودی‌های کاربر (پرامپت‌ها) و اضافه کردن جزئیات مفقود، پرسش‌های کامل و ساختاریافته‌ای را برای مدل تولید می‌کند.

فرآیند درک مکالمه از سه گام اصلی تشکیل شده است که به شرح زیر است.

۱. استخراج موجودیت‌های نام‌گذاری شده^۲ (بخش ۷) برای درک بهتر درخواست‌های کاربر، از تکنیک‌های استخراج موجودیت‌های نام‌گذاری شده استفاده می‌شود.

شناسایی موجودیت نام‌گذاری شده یک کار اساسی در پردازش زبان طبیعی است که شامل شناسایی و

¹Dialogue Understanding Module

²Named Entity Recognition (NER)

دسته‌بندی موجودیت‌های نام‌گذاری شده در یک سند متنی به دسته‌های از پیش تعیین شده است [۲۵]. این دسته‌ها معمولاً عبارتند از:

- شخص: نام افراد، مانند «جان اسمیت»
- سازمان: نام شرکت‌ها، مؤسسات یا سازمان‌ها، مانند «Google»
- منطقه: نام مکان‌های جغرافیایی، مانند «نیویورک»
- تاریخ: تاریخ‌ها، زمان‌ها یا دوره‌ها، مانند «۲۰۲۲-۰۱-۰۱»
- رویداد: نام رویدادها، مانند «جام جهانی»

هدف استخراج موجودیت‌های نام‌گذاری شده، شناسایی و طبقه‌بندی خودکار این موجودیت‌های نام‌گذاری شده در یک متن است که می‌تواند برای برنامه‌های مختلف استفاده شود، مانند:

- استخراج اطلاعات: استخراج اطلاعات مرتبط از داده‌های متنی
- خلاصه‌سازی متن: خلاصه‌کردن متن براساس موجودیت‌های شناسایی شده
- تجزیه و تحلیل احساسات: تجزیه و تحلیل احساس متن براساس موجودیت‌های ذکر شده
- پاسخ به سؤال: پاسخ به سؤالات براساس نهادهای شناسایی شده

چندین رویکرد برای استخراج موجودیت‌های نام‌گذاری شده وجود دارد [۷]

، از جمله:

- رویکرد مبتنی بر قانون: استفاده از قوانین از پیش تعیین شده برای شناسایی موجودیتها
- رویکرد نظارت شده: با استفاده از الگوریتم‌های یادگیری ماشین آموزش داده شده بر روی داده‌های برچسب‌دار
- رویکرد بدون نظارت: استفاده از خوشه‌بندی یا تکنیک‌های دیگر برای شناسایی موجودیت‌ها بدون داده‌های برچسب‌دار
- رویکرد یادگیری عمیق: استفاده از شبکه‌های عصبی برای یادگیری الگوهای موجود در داده‌ها [۱۲]

هدف اصلی در این بخش از سیستم شناسایی موارد زیر است:

• نام فیلم: برای یافتن نام فیلم در متن پرامپت، از روش‌های ساده‌ای مانند استفاده از نقل قول‌ها استفاده می‌شود. اگر نام فیلم داخل نقل قول باشد، سیستم به‌طور مستقیم آن را به‌عنوان یک فیلم شناسایی می‌کند و از سایر روش‌های پردازش صرف نظر می‌کند. در غیر این صورت با استفاده از پردازش زبانی طبیعی تلاش می‌کند که نام فیلم را از عبارت وارد شده استخراج کند.

• ژانر فیلم: سیستم تلاش می‌کند تا ژانر را از میان لیستی از ژانرهای از پیش تعریف‌شده تشخیص دهد. ژانرهای موجود به شرح زیر است: کمدی، موزیکال، هیجان‌انگیز، عاشقانه، مستند، ترسناک، جنایی، انیمیشن، فانتزی، ماجراجویی، علمی تخیلی، معمایی، کودکان، درام، جنگی، اکشن و وسترن.

استفاده از این تکنیک‌ها به سیستم کمک می‌کند تا اطلاعات اصلی از پرامپت استخراج شده و با دقت بیشتری پرسش کاربر پردازش شود. با این حال، برای حفظ سادگی، تمرکز ما در این بخش بر پاسخ‌های اولیه و پرسش‌های پیگیری است و سیستم از مدل‌های پیچیده‌تر استخراج موجودیت‌های نام‌گذاری شده صرف نظر کرده است.

۲. پرسش‌های پیگیری (بخش ۹):

اگر کاربر اطلاعاتی ناقص ارائه دهد (مانند عدم ذکر فیلم یا ژانر)، سیستم به صورت خودکار پرسش‌های پیگیری تولید می‌کند. این پرسش‌ها با استفاده از الگوهای از پیش تعریف‌شده طراحی شده‌اند. برای مثال:

- اگر نه نام فیلم و نه ژانر در پرسه کاربر نباشد، «لطفاً نام فیلم و ژانر مورد نظر خود را ذکر کنید»
- اگر نام فیلم مشخص نباشد: «لطفاً نام فیلم مورد نظر خود را مشخص کنید؟»
- اگر ژانر ذکر نشده باشد: «آیا ژانر خاصی را مدنظر دارید؟»

کاربر می‌تواند به این پرسش‌ها پاسخ دهد و سیستم پاسخ‌های کاربر را به پرامپت اولیه اضافه می‌کند تا یک پرامپت کامل و ساختاریافته ایجاد شود.

هرچه یک پرسه جزئیات دقیق‌تر مانند جزئیات ژانر و نام فیلم را دارا باشد مدل توانایی تولید عبارات بهتر و متناسب‌تر برای کاربر خواهد بود که در نهایت به بهبود تجربه کاربری منجر خواهد شد.

برای حفظ انعطاف‌پذیری، کاربران می‌توانند از این مرحله عبور کرده و پرامپت اولیه خود را بدون تغییر ارسال کنند. این قابلیت، تجربه کاربری را بهبود داده و امکان استفاده از سیستم را برای کاربران حرفه‌ای‌تر که می‌خواهند پرسش‌های خود را مستقیماً به مدل ارسال کنند، فراهم می‌کند.

۳. پیش‌پردازش پرامپت:

پیش‌پردازش پرامپت از طریق مازول درک مکالمه، تضمین می‌کند که مدل داده‌های ورودی کامل و دقیق دریافت می‌کند. همچنین احتمال بروز خطا یا پاسخ‌های نامرتب کاهش می‌یابد و تعاملات کاربر به شکلی ساختاریافته‌تر و قابل‌فهم‌تر برای مدل تبدیل می‌شود.

به عنوان مثال، اگر کاربر پرامپت زیر را وارد کند:

”I need movies similar to Inception”

سیستم از استخراج موجودیت‌های نام‌گذاری شده برای استخراج نام فیلم (”Inception”) استفاده می‌کند. اگر ژانری مشخص نشده باشد، سیستم پرسشی مانند: «آیا ژانر خاصی را برای پیشنهاد مدنظر دارید؟» ارائه می‌دهد. پاسخ کاربر به این پرسش‌ها اضافه شده و پرامپت نهایی، به شکل:

”I need movies similar to Inception in the Sci-Fi genre”

به مدل ارسال می‌شود.

این مرحله از پیش‌پردازش پرامپت، تضمین می‌کند که تعاملات کاربر با سیستم گفتگوی وظیفه‌محور در فازهای بعدی (تولید پاسخ) بهینه باشد. علاوه بر این، رویکرد ساده و مؤثر آن به حفظ کارایی و پاسخگویی سریع سیستم کمک می‌کند.

خروجی نهایی این بخش، عبارت ورودی کاربر به صورت کامل و همچنین نام فیلم و ژانر در صورت استخراج به صورت فراداده به عنوان ورودی به مدل وارد شده و عملیات‌های بعدی بر روی این عبارت صورت خواهد گرفت.

یک نمونه پرامپت جهت استفاده از مدل به صورت زیر خواهد بود

I need movies similar to Inception in the Sci-Fi genre (metadatas: movie=Inception
- genre=Sci-Fi)

۵.۳ مازول تولید پاسخ

بخش تولید پاسخ^۱ (بخش ۲۱) به توضیح فرآیند تولید پاسخ‌های شخصی‌سازی شده و متناسب با زمینه برای سیستم گفتگوی پیشنهادی می‌پردازد. هدف از این بخش آن است که مدل با استفاده از داده‌هایی که

¹Response Generation

در مرحله قبل و مختص هر کاربر تولید شده‌اند، تنظیم سریع شود. این داده‌ها شامل اطلاعاتی است که از پایگاه داده‌های فیلترشده استخراج شده و ترجیحات کاربر، مانند ژانرهای منتخب، را در خود جای داده است. علاوه بر این، مدل با پرامپت‌های خاصی که مبتنی بر ورودی‌های کاربر و دارای فراداده‌هایی مانند نام فیلم‌ها و ژانرهای آنها هستند، تنظیم می‌شود. این فرآیند به مدل اجازه می‌دهد تا پاسخ‌هایی دقیق، منطقی و سازگار با نیازهای کاربر تولید کند.

این رویکرد نه تنها به تولید پاسخ‌های شخصی‌سازی شده کمک می‌کند، بلکه باعث می‌شود که سیستم بتواند به طور دقیق‌تری با ترجیحات و رفتارهای کاربران سازگار شود. از طرفی، استفاده از مدل زبانی بزرگ و تنظیم سریع، امکان تطبیق سریع با سناریوهای جدید را فراهم می‌کند. این ترکیب از داده‌های شخصی‌سازی شده و مدل‌های زبانی پیشرفته، به سیستم کمک می‌کند تا پاسخ‌هایی با کیفیت بالا و مرتبط با زمینه تولید کند.

مراحل اصلی در تولید پاسخ به شرح زیر است.

- رمزگذاری پرسش کاربر: برای تبدیل پرسش‌های متنی به قالبی که مدل قادر به درک آن باشد، از توکنایزر استفاده می‌شود. این مرحله، پرسش‌های کاربر را به توالی‌های عددی تبدیل می‌کند.
- تولید پاسخ: از مدل زبانی تنظیم‌شده برای تولید پاسخ استفاده می‌شود. این مدل قادر است بر اساس ورودی‌ها، پاسخ‌هایی سازگار با تاریخچه تعاملات کاربر تولید کند.
- استخراج اطلاعات کلیدی: پس از تولید پاسخ، اطلاعاتی مانند نام فیلم‌ها یا ژانرها از پاسخ‌های تولیدشده استخراج می‌شوند. این اطلاعات برای ذخیره‌سازی و تحلیل‌های بعدی ثبت می‌گردند.
- طراحی پارامترهای تولید پاسخ برای اطمینان از کیفیت و تنوع پاسخ‌ها، پارامترهایی مانند `doSample`، `top-k` و `temperature` تنظیم شده‌اند.
- پارامتر `doSample`: این پارامتر برای ایجاد تنوع در پاسخ‌ها فعال شده است. مقداردهی به این پارامتر به مدل امکان می‌دهد که پاسخ‌هایی غیرتکراری تولید کند.
- پارامتر `top-k`: این مقدار برای محدود کردن تعداد گزینه‌های کاندیدای تولید در هر مرحله به ۱۰۰ تنظیم شده است.
- پارامتر `temperature`: این پارامتر بر نحوه تعادل میان تنوع و انسجام پاسخ‌ها تاثیر می‌گذارد و مقدار آن ۰.۸ تنظیم شده است.

۱.۵.۳ مدیریت تاریخچه تعاملات

یکی از ویژگی‌های کلیدی سیستم این است که برای هر سوال جدید کاربر، تاریخچه گفتگو در نظر گرفته می‌شود. این تاریخچه تنها برای تعامل جاری کاربر استفاده می‌شود و از مکالمات چندمرحله‌ای برای تولید پاسخ پشتیبانی نمی‌شود. این رویکرد تضمین می‌کند که پاسخ‌ها مرتبط با موضوع باشند و پیچیدگی‌های اضافی را کاهش می‌دهد.

۲.۵.۳ فرآیند پاکسازی داده

سیستم شامل مکانیزمی برای اجرای «حق فراموشی» است. این امکان به کاربر اجازه می‌دهد که درخواست حذف داده‌های پیشین خود را ارائه دهد. عملکرد پاک‌سازی داده‌ها به صورت زیر است:

- بررسی ورودی کاربر برای تشخیص عبارت "RTBF"
- پاکسازی داده‌های ذخیره‌شده مرتبط با کاربر.
- بازگرداندن اطلاعات در مورد تعداد رکوردهای حذف‌شده.
- استفاده از بقیه داده‌ها جهت تنظیم سریع مجدد مدل و پاسخ به سوالات بعدی کاربر

۳.۵.۳ واکنش‌های کاربر به پاسخ‌ها

- سیستم بازخورد: پس از تولید هر پاسخ، کاربر می‌تواند واکنش خود که شامل «پسندیدم» یا «نپسندیدم» است را به پاسخ ثبت کند. در صورت عدم ارائه بازخورد، واکنش به صورت پیش‌فرض روی «هیچ» تنظیم می‌شود.
- هدف بازخورد: این مکانیزم به بهبود دقت و شخصی‌سازی پاسخ‌ها کمک می‌کند و امکان تحلیل بیشتر برای ارتقای مدل را فراهم می‌سازد. همچنین جهت دست یافتن به میزان کیفیت پاسخ‌های تولیدشده باید از بازخوردهای کاربران استفاده کرد که به تفصیل در بخش ۴ به آن پرداخته خواهد شد.
- این بخش از سیستم، با بهره‌گیری از قابلیت‌های مدل‌های زبانی و تنظیم داده‌ها، تضمین می‌کند که پاسخ‌های تولیدشده متناسب با ورودی‌های کاربران و نیازهای آن‌ها باشند. علاوه بر این، طراحی انعطاف‌پذیر سیستم امکان ارتقا و بهبود آن در آینده را فراهم می‌کند.

۶.۳ منطق شخصی سازی

شخصی‌سازی یکی از اجزای کلیدی در سیستم‌های گفتگوی وظیفه‌گرا است که بر اساس ترجیحات و بازخورد کاربران، پاسخ‌هایی دقیق و مرتبط تولید می‌کند. این منطق بر اساس تحلیل داده‌های کاربران و به‌روزرسانی‌های پویا در مدل‌های تنظیم‌شده برای هر کاربر طراحی شده است.

این بخش به بررسی مراحل ایجاد مجموعه داده‌های شخصی‌سازی شده، مکانیزم بازخورد کاربر، و تأثیر این بازخورد در تولید پاسخ‌ها می‌پردازد.

ایجاد مجموعه داده‌های شخصی‌سازی شده^۱، سنگ بنای سیستم‌های مبتنی بر شخصی‌سازی است که نیازهای کاربران را در مرکز توجه قرار می‌دهد.

یکی از گام‌های کلیدی در سیستم‌های توصیه‌گر و شخصی‌سازی گفتگوها، ایجاد مجموعه داده‌هایی است که مختص هر کاربر بوده و نیازهای خاص او را منعکس کنند.

همچنین این گام یکی از مهمترین کارهای انجام شده در راستای ایجاد یک مدل کاملاً شخصی‌سازی شده برای هر کاربری است که می‌خواهد با سیستم فوق کار کند و از آن به بهترین شکل برای روزمره خود بهره ببرد. در این جا گام‌های اصلی این فرآیند همراه با جزئیات کامل بیان می‌شود. این فرآیند شامل سه مرحله اصلی است:

۱.۶.۳ پروفایل‌سازی ساده

پروفایل‌سازی ساده^۲ ساده‌ترین نوع ایجاد پروفایل کاربری برای کاربران، استفاده از المان‌های کلیدی برای هر فرد نظیر جنسیت، سن، علایق شخصی در یک حیطه خاص و مواردی از این دست است.

در مرحله اول ایجاد پروفایل شخصی کاربر نیز از همین روش استفاده شده است. هدف از انجام این مرحله، تحلیل رفتار کاربران و استخراج اطلاعات کلیدی مانند فیلم‌های مورد علاقه، ژانرهای محبوب و سایر ترجیحات برای هر کاربر و فیلترکردن مجموعه داده اصلی با استفاده از موارد مورد علاقه کاربر هدف است.

مراحل انجام‌شده در این گام به شرح زیر است:

¹Personalized User Datasets

²Simple User Profiling

• تحلیل داده‌های کاربران: اطلاعات مربوط به تعداد فیلم‌های امتیازدهی شده، میانگین امتیازات، و ژانرهای پرتکرار برای هر کاربر استخراج می‌شود. به عنوان مثال، شناسایی پنج ژانر برتر با استفاده از تکنیک‌های آماری و فراوانی.

• فیلترکردن داده‌ها: بر اساس نتایج تحلیل، مجموعه داده‌های اصلی محدود به فیلم‌ها و ژانرهایی می‌شود که با ترجیحات کاربر تطابق دارند.

اهمیت این مرحله پایه‌ای برای شناسایی دقیق‌تر سلیقه کاربر است و اطلاعات اولیه لازم برای مراحل بعدی را فراهم می‌کند.

رابطه استفاده شده جهت شناسایی ژانرهای برتر مطابق با رابطه‌ی ۲.۳ است:

$$\text{TopGenres} = \arg \max_g \sum_{m \in \text{LikedMovies}} \mathbb{I}(g \in \text{Genres}(m)) \quad (2.3)$$

رابطه ۲.۳ به دنبال شناسایی ژانرهای برتر برای یک کاربر هدف است که بیشترین تعداد تکرار را در فیلم‌های مورد علاقه کاربر دارند. برای این منظور، تعداد حضور هر ژانر در فیلم‌های پسندیده شده محاسبه می‌شود و ژانرهایی که بیشترین فراوانی را دارند، به عنوان ژانرهای برتر انتخاب می‌شوند. این روش به استخراج ترجیحات کاربر بر اساس داده‌های موجود کمک می‌کند.

۲.۶.۳ تحلیل احساسات بر اساس برچسب‌های کاربر

تجزیه و تحلیل احساسات، تکنیکی است که در سیستم‌های توصیه‌گر برای تجزیه و تحلیل لحن احساسی یا نگرش منتقل شده توسط کاربران در بررسی‌ها یا بازخوردهای خود استفاده می‌شود. این به استخراج احساسات یا نظر از داده‌های متنی می‌تواند برای بهبود دقت توصیه‌ها استفاده شود.

تجزیه و تحلیل احساسات در سیستم‌های توصیه‌گر مهم است زیرا می‌تواند درک بیشتری از ترجیحات و نظرات کاربر ارائه دهد. با تجزیه و تحلیل احساسات نظرات کاربران، سیستم‌های توصیه‌گر می‌توانند لحن عاطفی کاربران نسبت به محصولات یا خدمات خاص را شناسایی می‌کند. همچنین بینش‌های ارزشمندی را از بازخورد کاربران استخراج می‌کند که ممکن است توسط سیستم‌های مبتنی بر رتبه‌بندی سنتی دریافت نشوند. علاوه بر آن باعث بهبود دقت توصیه‌ها با در نظر گرفتن احساسات کاربران در کنار رتبه‌بندی آن‌ها می‌شود.

همچنین تجزیه و تحلیل احساسات این پتانسیل را دارد که سهم قابل توجهی در ایجاد پروفایل کاربری دقیق‌تر برای هر فرد داشته باشد.

با تجزیه و تحلیل احساسات نظرات کاربران، سیستم‌های توصیه‌گر می‌توان ترجیحات عاطفی کاربر را شناسایی کرد، تفاوت‌های ظریف نظرات و نگرش‌های کاربر را به تصویر کشید و درک شخصی‌تر از رفتار و ترجیحات کاربر ایجاد کرد.

این می‌تواند به توصیه‌های مؤثرتر و مرتبط‌تری منجر شود که لحن و نگرش عاطفی کاربر را در نظر می‌گیرد [۹]

هدف استفاده از تحلیل احساسات برای شناسایی فیلم‌ها و ژانرهایی که کاربر هدف بیشترین احساس مثبت را نسبت به آن‌ها داشته است. مراحل طی شده جهت استفاده از این روش به شرح زیر است:

- تحلیل برجسب‌های کاربران: از مدل آماده twitter-roberta-base-sentiment-latest برای تحلیل برجسب‌های کاربران استفاده شده است.
- استخراج داده‌های برتر: شناسایی ۵ فیلم با بالاترین امتیاز احساسی گام اول است. این گام با تعیین ژانرهای مورد علاقه کاربر بر اساس امتیازات احساسی تگ‌هایی که کاربران به فیلم‌های مختلف داده‌اند انجام می‌شود. به عنوان مثال مثال فیلم‌هایی با برجسب مثبت مانند inspirational یا funny ممکن است ژانرهای کمدی و درام را برجسته کنند.

این تحلیل، لایه عمیق‌تری از ترجیحات کاربر را کشف می‌کند که فراتر از رتبه‌بندی‌های ساده است. نتایج می‌توانند در ارائه توصیه‌هایی دقیق‌تر و مؤثرتر مورد استفاده قرار گیرند.

۳.۶.۳ فیلتر مبتنی بر آیتم

فیلتر مشارکتی مبتنی بر آیتم^۱ نوعی الگوریتم توصیه است که موارد را براساس رفتار سایر کاربران که با موارد مشابه تعامل داشته‌اند به کاربر پیشنهاد می‌کند. با تجزیه و تحلیل روابط بین موارد و شناسایی الگوها در رفتار کاربر کار می‌کند [۱].

نحوه عملکرد فیلتر مشارکتی مبتنی بر آیتم به شرح زیر است:

- محاسبه شباهت آیتم: شباهت بین موارد را بر اساس تعاملات کاربر (به عنوان مثال، رتبه‌بندی، مشاهده فیلم) محاسبه می‌کند.

¹Item-Based Collaborative Filtering

- ساخت نمایه کاربر: با تجزیه و تحلیل تاریخچه تعامل آنها با موارد، یک نمایه کاربری ایجاد می‌کند.
 - تولید توصیه: مواردی را بر اساس شباهت بین پروفایل کاربر و پروفایل سایر کاربران که با موارد مشابه تعامل داشته‌اند به کاربر توصیه می‌کند [۸].
- در زمینه یک سیستم گفتگو برای توصیه‌های کاربر، فیلتر مشارکتی مبتنی بر آیتم می‌تواند برای موارد زیر استفاده شود:
- ایجاد نمایه کاربری: تجزیه و تحلیل تاریخچه تعامل کاربر با سیستم جهت ایجاد نمایه‌ای که ترجیحات و رفتار آنها را نشان می‌دهد.
 - ایجاد توصیه: از نمایه کاربر برای توصیه مواردی که احتمالاً مورد علاقه کاربر هستند استفاده می‌کند.
 - به‌روزرکردن نمایه کاربر: به‌طور مداوم نمایه کاربر را بر اساس تعامل آنها با موارد توصیه‌شده به‌روز می‌شود تا توصیه‌ها در طول زمان اصلاح شود.
- هدف از استفاده از این روش پیشنهاد فیلم‌های جدید به کاربر بر اساس شباهت به فیلم‌هایی که کاربران دیگر که سلیقه‌ای مشابه با کاربر هدف دارند تماشا کرده‌اند است. مراحل این کار به شرح زیر است.
- ایجاد ماتریس کاربر-فیلم: یک ماتریس از داده‌های امتیازدهی ایجاد می‌شود که نشان‌دهنده تعاملات کاربران با فیلم‌هاست.
 - نرمال‌سازی داده‌ها: ماتریس نرمال‌سازی شده برای کاهش تأثیر تعصبات کاربر استفاده می‌شود که مطابق با ۳.۳ است.

$$\text{NormalizedMatrix} = \text{Ratings} - \text{UserRatingsMean} \quad (3.3)$$

- پیش‌بینی امتیاز برای فیلم‌های جدید: فیلم‌های مشابه با استفاده از میانگین وزنی امتیازات و شباهت‌ها رتبه‌بندی می‌شوند.
- این روش، فیلم‌هایی را پیشنهاد می‌کند که کاربران با سلیقه مشابه آنها را ترجیح داده‌اند و به بهبود دقت سیستم کمک می‌کند.

۴.۶.۳ ترکیب و فیلترسازی نهایی

در نهایت، اطلاعات جمع‌آوری شده از سه مرحله فوق ترکیب می‌شود:

- ژانرهای برتر کاربر: تعیین ژانرهایی که بیشترین تعداد فیلم محبوب کاربر را شامل می‌شوند.
- فیلم‌های توصیه‌شده: فیلم‌های جدید با استفاده از فیلتر مبتنی بر آیتم و تحلیل احساسات انتخاب می‌شوند.
- فیلترسازی نهایی: فیلم‌های انتخاب‌شده در صورتی که با ژانرهای هدف مشخص‌شده در پرسه کاربر سازگار باشند، به مجموعه نهایی اضافه می‌شوند.

این روش با استفاده از داده‌های موجود از رفتار کاربر، تحلیل احساسات و تکنیک‌های فیلترسازی مبتنی بر آیتم، مجموعه داده‌ای شخصی‌سازی شده ایجاد می‌کند. این مجموعه داده، مدل‌های زبانی تنظیم‌شده را قادر می‌سازد تا پاسخ‌های دقیق‌تر و مرتبط‌تر با نیازهای کاربران تولید کنند. همچنین مکانیزم بازخورد و تطبیق با ژانرهای مشخص‌شده توسط کاربر، دقت سیستم را بهبود می‌بخشد.

۵.۶.۳ مکانیزم بازخورد

این سیستم از یک مکانیزم بازخورد کاربر برای بهبود مستمر شخصی‌سازی بهره می‌برد: کاربران می‌توانند به پاسخ‌های سیستم واکنش‌های «پسندیدم»، «نپسندیدم» و «هیچ» (پیش‌فرض) را نشان دهند. این بازخوردها برای اصلاح مجموعه داده‌های کاربر و تطبیق بیشتر پاسخ‌ها استفاده می‌شوند. این بازخورد به طور مستقیم مجموعه داده کاربر را به‌روزرسانی کرده و داده‌های مرتبط با ترجیحات او را اصلاح می‌کند. در واقع ترجیحات کاربر در زمان واقعی به‌روزرسانی می‌شود و ژانرهای برتر کاربر و داده‌های مرتبط با بازخورد وی در هر مرحله تنظیم می‌شوند.

تأثیر بازخورد در تولید پاسخ:

بازخورد کاربران نه تنها مجموعه داده‌های آموزشی را تغییر می‌دهد، بلکه پاسخ‌های تولیدی آینده را نیز به‌طور مستقیم تحت تأثیر قرار می‌دهد.

با تغییر مجموعه داده‌هایی که برای تنظیم مدل زبانی استفاده می‌شوند، پاسخ‌های شخصی‌سازی‌شده‌تری بر اساس داده‌های به‌روز شده تولید می‌شوند. همچنین برای سیستم این امکان فراهم است که حتی پس از ایجاد مدل تنظیم‌شده، با ارائه بازخورد بیشتر، پاسخ‌ها دقیق‌تر و متناسب‌تر شوند.

منطق شخصی‌سازی از طریق ایجاد مدل‌های تنظیم‌شده بر اساس ترجیحات کاربران و بازخوردهای آن‌ها، تجربه کاربری بهتری را فراهم می‌کند. انعطاف‌پذیری این سیستم، امکان تعامل پویا و ارائه پاسخ‌های متناسب‌تر را فراهم می‌کند. علاوه بر این، قابلیت فیلترکردن داده‌ها بر اساس ژانر هدف، به بهبود کیفیت و کارایی سیستم کمک شایانی می‌کند.

۷.۳ نتیجه‌گیری

در این بخش، به منظور بهبود تعاملات کاربران با سیستم‌های گفتگوی وظیفه‌گرا، رویکردی چندلایه طراحی شده که هر بخش آن به حل یکی از چالش‌های مهم در این حوزه اختصاص یافته است. در لایه ورودی، فرآیندهای پیش‌پردازش و نرمال‌سازی داده‌ها به شکلی انجام می‌شود که هم دقت سیستم و هم درک متنی افزایش یابد. همچنین ماژول‌های درک گفتگو و شخصی‌سازی پروفایل کاربر به سیستم امکان می‌دهند که نیازها و اولویت‌های کاربران را به‌صورت پویا شناسایی کرده و پاسخ‌های دقیق‌تری ارائه دهد.

در لایه تنظیم سریع و تولید پاسخ، استفاده از مدل‌های زبانی و تکنیک‌های تنظیم سریع، انعطاف‌پذیری سیستم را برای سازگاری با داده‌های جدید بهبود داده است. علاوه بر این، تضمین حق فراموشی و توجه به حفظ حریم خصوصی کاربران، از جمله نوآوری‌های مهم این سیستم بوده است. مکانیزم جمع‌آوری بازخورد و تطبیق مکرر نیز به عنوان ابزاری موثر برای بهبود مستمر سیستم معرفی شد. این رویکرد چندجانبه نشان می‌دهد که چگونه می‌توان با ترکیب تکنیک‌های پیشرفته، تعاملات کاربر و عملکرد کلی سیستم‌های گفتگو را به سطح بالاتری ارتقا داد.

در این پژوهش، روشی عمومی برای توصیه‌سازی پیشنهاد شد که می‌تواند در حوزه‌های مختلفی از جمله فیلم‌ها، موسیقی، کتاب‌ها، و حتی خدمات آموزشی استفاده شود. اگرچه به منظور دستیابی به نتایج قابل مقایسه از دیتاست مووی لنز به عنوان مثالی کاربردی استفاده کردیم، اما تمامی مراحل و الگوریتم‌های ارائه‌شده به گونه‌ای طراحی شده‌اند که مستقل از حوزه خاصی هستند. این انعطاف‌پذیری، امکان استفاده از روش پیشنهادی در بسیاری از کاربردهای دیگر را فراهم می‌کند.

فصل ۴

ارزیابی و تحلیل نتایج

۱.۴ مقدمه

در این فصل یک کاوش عمیق از مجموعه داده‌ها، مجموعه داده‌های آزمایشی، ابرپارامترها، معیارهای ارزیابی و نتایج مورد استفاده در تحقیق ارائه شده است که با توصیف مجموعه داده‌های اولیه، از جمله ساختار، ویژگی‌ها و ارتباط آنها با حوزه شروع می‌گردد.

این فصل به تشریح مجموعه داده‌های آزمایشی مورد استفاده برای اعتبارسنجی و مقایسه‌های مورد نیاز ادامه می‌دهد و به دنبال آن یک ارایه با جزییات از ابرپارامترهای انتخاب‌شده برای بهینه‌سازی عملکرد مدل ارائه می‌شود. علاوه بر این، معیارهای ارزیابی مورد استفاده جهت تعیین کمیت اثربخشی مدل و تجزیه و تحلیل نتایج تجربی، از جمله آنالیزهای حساسیت، برای ارزیابی استحکام رویکرد پیشنهادی تعریف شده‌است. این بحث جامع به اعتبار نتایج تحقیق کمک می‌کند.

۲.۴ مجموعه داده‌های مورد استفاده

در این قسمت دیتاست‌های مورد استفاده در این پژوهش توضیح داده شده است.

۱.۲.۴ مجموعه داده مووی لنز

همانطور که در بخش ۲.۳ گفته شد، از دیتاست ۲۵ میلیونی مووی لنز استفاده شده است. این مجموعه داده‌های کاربران و فیلم‌ها، مانند رتبه‌بندی‌ها، ژانرها، و مهرهای زمانی را ارائه می‌کند که پایه و اساس پروفایل‌سازی کاربر و وظایف پیشنهادی را تشکیل می‌دهند.

مجموعه داده‌های موجود در مووی لنز به شرح زیر است:

۱. دیتاست فیلم‌ها: ویژگی‌های این دیتاست به شرح زیر است

- آیدی: یک شناسه منحصر به فرد برای هر فیلم.
- عنوان: عنوان فیلم به همراه سال اکران آن.
- ژانرها: فهرستی از ژانرهای مرتبط با فیلم.

۲. دیتاست امتیازها: ویژگی‌های این دیتاست به شرح زیر است

- آیدی کاربر: یک شناسه منحصر به فرد برای هر کاربر.
- آیدی فیلم: شناسه فیلم رتبه‌بندی‌شده توسط کاربر.
- امتیاز: امتیاز ارائه‌شده توسط کاربر، از ۰.۵ تا ۵.۰.
- مهر زمان: یک مهر زمانی یونیکس از زمانی که امتیاز داده‌شده است.

۳. دیتاست تگ‌ها: ویژگی‌های این دیتاست به شرح زیر است.

- آیدی کاربر: کاربری که تگ را اضافه کرده است.
- آیدی فیلم: شناسه فیلم تگ‌شده.
- برچسب: تگ توصیفی اضافه‌شده توسط کاربر.
- مهر زمان: یک مهر زمانی یونیکس از زمانی که برچسب اضافه شده است.

همچنین با استفاده از دیتاست‌های فوق، یک مجموعه داده تلفیقی از پیش پردازش شده MovieRatingTag ایجاد شده است.

ویژگی‌های این مجموعه داده به صورت زیر است.

- آیدی کاربر: شناسه کاربر.

- آیدی فیلم: شناسه فیلم.
- امتیاز: امتیاز کاربر برای فیلم.
- عنوان: عنوان فیلم.
- ژانرها: ژانرهای مرتبط.
- برچسب: برچسب داده‌شده توسط کاربر، در صورت وجود.

۲.۲.۴ رویکردهای ایجاد مجموعه داده

با توجه به آن‌که جهت آموزش یک مدل زبانی بزرگ جهت ایجاد یک سیستم گفت‌وگو نیازمند دیتاستی با فرمت سوالات پرسیده و جواب‌های داده‌شده است، یک دیتاست به فرمت فوق ایجاد کردیم. این مجموعه داده برگرفته از مووی لنز، مکالمه طبیعی را با ایجاد جفت پرسش-پاسخ شبیه سازی می‌کند. این مجموعه داده برای تکرارپذیری و استفاده سایرین در سایت هاگینگ فیس منتشر شده است. نحوه ایجاد این دیتاست به تفصیل در بخش ۲.۳ آورده شده است. ویژگی‌های مجموعه داده به شرح زیر است.

- ورودی: اعلان ورودی که به سیستم گفتگو داده می‌شود.
 - خروجی: پاسخ مورد انتظار تولیدشده توسط سیستم گفتگو.
 - عنوان فیلم: عنوان فیلم مربوط به دیالوگ.
 - سال: سال اکران فیلم.
 - ژانرها: ژانر(های) مرتبط با فیلم.
 - امتیاز شباهت: امتیاز شباهت بین پاسخ‌های تولیدشده و فیلم موجود در ورودی.
- یک نمونه از رکوردهای این دیتاست به فرمت زیر است.
- ورودی: من چند فیلم جنایی می‌خواهم که مانند «باشگاه مشت زنی (۱۹۹۹)» باشد. پیشنهاد شما چیست؟
خروجی: پس از لذت بردن از «باشگاه مشت زنی (۱۹۹۹)»، فیلم‌های جنایی پنهان را کشف کنید. در اینجا چند پیشنهاد برای فیلم وجود دارد: Seven (۱۹۹۵)
نام فیلم: باشگاه مشت زنی (۱۹۹۹)

سال: ۱۹۹۵

ژانر: اکشن | جنایی | درام | هیجان انگیز

امتیاز شباهت: ۰.۹۳

۳.۴ مجموعه داده تست

مجموعه داده مووی لنز برای استخراج پروفایل‌های کاربر، داده‌های آموزشی و داده‌های ارزیابی استفاده می‌شود. نمایه‌های کاربران با تجزیه و تحلیل رتبه‌بندی کاربران، ژانرها و برچسب‌ها ساخته شده است. داده‌های آموزشی شامل ۸۰ درصد از دیتاست شخصی‌سازی شده کاربر و تعاملات وی است که برای تنظیم دقیق سیستم گفتگو استفاده می‌شود. با استفاده از این دیتاست، برای هر کاربر موجود در دیتاست یک مدل مجزا آموزش داده شده است که در مرحله ارزیابی مورد استفاده قرار گرفته است. داده‌های آموزشی شامل ۲۰ درصد از دیتاست شخصی‌سازی شده کاربر و تعاملات وی برای ارزیابی استفاده شده است. ده نمونه تصادفی از هر کاربر برای آزمایش استفاده شد که با استفاده از مدل آموزش دیده خاص کاربر، مجموعه‌ای از جواب‌های شخصی‌سازی شده کاربر را ایجاد می‌کند که در نهایت پارامترهای ارزیابی بر روی این مجموعه داده‌ها اعمال خواهند شد.

۴.۴ ابرپارامترها

ابرپارامترها تنظیمات کلیدی در مدل‌های یادگیری ماشینی هستند که به طور قابل توجهی بر آموزش و عملکرد تأثیر می‌گذارند. برای این کار، ابرپارامترهای انتخاب شده بر روی تنظیم سریع و رفتار تولید مدل، و همچنین پیکربندی آموزش تمرکز دارند. در زیر به تفکیک هر یک از ابرپارامترها و تأثیر آن می‌پردازیم.

۱.۴.۴ ابرپارامترهای تنظیم سریع و تولید پاسخ

• max-length

این مقدار حداکثر تعداد کلماتی را که مدل می‌تواند برای یک پاسخ ایجاد کند را تعیین می‌کند که ارزش ۵۰۰ برای این مقدار در نظر گرفته شده است.

مقدار بالاتر، پاسخ‌های طولانی‌تر و دقیق‌تر را امکان‌پذیر می‌کند، اما زمان محاسبات و استفاده از حافظه را افزایش می‌دهد در حالی که مقادیر پایین‌تر می‌تواند طول پاسخ را محدود کند و به طور بالقوه پاسخ‌های معنی‌دار را کوتاه کند. مقدار انتخاب‌شده پرحرفی و کارایی محاسباتی را متعادل می‌کند.

• pad-token-id

شناسه پد توکن، نشانه مورد استفاده‌ای است که فاصله‌های توالی به طول یکنواخت را مشخص می‌کند. اندازه ورودی ثابت و سازگاری با معماری مدل را تضمین می‌کند و از بروز خطا در طول آموزش یا استنتاج جلوگیری می‌کند. به همین دلیل مقدار tokenizer.eos-token-id برای این ابرپارامتر در نظر گرفته شده‌است.

• no-repeat-ngram-size

از تکرار هر n-گرام (توالی از n کلمه) در طول تولید توسط مدل جلوگیری می‌کند. افزایش این مقدار تنوع در متن تولیدشده را تشویق می‌کند، افزونگی را کاهش می‌دهد و منجر به پاسخ‌های طبیعی‌تر و متنوع‌تر می‌شود. برای این مقدار در آموزش مدل مقدار پنج انتخاب شده‌است.

• do-sample

نمونه برداری از توزیع احتمال نشانه بعدی را به جای انتخاب همیشه نشانه با بیشترین احتمال (رمزگشایی حریصانه) فعال می‌کند. فعال کردن این مقدار در مدل تصادفی بودن را به پاسخ‌ها اضافه می‌کند و تنوع را افزایش می‌دهد. برای تولید خروجی‌های خلاقانه یا کمتر قطعی مفید است.

• top-k

این ابرپارامتر در آموزش مدل تعداد توکن‌های بالقوه بعدی را به k محتمل‌ترین آن‌ها محدود می‌کند. مقدار در نظر گرفته‌شده برای این پارامتر ۱۰۰ است. افزایش مقدار این ابرپارامتر تصادفی بودن را به ادامه‌های قابل قبول‌تر محدود می‌کند. مقادیر بالاتر تنوع را افزایش می‌دهد اما می‌تواند منجر به پاسخ‌های منسجم کمتری شود.

• top-p

توکن‌هایی که احتمال تجمعی آن‌ها با تمرکز بر محتمل‌ترین نتایج تا p باشد را انتخاب می‌کند.

مقدار این ابرپارامتر تعادل بین رفتار قطعی و تصادفی را تضمین می‌کند. مقدار کمتر پاسخ‌های منسجم‌تری را در اولویت قرار می‌دهد.

• temperature

این ابرپارامتر تصادفی‌بودن انتخاب نشانه را در طول تولید کنترل می‌کند. مقادیر نزدیک‌تر به صفر مدل را قطعی‌تر می‌کند، در حالی که مقادیر بالاتر تغییرپذیری را ایجاد می‌کند. مقدار انتخاب شده ۰.۸ است که خروجی‌های متنوع و نسبتاً منسجم را تضمین می‌کند.

• target-device

سخت‌افزار مورد استفاده برای محاسبات را مشخص می‌کند. که با توجه به سیستم و سخت‌افزار مقدار، "cuda" در صورت موجود بودن یا "cpu" در صورت عدم وجود حافظه گرافیکی مجزا انتخاب می‌شوند. استفاده از جی‌پی‌یو به طور قابل توجهی سرعت آموزش و استنتاج را افزایش می‌دهد. همچنین مقدار سی‌پی‌یو سازگاری را در سیستم‌های بدون جی‌پی‌یو تضمین می‌کند.

۲.۴.۴ ابرپارامترهای آموزشی

• learning-rate

این ابرپارامتر اندازه گام را برای به‌روزرسانی پارامترهای مدل در طول آموزش تعیین می‌کند. نرخ بالای یادگیری همگرایی را تسریع می‌کند، اما خطر فراتر رفتن از مقادیر بهینه را به همراه دارد که منجر به بی‌ثباتی می‌شود. نرخ یادگیری تنظیم دقیق معمولاً کمتر است (به عنوان مثال، ۵-۵e)، اما تنظیم سریع از مقادیر بالاتر برای تطبیق سریع جاسازی‌ها استفاده می‌کند. به همین دلیل مقدار ۰.۰۳ برای این ابرپارامتر در نظر گرفته شده است.

• prompt-tuning-training-epoch

تعداد اپاک^۱ های کامل از مجموعه داده آموزشی را مشخص می‌کند. دوره‌های بیشتر انطباق مدل را بهبود می‌بخشد، اما در صورت زیاده‌روی، خطر تطبیق بیش از حد^۲ را دارد. مقدار انتخاب‌شده برای آموزش مدل پنج اپاک است عمق تمرین و کارایی زمان را متعادل می‌کند.

^۱epoch

^۲Overfitting

- auto-find-batch-size

با مقداردهی به این ابرپارامتر، مدل به صورت پویا بزرگترین اندازه دسته‌ای را که در حافظه جا می‌گیرد، تعیین می‌کند.

راه‌اندازی آموزش را با جلوگیری از مشکلات سرریز حافظه ساده می‌کند و همچنین استفاده موثر از سخت‌افزار موجود را تضمین می‌کند.

- no-cuda

اطمینان حاصل می‌کند که مدل در صورت وجود از منابع جی‌پی‌یو استفاده می‌کند. سرعت آموزش و توان عملیاتی مدل را بهبود می‌بخشد و همچنین سازگاری با هر دو سیستم جی‌پی‌یو و سی‌پی‌یو را تضمین می‌کند.

۳.۴.۴ تعامل ابرپارامترها

- تعادل تصادفی و انسجام

ترکیب top-k top-p، و temperature مستقیماً بر تنوع و طبیعی بودن پاسخ‌های تولیدشده تأثیر می‌گذارد. ارزش‌های انتخاب شده به نفع خروجی‌های خلاقانه بدون قربانی کردن انسجام است.

- ثبات آموزش مدل

نرخ یادگیری بالاتر (۳-۲e) به‌روزرسانی‌های تعبیه‌شده را در طول تنظیم سریع تسریع می‌کند.

- استفاده از منابع

ویژگی‌هایی مانند auto-find-batch-size و پشتیبانی از جی‌پی‌یو تضمین می‌کند که فرآیند آموزش با منابع موجود سازگار می‌شود و کارایی را به حداکثر می‌رساند.

۵.۴ معیارهای ارزیابی

در این بخش، به معیارهای ارزیابی مورد استفاده در ارزیابی سیستم گفتگو وظیفه‌گرا را بررسی می‌کنیم. هدف از این معیارهای ارزیابی هم کیفیت پاسخ‌های تولیدشده توسط مدل و هم میزان موفقیت سیستم گفتگو است. هر معیار بر جنبه‌های خاصی از سیستم، مانند موفقیت کار، رضایت کاربر، یا کیفیت پاسخ تمرکز می‌کند. در ادامه بحث مفصلی از معیارهای مربوطه، از جمله تعاریف، محاسبات و نقش آنها در ارزیابی ارائه شده است.

۱.۵.۴ معیار گيجی^۱

گيجی معیاری است برای اینکه یک مدل زبان احتمالی چقدر یک نمونه را پیش‌بینی می‌کند. این نشان دهنده عدم قطعیت مدل در تولید توکن بعدی در یک دنباله است.

$$P(W) = 2^{-\frac{1}{N} \sum_{i=1}^N \log_2 P(w_i | w_1, w_2, \dots, w_{i-1})} \quad (1.4)$$

در رابطه ۱.۴ مقدار N تعداد کل توکن‌ها در دنباله است. همچنین $P(w_i)$ احتمالی که توسط مدل به توکن w_i اختصاص داده شده است.

گيجی کمتر نشان می‌دهد که مدل در پیش‌بینی نشانه بعدی بهتر است. در سیستم‌های گفتگو، گيجی روان بودن پاسخ و ارتباط پاسخ‌ها را ارزیابی می‌کند.

۲.۵.۴ معیار تمایز^۱

مقاله [۱۶] به معیارهای ارزیابی تمایز برای ارزیابی تنوع پاسخ‌های تولیدشده اشاره می‌کند. تمایز- n ، تنوع متن تولیدشده را با محاسبه نسبت گرام- n منحصربه‌فرد به کل گرام- n در پاسخ‌ها اندازه‌گیری می‌کند. معیار تمایز-۱: تنوع یونیگرام‌ها (کلمات فردی) در متن تولیدشده را ارزیابی می‌کند.

$$Distinct - 1 = \frac{NumberOfUniqueUnigrams}{TotalNumberOfUnigrams} \quad (2.4)$$

معیار تمایز-۲: تنوع توالی دو کلمه‌ای‌ها در متن تولیدشده را ارزیابی می‌کند.

$$Distinct - 2 = \frac{NumberOfUniqueBigrams}{TotalNumberOfBigrams} \quad (3.4)$$

مقادیر بالاتر نشان‌دهنده پاسخ‌های متنوع‌تر و کمتر تکراری است که برای طبیعی‌بودن مکالمه بسیار مهم است.

¹Perplexity

¹Distinct

۳.۵.۴ معیار میزان موفقیت^۲

میزان موفقیت یک معیار ارزیابی پرکاربرد برای سیستم‌های گفتگو، به ویژه در سیستم‌های گفتگوی وظیفه‌گرا است. این معیار به صورت کلی درصد اهداف موفق کاربر که توسط سیستم به دست آمده است را اندازه‌گیری می‌کند.

نرخ موفقیت به عنوان نسبت اهداف موفق کاربر به تعداد کل اهداف کاربر محاسبه می‌شود. هدف کاربر در صورتی موفق تلقی می‌شود که سیستم بتواند درخواست کاربر را برآورده کند یا کار را کامل کند [۲۳]. در ارزیابی سیستم گفتگو فوق میزان موفقیت معادل آن است که هر چند وقت یکبار سیستم به یک نتیجه مثبت بر اساس بازخورد کاربر می‌رسد.

در این معیار محاسبه میزان موفقیت آسان است و آن را به معیاری مناسب برای ارزیابی تبدیل می‌کند. همچنین درک روشنی از توانایی سیستم برای تحقق اهداف کاربر ارائه می‌دهد و میزان موفقیت امکان مقایسه سیستم‌های گفتگوی مختلف را فراهم می‌کند. رابطه محاسبه میزان موفقیت مطابق با ۴.۴ است.

$$SuccessRate = \frac{Number\ of\ 'LIKE'\ Feedbacks}{Total\ Feedbacks\ ('LIKE'\ +\ 'DISLIKE')} \quad (۴.۴)$$

با استفاده از این معیار می‌توان توانایی سیستم در برآوردن انتظارات کاربر را ارزیابی کرد. همچنین بازخورد خنثی را برای تمرکز بر ترجیحات صریح کاربر در نظر گرفته نمی‌شود.

۴.۵.۴ معیار نرخ تکمیل^۱

نرخ تکمیل یک معیار ارزیابی است که برای ارزیابی عملکرد سیستم‌های گفتگو، به ویژه در سیستم‌های گفتگوی وظیفه‌گرا استفاده می‌شود. درصد مکالماتی که توسط سیستم با موفقیت انجام شده است را اندازه‌گیری می‌کند [۲۳].

در واقع نرخ تکمیل کار، توانایی سیستم را برای انجام موفقیت‌آمیز یک کار در نوبت گفتگو اندازه‌گیری می‌کند. معیار تکمیل کار در سیستم گفتگو فوق، نشان‌دهنده موفقیت تکلیف‌محور، مانند ارائه توصیه‌های فیلم یا تکمیل هدف گفتگو است [۲۶].

نرخ تکمیل به عنوان نسبت مکالماتی که معیارهای تکمیل را دارند به تعداد کل مکالمات آغاز شده محاسبه می‌شود.

^۲Success Rate

^۱Completion Rate

معیارهای تکمیل به شرح زیر خواهد بود:

۱. پایان معتبر پیام تولید شده:

متن تولید شده با علائم نگارشی معتبر (نشان دهنده پاسخ کامل) به پایان می‌رسد.

۲. توصیه فیلم:

پاسخ حاوی توصیه حداقل یک فیلم است. بعد از دریافت گزاره تولید شده توسط مدل، فیلم‌های موجود در آن گزاره از آن استخراج می‌گردد. این معیار خالی بودن یا نبودن این لیست از فیلم‌های پیشنهادی را بررسی می‌کند.

رابطه محاسبه نرخ تکمیل مطابق با رابطه ۵.۴ است.

$$CompletionRate = \frac{NumberOfCompletedTasks}{TotalNumberOfTasks} \quad (5.4)$$

این معیار درکی واضح از تکمیل کار را ارائه می‌دهد. نرخ تکمیل نشانه واضحی از توانایی سیستم برای تکمیل مکالمات با موفقیت ارائه می‌دهد. همچنین با در نظر گرفتن هر دو معیار، میزان تکمیل موفقیت جزئی را در نظر می‌گیرد، مانند مکالماتی که پایان معتبری دارند اما توصیه فیلم ندارند.

۵.۵.۴ معیار امتیاز تعامل کاربر^۱

امتیاز تعامل کاربر سطح تعامل کاربران با سیستم را اندازه‌گیری می‌کند. این معیار با توجه به نشست‌های کاربر و بازخوردهایی که به سیستم داده است محاسبه می‌شود [۱۱]. برای هر کاربر به ازای هر نشست جدیدی که ایجاد می‌کند، تعداد جواب‌های تولیدی مدل که بازخورد مثبت گرفته‌اند را به تعداد کل پیام‌های ردوبدل شده مدل تقسیم می‌کند.

$$UES = \left(\frac{TotalInteractionsintheSession}{NumberOfLIKE'Feedbacks} \right) \times 10 \quad (6.4)$$

امتیاز تعامل کاربر بالاتر سیستم جذاب‌تری را پیشنهاد می‌کند.

¹User engagement score metric

۶.۵.۴ مطابقت تنوع نمایه^۲

مطابقت تنوع نمایه تنوع ژانرهای تحت پوشش توصیه‌های سیستم را در مقایسه با ترجیحات کاربر اندازه‌گیری می‌کند. این معیار در واقع ارزیابی می‌کند که سیستم تا چه حد از وسعت علایق کاربر به درستی در جواب‌های تولیدی خود استفاده کرده است.

$$PDM = \frac{NumberOfUniqueRecommendedGenres}{NumberOfUniqueUser - PreferredGenres} \quad (۷.۴)$$

در رابطه ۷.۴ ژانرهای توصیه‌شده منحصر به فرد برای کاربر در واقع ژانرهای متمایز در توصیه‌های سیستم گفتگو در طول دوره ارزیابی هستند. همچنین ژانرهای منحصر به فرد ترجیحی کاربر، ژانرهای متمایز در نمایه کاربر هستند که در ابتدای ایجاد پروفایل به وجود آمده‌اند و در طول زمان نیز به‌روز می‌شوند.

مقدار مطابقت تنوع نمایه بالا نشان می‌دهد که سیستم طیف گسترده‌ای از ژانرهای ترجیحی کاربر را پوشش می‌دهد و توانایی آن در تنوع بخشیدن به توصیه‌ها را نشان می‌دهد. مقدار مطابقت تنوع نمایه پایین نشان می‌دهد که توصیه‌ها تکراری هستند یا نمی‌توانند دامنه علایق کاربر را جلب کنند.

۶.۴ ارزیابی اعمال تغییرات بر روی معیارهای ارزیابی

در این بخش تأثیر تکنیک‌های نمایه‌سازی کاربر، به عنوان مثال تحلیل معنایی و فیلتر مشارکتی مبتنی بر آیم، بر عملکرد مدل و رضایت کاربر ارزیابی شده است.

تحلیل معنایی به درک تفاوت‌های احساسات کمک می‌کند. این تحلیل باعث می‌شود پاسخ‌ها با زمینه و نیازهای کاربر سازگارتر باشند. از طرف دیگر، فیلتر مشارکتی توصیه‌های دقیق‌تری ارائه می‌دهد. این فیلتر بر اساس شباهت‌های بین کاربران عمل می‌کند و دقت توصیه‌ها را تضمین می‌کند. معیارهای قبلی نشان داده‌اند که ترکیب این دو رویکرد می‌تواند تعامل و دقت را بهبود بخشد. این نتایج نقش حیاتی هر دو رویکرد را در بهبود عملکرد سیستم تأکید می‌کند.

در ادامه، چارچوبی برای آزمایش تأثیرات مستقیم پروفایل کاربر ارائه شده است. این چارچوب به بررسی فرضیه‌های خاص می‌پردازد. برای مثال، سهم تحلیل معنایی در درک بهتر زمینه و نقش فیلتر مشارکتی در بهبود

^۲Profile Diversity Match

دقت توصیه‌ها مورد بررسی قرار می‌گیرد. هدف از این بخش، جداسازی و اندازه‌گیری تأثیر هر بخش سیستم بر نتایج نهایی است. علاوه بر این، تأثیر ترکیبی مؤلفه‌های مختلف پروفایل‌سازی نیز بررسی می‌شود. این بررسی شامل کیفیت تولید گفتگو، موفقیت کاربر در رسیدن به هدف، و معیارهای تعامل کاربر است. جهت انجام مطالعات فرسایشی^۱ بر روی بخش‌های مختلف سیستم، باید سیستم را به طور کامل و در چندین مرحله بررسی کنیم.

در هر مرحله کل سیستم بدون یک قسمت از برنامه مورد ارزیابی مجزا قرار داده می‌شود تا نتایج با و بدون وجود آن قسمت باهم مقایسه شوند و میزان تأثیر قسمت فوق در برنامه مشخص گردد. این رویکرد به شناسایی اهمیت هر جزء کمک می‌کند و بینش‌هایی را در مورد استحکام و رفتار سیستم کلی ارائه می‌کند [۱۸]. همچنین معیارهای دیگر نظیر تغییر بیشینه طول رشته تولیدی توسط مدل نیز در این قسمت مورد ارزیابی قرار گرفته‌است.

در ادامه انواع قسمت‌ها از سیستم حذف شده‌اند و نتایج در قالب جدول آورده شده‌است. مدل پایه، مدل تولید پاسخ بدون اجزای پروفایل کاربر اجرا و ارزیابی شده است که نشان می‌دهد چگونه هر عنصر پروفایل به عملکرد سیستم کمک می‌کند. این راه‌اندازی پایه یک سناریوی کنترلی را فراهم کرده است که امکان مقایسه مستقیم و ارائه بینش‌هایی در مورد اثربخشی اجزای پروفایل در افزایش کیفیت گفتگو و تعامل کاربر را فراهم می‌کند.

شکل ۱.۴ نشان‌دهنده پیکربندی مدل است.



```
chat_history_ids    loaded_model.generate(
    new_user_input_ids,
    max_length 500,
    pad_token_id tokenizer.eos_token_id,
    no_repeat_ngram_size 5,
    do_sample True,
    top_k 100,
    top_p 0.7,
    temperature 0.8,
).to(target_device)
```

شکل ۱.۴: پیکربندی مدل

^۱ablation study

آزمایش‌های فرعی جهت ارزیابی قسمت‌های مختلف دخیل در فرآیند پروفایل‌سازی کاربر به شرح زیر دسته‌بندی می‌شوند.

- بدون ماژول تحلیل معنایی
 - بدون فیلتر مشارکتی: صرف نظر از محاسبات شباهت و توصیه‌های مستقیم.
 - ورودی توکن کاهش/افزایش‌یافته: مقایسه کیفیت کار و پیشنهادهای تولیدی سیستم زمانی که بیشینه طول عبارت تولیدی توسط سیستم کاهش یا افزایش باید.
- در جدول ۱.۴ مقایسه تغییر مقادیر معیارهای ارزیابی معرفی شده با استفاده از مطالعات فرسایشی بر روی قسمت‌های مختلف سیستم آورده شده است.

جدول ۱.۴: مطالعه فرسایشی

معیارهای ارزیابی	Perplexity	Distinct-۱	Distinct-۲	SuccessRate	CompletionRate	UES	PDM
سیستم کامل	۸.۸۴	۰.۲۶	۰.۵۸	۹۱.۹۷	۹۳.۸۷	۹۱.۹۷	۹۴.۲۹
بدون تحلیل معنایی	۹.۵۰	۰.۲۲	۰.۵	۸۸	۹۰	۸۸	۹۱
بدون فیلتر مشارکتی	۹.۳۰	۰.۲۴	۰.۵۴	۸۹	۹۱	۸۹	۹۲.۵
کاهش طول خروجی مدل	۱۰.۲۰	۰.۱۸	۰.۴۵	۸۵	۸۸	۸۵	۸۹
بدون پروفایل کاربری	۱۱.۵۰	۰.۱۵	۰.۴	۸۰	۸۳	۸۰	۸۵

۱.۶.۴ تاثیر ماژول پروفایل کاربری بر رضایت کاربران

مشاهدات از مطالعات فرسایشی بخش پروفایل‌سازی کاربر به شرح زیر است.

۱.۱.۶.۴ ماژول تحلیل معنایی

همانطور که انتظار می‌رفت، حذف برجسب‌گذاری احساسات باعث کاهش امتیازهای معیارهای ارزیابی مرتبط به پروفایل کاربری شده‌است، زیرا نشانه‌های زمینه‌ای خاص ژانر یا برجسب از بین می‌رود.

معیار PDM زمانی که این مؤلفه حذف می‌شود، دقت و اثربخشی پروفایل را کاهش می‌دهد.

۲.۱.۶.۴ مازول فیلتر مشارکتی

با حذف مازول فیلتر مشارکتی مبتنی بر آیت‌م کاهش متوسط در میزان موفقیت و تکمیل قابل مشاهده است، زیرا توصیه‌های شخصی‌شده حذف می‌شوند. همچنین معیار PDM نشان‌دهنده کاهش جزئی به دلیل عدم وجود بینش مشترک بین پروفایل کاربر و نتایج تولیدشده توسط مدل است.

۳.۱.۶.۴ بدون هیچ گونه پروفایل کاربری

بالاترین گنجی و کمترین UES، که منعکس‌کننده شخصی‌سازی و تعامل ضعیف است. معیار PDM در پایین‌ترین حد خود قرار دارد که نشان‌دهنده حداقل مشارکت در پروفایل کاربری است.

۲.۶.۴ تاثیر کاهش طول پیشینه متن تولیدی توسط مدل

تخریب قابل توجه در معیارهای تمایز و موفقیت به دلیل زمینه محدود برای تولید پاسخ، که ناشی از اتکای مدل به داده‌های ورودی گسترده‌تر و تولید متن طولانی‌تر برای حفظ انسجام و ایجاد پاسخ‌های متنوع است. این نشان می‌دهد که کاهش طول ورودی، توانایی مدل را برای استفاده مؤثر از داده‌های پروفایل کاربر و تاریخچه گفتگو، و همچنین رایحه پیشنهاد در متن خروجی که برای تولید پاسخ‌های ظریف و شخصی‌شده حیاتی هستند، محدود می‌کند.

معیار PDM منعکس‌کننده تأثیر منفی گسترده‌تری بر تصمیمات پروفایل است.

۳.۶.۴ جمع‌بندی

ارزیابی‌های انجام‌شده نشان می‌دهد که چگونه تکنیک‌های پروفایل کاربر به طور مستقیم با برجسته‌کردن تأثیر آنها بر معیارهایی مانند PDM و UES به عملکرد سیستم کمک می‌کند. این تجزیه و تحلیل همچنین زمینه‌های بالقوه برای بهینه‌سازی، مانند پالایش اجزای فیلتر مشارکتی یا تجزیه و تحلیل معنایی را روشن می‌کند و در نتیجه راه را برای تعامل کاربر افزایش یافته و سیستم‌های گفتگوی قوی‌تر در آینده هموار می‌کند. ردیابی امتیاز PDM بینش بیشتری در مورد اثربخشی روش‌های پروفایل ارائه می‌دهد. این یافته‌ها بهینه‌سازی بیشتر سیستم گفتگو و بهبود رضایت کاربر را راهنمایی می‌کند.

۷.۴ نتایج نهایی و مقایسه با کارهای موجود

۱.۷.۴ نتایج نهایی

در این بخش با تاکید بر ایجاد یک سیستم گفتگوی شخصی با استفاده از تکنیک‌های تنظیم سریع و پروفایل کاربری، عملکرد سیستم را از طریق معیارهای مختلفی ارزیابی کردیم. که کیفیت پاسخ‌های تولیدشده، تعامل سیستم و رضایت کاربر را ارزیابی شده است.

روش‌شناسی در اینجا شامل استفاده از سیستم‌های گفتگوی وظیفه‌محور است که با تنظیم سریع بهبود یافته‌اند، جایی که مدل در طول زمان با ترجیحات کاربر سازگار می‌شود. برای ارزیابی عملکرد سیستم، مجموعه‌ای از معیارهای کلیدی را به کار می‌گیریم، از جمله:

نتایج نهایی و عملکرد روش پیشنهادی برای تمامی معیارهای کلیدی مورد ارزیابی در جدول ۲.۴ آمده است.


جدول ۲.۴: معیارهای ارزیابی و مقادیر آنها

مقدار	معیار
۸.۸۴	Perplexity
۰.۲۶	Distinct۱
۰.۵۸	Distinct۲
۹۱.۹۷%	SuccessRate
۹۳.۸۷%	CompletionRate
۹۱.۹۷	UES
۹۴.۲۹	PDM

۲.۷.۴ مقایسه با کارهای موجود

در این بخش، عملکرد روش پیشنهادی با کارهای موجود مقایسه شده است. از آنجایی که هیچ مرجعی وجود ندارد که شامل تمام معیارهای ارزیابی خاص ما باشد، مقایسه‌ها بر اساس معیارهای مشترک بین مقالات مختلف انجام شده است. به عبارت دیگر، هر مرجع تنها شامل بخشی از معیارهای ارزیابی است و ما عملکرد خود را با هر مرجع در معیارهای مربوطه مقایسه کرده‌ایم. مقایسه فوق در شکل ۲.۴ آمده است که در ادامه به طور جزئی‌تر مورد بحث قرار گرفته است.

۱. گیجی: گیجی روش پیشنهادی مقدار ۸.۸۴ است که کمتر از مدل بیان‌شده در مقاله [۱۷] با مقدار ۹.۵ و



شکل ۲.۴: مقایسه مقادیر معیارهای ارزیابی با کارهای موجود

همچنین کمتر از مقدار بیان‌شده در مقاله [۶] با مقدار ۳۶.۶۳ است، که نشان می‌دهد مدل در مقایسه با مقالات بیان‌شده در پیش‌بینی‌های خود اطمینان بیشتری دارد. این اختلاف می‌تواند به دلیل ماهیت خاص دامنه و بهبودهای انجام شده هنگام تنظیم سریع مدل باشد.

۲. معیار دیستینک-۱: امتیاز مدل بیان شده ۰.۲۶ است که با امتیاز گزارش شده در مقاله [۱۵] ۰.۲۳۱ مطابقت دارد. این نشان می‌دهد که مدل فوق نسبت به تعداد کل تک‌گرم‌ها، یونی‌گرام‌های منحصر به فرد بیشتری تولید می‌کند، که نشان‌دهنده تنوع واژگانی بالاتر در سطح یونی‌گرام است.

۳. معیار دیستینک-۲: مقاله [۱۵] در مقایسه با کار مدل بیان شده با امتیاز ۰.۵۸ دارای امتیاز کمی بالاتر ۰.۵۹۵ است. این نشان می‌دهد که مدل این مقاله نسبت به تعداد کل بای‌گرام‌ها، بای‌گرام‌های منحصر به فرد بیشتری تولید می‌کند که نشان‌دهنده تنوع واژگانی اندکی بالاتر در سطح بای‌گرام است.

۴. میزان موفقیت: میزان موفقیت در روش پیشنهادی ۹۱.۷۹ متفاوت از آنچه در InstructTODS ارائه شده است. مقاله «InstructTODS» مدل‌های زبان بزرگ برای سیستم‌های گفتگوی وظیفه‌محور انتها به انتها [۶] نرخ موفقیت را به عنوان معیاری از توانایی سیستم گفتگو برای دستیابی به هدف کاربر تعریف می‌کند. بر این اساس محاسبه می‌شود که آیا سیستم وظیفه درخواست‌شده توسط کاربر را با موفقیت انجام می‌دهد یا خیر. این مقاله مقدار نهایی ۷۸.۴۸ را برای میزان موفقیت خود ارائه داده است.

همچنین در [۱۳] این مقدار به صورت میانگین برابر با ۸۵.۱ محاسبه می‌شود.

برای معیارهایی مانند میزان موفقیت، که در آن آثار مختلف از تعاریف متفاوتی استفاده می‌کنند تفاوت در روش‌های محاسبه باید مورد توجه قرار گیرد، زیرا ما از یک تعریف سفارشی بر اساس تکمیل کار استفاده می‌کنیم، در حالی که InstructTOD ممکن است شامل عوامل اضافی باشد اما تعریف نهایی همه در حیطه به انجام رساندن وظیفه محول شده به سیستم گفتگوی یکسان است.

در ارزیابی فوق میزان موفقیت را بر اساس تعداد کارهایی که با موفقیت توسط سیستم انجام شده است، با توجه به تشخیص قصد و دقت پاسخ محاسبه می‌کنیم.

۳.۷.۴ ارزیابی انسانی

علاوه بر ارزیابی‌های انجام شده، یک ارزیابی انسان-هوش مصنوعی انجام شده است که در آن ده ارزیاب انسانی با روش پیشنهادی تعامل داشتند و در مورد جنبه‌های مختلف عملکرد سیستم بازخورد ارائه می‌کردند. در زیر نتایج آماری برای بازخورد انسانی آورده شده است.

ارزیابی انسانی به فرآیند ارزیابی خروجی‌های سیستم‌های توصیه از طریق قضاوت مستقیم انسانی اشاره دارد. این رویکرد به‌ویژه برای ارزیابی جنبه‌های کیفی توصیه‌ها، مانند ارتباط، انسجام، شخصی‌سازی و رضایت کاربر، که ممکن است معیارهای خودکار به‌طور کامل نتوانند از آن‌ها استفاده کنند، مهم است. ارزیاب‌های انسانی معمولاً توصیه‌ها را بر اساس معیارهای از پیش تعریف شده رتبه‌بندی یا رتبه‌بندی می‌کنند و بینش‌هایی را در مورد اینکه چقدر سیستم با انتظارات و نیازهای کاربر همسو می‌شود، ارائه می‌دهند.

برای مثال، در سیستم‌های توصیه مبتنی بر LLM، ارزیاب‌های انسانی ممکن است ارزیابی کنند که آیا آیتم‌های توصیه شده (مانند فیلم‌ها، محصولات یا مقالات) برای کاربر هدف مناسب، متنوع و جذاب هستند یا خیر [۱۰]. نتایج ارزیابی‌های انسانی انجام شده به همراه ارسال همان سوالات و پاسخ‌ها به مدل هوش مصنوعی جی‌پی‌تی ۳.۵ جهت انجام ارزیابی هوشمند و مقایسه آن در جدول ۳.۴ آورده شده است.

- گنجی: ارزیابی انسان برای گنجی تقریباً با نتایج مدل هوش مصنوعی یکسان است. این نشان می‌دهد که پاسخ‌های این مدل برای انسان‌ها به همان اندازه که برای خود سیستم هوش مصنوعی گنجی‌کننده است.
- دیستینیک ۱ و ۲: هر دو معیار بین ارزیابی‌های انسان و هوش مصنوعی سازگار هستند، که نشان می‌دهد این مدل پاسخ‌های مشابهی را در تعاملات انسانی ایجاد می‌کند که در ارزیابی‌های هوش مصنوعی انجام می‌دهد.

جدول ۳.۴: مقایسه نتایج ارزیابی انسان و مدل

معیارها	ارزیابی انسان	ارزیابی هوش مصنوعی
Perplexity	۱۳.۴۹	۱۳.۰۹
Distinct۱	۰.۲۹	۰.۲۹
Distinct۲	۰.۶۰	۰.۶۰
SuccessRate	۸۴.۴۲	۸۵.۲۹
CompletionRate	۹۴.۱۹	۹۳.۸۹
UES	۷۹.۵۷	۸۵.۲۹

- میزان موفقیت: میزان موفقیت در ارزیابی انسانی در مقایسه با نتایج مدل هوش مصنوعی کمی کمتر است. این اختلاف را می‌توان به ماهیت ذهنی ارزیابی انسانی نسبت داد، جایی که کاربران ممکن است همیشه در مورد تکمیل کامل یک کار به توافق نرسند.
- نرخ تکمیل: میزان تکمیل در هر دو ارزیابی تقریباً یکسان است، با یک تفاوت بسیار کوچک، که نشان می‌دهد سیستم در هر دو ارزیابی پاسخ‌های منسجم و کاملی را ارائه می‌دهد.
- امتیاز تعامل کاربر: در ارزیابی انسانی در مقایسه با هوش مصنوعی به طور قابل توجهی کمتر است. این اختلاف ممکن است منعکس‌کننده تفاوت در نحوه درک ارزیابی‌های انسانی از کیفیت تعامل در مقابل ارزیابی داخلی مدل هوش مصنوعی باشد.

بازخورد انسانی نشان می‌دهد که در حالی که مدل هوش مصنوعی در ایجاد پاسخ‌ها عملکرد خوبی دارد، تفاوت‌های ظریفی در نحوه درک انسان از اثربخشی سیستم، به ویژه در مورد تعامل کاربر وجود دارد. این بینش، پیشرفت‌های آینده را در افزایش توانایی سیستم برای تعامل مؤثرتر با کاربران راهنمایی می‌کند.

۴.۷.۴ رابط کاربری برای ارزیابی انسانی

برای ارزیابی اثربخشی سیستم گفتگوی وظیفه‌محور و جمع‌آوری بازخورد انسانی، یک رابط کاربری مبتنی بر اپلیکیشن موبایل نیز توسعه داده شد. این رابط کاربری برای تقلید از سناریوهای دنیای واقعی طراحی شده است که در آن کاربران با سیستم‌های توصیه‌ای تعامل دارند و به آنها اجازه می‌دهد:

- ثبت ژانرهای مورد علاقه: برای همه کاربران به‌ویژه برای کاربران تازه‌وارد، امکان انتخاب ژانرهای مورد علاقه فراهم است.

- ارسال پرسش‌ها: کاربران عبارت‌های زبان طبیعی را وارد می‌کنند، مانند «آیا می‌توانید یک فیلم اکشن توصیه کنید؟»
- دریافت پاسخ‌ها: سیستم توصیه‌های سریع تنظیم‌شده متناسب با پرس‌وجو و نمایه کاربر را ارائه می‌دهد.
- ارائه بازخورد: کاربران می‌توانند با انتخاب یکی از سه گزینه به پاسخ‌ها واکنش نشان دهند: «پسندیدن»، «نپسندیدن» یا «خنثی».

هدف اولیه رابط کاربری ارزیابی عملکرد سیستم از نظر موارد زیر بود:

- ارتباط و انسجام: توسط بازخورد کاربر در مورد پاسخ‌های فردی ارزیابی می‌شود.
 - تعامل و رضایت: از طریق تعاملات مکرر و ورودی کیفی کاربر اندازه‌گیری می‌شود.
 - تنوع پاسخ: با مشاهده واکنش کاربران به ژانرها یا سبک‌های مختلف پاسخ‌ها ارزیابی می‌شود.
- این رابط همچنین ثبت تمام تعاملات کاربر را تسهیل کرد و یک مجموعه داده حیاتی را برای ارزیابی انسانی تشکیل داد. این مجموعه، داده برای محاسبه معیارهایی مانند امتیاز تعامل کاربر و میزان موفقیت و اعتبارسنجی معیارهای خودکار استفاده شد.
- یک نمونه از این رابط کاربری مطابق با شکل ۳.۴ است.

۸.۴ نتیجه‌گیری


در این فصل، به طور سیستماتیک مجموعه داده‌های مورد استفاده برای آموزش و ارزیابی مدل را با تمرکز اولیه روی مجموعه داده‌های مووی لنز مورد بررسی قرار گرفت.

این مجموعه داده‌های غنی و متنوعی از تعاملات کاربران ارائه می‌دهد که مبنایی برای کارهای شخصی‌سازی و توصیه‌ها را تشکیل می‌دهد. ویژگی‌های مجموعه داده‌ها، از جمله رتبه‌بندی‌های کاربر، ژانرهای فیلم، و مهرهای زمانی را که برای ایجاد نمایه‌های دقیق کاربر ضروری بودند، به تفصیل شرح داده شدند.

مجموعه داده‌های آزمایشی به دقت تنظیم شدند تا عملکرد مدل را تحت سناریوهای واقعی ارزیابی کنند و از مقایسه منصفانه و قابل اعتماد نتایج اطمینان حاصل کنند. علاوه بر این، این فصل در مورد پیکربندی ابرپارامتر که برای افزایش کارایی مدل، از جمله نرخ یادگیری به خوبی تنظیم شده بودند، توضیح داده شد.

نتایج با استفاده از معیارهایی مانند گنجی، تمایز، میزان موفقیت، میزان تکمیل و امتیاز تعامل کاربر و همچنین معیارهای مرتبط به طور مستقیم با پروفایل کاربری مانند دقت توصیه شخصی و تطابق تنوع نمایه ارزیابی شدند.

این معیارها نقاط قوت و محدودیت‌های مدل را برجسته می‌کنند و نمای شفاف‌تری از عملکرد آن در ابعاد مختلف ارائه می‌دهند. تجزیه و تحلیل حساسیت بیشتر استحکام مدل را در برابر تغییرات در پارامترهای کلیدی نشان داد و بر سازگاری و قابلیت اطمینان آن در محیط‌های پویا تأکید کرد. این فصل چارچوب آزمایش و ارزیابی دقیق را در بر می‌گیرد که از نتیجه‌گیری‌ها و بینش‌های گسترده‌تر ارائه شده در این تحقیق پشتیبانی می‌کند. روش پیشنهادی در بسیاری از زمینه‌ها خوب عمل می‌کند، اما فضایی برای بهبود، به ویژه در تعامل با کاربر، همانطور که توسط ارزیابی انسان-هوش مصنوعی برجسته شده است، نشان می‌دهد.



شکل ۳.۴: رابط کاربری طراحی شده

فصل ۵

جمع بندی و پیشنهادهایی برای ادامه پژوهش

۱.۵ مقدمه

در این پژوهش به بررسی و بهبود سیستم‌های گفتگوی وظیفه‌محور پرداخته شده است. این سیستم‌ها دارای چالش‌هایی در زمینه شخصی‌سازی، نمایه‌سازی کاربر، رفع مشکل شروع سرد و در عین حال تضمین حریم خصوصی از طریق رعایت حق فراموشی هستند که مورد بررسی قرار گرفته‌اند. با استفاده از تکنیک‌هایی مانند تنظیم سریع، فیلتر مشارکتی، و پروفایل پویا کاربری، پیشرفت‌های قابل توجهی از نظر دقت سیستم، سازگاری و رضایت کاربر به دست آمد. اهداف اصلی این پژوهش شامل موارد زیر است.

- بهبود شخصی‌سازی در سیستم‌های گفتگو
- حل مشکل شروع سرد برای کاربران تازه وارد
- ادغام حق فراموشی و حفظ حریم خصوصی کاربران
- افزایش سازگاری با دامنه‌های جدید

برای دستیابی به این اهداف، از تکنیک‌های مانند تنظیم سریع، فیلتر مشارکتی و پروفایل پویا کاربری استفاده شده است. این رویکردها منجر به پیشرفت در دقت سیستم، سازگاری و رضایت کاربر شده‌اند.

۲.۵ روش پیشنهادی

روش پیشنهادی در این پژوهش به طور خاص بر سه محور اصلی تمرکز دارد: شخصی‌سازی، حل مشکل شروع سرد، و حفظ حریم خصوصی. این رویکرد با استفاده از تکنیک‌هایی مانند تنظیم سریع، فیلتر مشارکتی مبتنی بر آیتم، و تحلیل احساسات، عملکرد سیستم گفتگوی وظیفه‌محور را بهبود بخشیده است.

• شخصی‌سازی

سیستم می‌تواند با استفاده از پروفایل کاربری پویا و تنظیم سریع، پاسخ‌ها را بر اساس ترجیحات و تعاملات قبلی کاربر تنظیم کند. این رویکرد به سیستم اجازه می‌دهد تا با حداقل میزان داده، به سرعت با نیازهای کاربر سازگار شود و پاسخ مناسب را ایجاد کند.

• حل مشکل شروع سرد

علاوه بر دریافت اطلاعات مورد نیاز برای ایجاد یک پروفایل کاربری اولیه برای کاربران تازه‌وارد، سیستم با استفاده از فیلتر مشارکتی مبتنی بر آیتم، قادر است برای کاربران جدید توصیه‌های دقیق و مرتبط با سلاقی آن‌ها ارائه دهد. این رویکرد با استفاده از داده‌های کاربران مشابه، شکاف اطلاعاتی را برای کاربران جدید پر می‌کند.

• حفظ حریم خصوصی

سیستم با اجرای حق فراموشی، به کاربران اجازه می‌دهد داده‌های خود را حذف کنند، بدون اینکه عملکرد کلی سیستم تحت تأثیر قرار گیرد. این ویژگی اعتماد کاربر را افزایش داده و با قوانین جهانی حفظ حریم خصوصی هماهنگ می‌شود.

۳.۵ نوآوری و دستاوردهای پژوهش

این پژوهش با ارائه ادغام روش‌ها و تکنیک‌های نوآورانه، شکاف‌هایی را در توسعه سیستم‌های گفتگوی وظیفه‌محور پر کرده است. زیرا به طور خاص به چالش‌هایی در زمینه شخصی‌سازی، سازگاری، و رعایت حریم خصوصی پرداخته است. در ادامه به بررسی نوآوری‌ها و مشارکت‌های اصلی پرداخته می‌شود.

۱.۳.۵ پیشرفت در شخصی‌سازی

• تولید دیالوگ تطبیقی:

ارتقای سیستم گفتگوی وظیفه‌گرا از طریق تنظیم سریع و پروفایل‌سازی کارفصل ۵: جمع‌بندی و پیشنهادهایی برای ادامه پژوهش

سیستم گفتگو با ترکیب ترجیحات کاربر مانند ژانرهای مورد علاقه، تعاملات گذشته و ویژگی‌های خاص زمینه، پاسخ‌های خود را به صورت پویا تنظیم می‌کند. به عنوان مثال کاربرانی که فیلم‌های علمی تخیلی را ترجیح می‌دهند، توصیه‌ها و تعاملات غنی‌شده با زبان مرتبط را دریافت کردند که به طور قابل‌توجهی امتیاز تعامل آنها را بهبود بخشید.

همچنین نمرات گیجی و تمایز بهبودیافته تعادل بین ارتباط و تنوع پاسخ را نشان می‌دهد.

• تنظیم سریع برای شخصی‌سازی:

این رویکرد اجازه کنترل دقیق بر پاسخ‌های سیستم را بدون آموزش مجدد کل مدل می‌دهد. همچنین با استفاده از این روش می‌توان به قابلیت‌های یادگیری چند شات دست یافت و سیستم را قادر ساخت حتی با داده‌های محدود به خوبی تعمیم یابد. استفاده از این روش، از روش‌های تنظیم دقیق سنتی با کاهش سربار محاسباتی و در عین حال حفظ تعاملات با کیفیت بالا و مرتبط با زمینه، عملکرد بهتری داشت.

۲.۳.۵ حل مشکل شروع سرد

سیستم با استفاده نوآورانه از فیلتر مشارکتی تعاملات اولیه با کاربران با استفاده از فیلتر اشتراکی مبتنی بر آیتم را افزایش داده‌ها از کاربران مشابه برای شخصی‌سازی به طرز محسوسی افزایش یافت. در نتیجه سیستم به طور موثر مشکل شروع سرد را برطرف کرد و توصیه‌های دقیق و تعاملات معناداری را برای کاربران جدید ارائه کرد.

۳.۳.۵ ادغام حق فراموشی و حریم خصوصی

این سیستم نگرانی‌های فزاینده در مورد حفظ حریم خصوصی در حوزه‌های داده‌ها را از طریق رعایت حق فراموشی برطرف کرد. هوش مصنوعی اخلاقی به معنای طراحی، توسعه و استفاده از سیستم‌های هوش مصنوعی به گونه‌ای است که اصول اخلاقی، حقوق بشر، شفافیت، عدالت و پاسخگویی را رعایت کند. این رویکرد هدفمند، تمرکز خاصی بر کاهش خطرات احتمالی و افزایش فواید هوش مصنوعی برای جامعه دارد. برای مثال، در حوزه‌هایی مانند سیستم‌های توصیه‌گر، اخلاق هوش مصنوعی شامل احترام به حریم خصوصی کاربران، اطمینان از عدم تبعیض الگوریتمی و اعمال حق فراموشی (حق کاربر بر حذف داده‌های شخصی) می‌شود [۴].

حذف پویا اطلاعات کاربر مکانیسم‌هایی را برای کاربران به منظور درخواست حذف داده‌های خود پیاده‌سازی کرده است، که از عدم وجود اثر باقی‌مانده در پروفایل‌های کاربر یا سیستم‌های فیلتر مشترک اطمینان حاصل می‌کند. این ویژگی اعتماد کاربر را افزایش داد و با قوانین حفظ حریم خصوصی جهانی هماهنگ شد و معیاری

ارتقای سیستم گفتگوی وظیفه‌گرا از طریق تنظیم سریع و پروفایل‌سازی کارفصل ۵: جمع‌بندی و پیشنهادهایی برای ادامه پژوهش

برای سیستم‌های هوش مصنوعی اخلاقی تعیین کرد. علیرغم حذف داده‌های کاربر، تنظیم سریع و یادگیری چند شات به سیستم اجازه می‌دهد تا عملکرد بالایی را بدون اتکا به داده‌های تاریخی حفظ کند.

۴.۳.۵ سازگاری با دامنه‌های جدید

انعطاف‌پذیری در استفاده از پایگاه دانش برای سیستم فوق نیز قابل بیان است. می‌توان از قابلیت انطباق مدل‌های زبانی با هر پایگاه دانشی استفاده کرد و از ارتباط سیستم در حوزه‌های مختلف اطمینان حاصل کرد. در صورت وجود دیتاست مرتبط با هر حوزه، سیستم را می‌توان به راحتی به برنامه‌های کاربردی خدمات مشتری، مراقبت‌های بهداشتی و تجارت الکترونیک گسترش داد. همچنین تکنیک‌های شروع سرد و آموزش چندشات، سیستم را قادر می‌سازد حتی در سناریوهایی که قبلاً دیده نشده بود یا با حداقل داده‌های مربوط به کار، به خوبی عمل کند و نیاز به بازآموزی گسترده را به حداقل برساند.

۵.۳.۵ زمینه‌های فراگیر

- رضایت و تعامل کاربر
شخصی‌سازی و رعایت حریم خصوصی به طور جمعی رضایت کاربر را افزایش می‌دهد، همانطور که با نمرات تعامل بالاتر مشهود است. تعادل بین حریم خصوصی و عملکرد استاندارد جدیدی را برای سیستم‌های هوش مصنوعی در حوزه‌های تنظیم‌شده ایجاد می‌کند.
- مقیاس‌پذیری
ماهیت سبک تنظیم سریع مقیاس‌پذیری را در دستگاه‌های با قدرت محاسباتی محدود تضمین می‌کند و این رویکرد را برای مخاطبان گسترده‌تری قابل دسترسی می‌سازد.
- حفظ حریم خصوصی
گنجاندن انطباق با حق فراموشی، همسویی سیستم را با شیوه‌های هوش مصنوعی اخلاقی برجسته می‌کند و به مسائل مربوط به اعتماد کاربر که اغلب در سیستم‌های گفتگوی وظیفه‌محور سنتی نادیده گرفته می‌شوند، می‌پردازد.

۴.۵ مشارکت و نوآوری

این رساله از سیستم‌های گفتگوی وظیفه‌محور، با تمرکز بر شخصی‌سازی، شروع سرد و حفظ حریم خصوصی، در حالی که از تکنیک‌های نوآورانه مانند تنظیم سریع و ساخت پروفایل کاربری با استفاده از تکنیک‌هایی مانند فیلتر مشارکتی مبتنی بر آیتم و تحلیل احساسات استفاده می‌کند. در زیر یک طرح کلی ساختار یافته از مشارکت‌ها و جنبه‌های بدیع این تحقیق آورده شده است.

۱.۴.۵ مشارکت‌های اصلی

۱.۱.۴.۵ شخصی‌سازی در سیستم‌های گفتگو

- پروفایل کاربری پویا:
یک چارچوب جدید برای ایجاد و حفظ نمایه‌های کاربر پویا با استخراج اولویت‌ها (مانند ژانرهای برتر، فیلم‌های پسندیده) از تعاملات ایجاد شد.
در نتیجه سیستم پاسخ‌ها را در زمان واقعی تطبیق داده و تعامل و رضایت کاربر را بهبود می‌بخشد.
برخلاف سیستم‌های شخصی‌سازی ایستا یا مبتنی بر قانون، این رویکرد یادگیری و سازگاری مداوم را امکان‌پذیر می‌کند که پروفایل هرکاربر به مرور و با تعامل با برنامه به‌روز شود.
- تعاملات آگاه از زمینه:
استفاده از تنظیم سریع امکان ادغام بلادرنگ زمینه کاربر (به عنوان مثال، ترجیحات، تاریخچه هر گفتگو) را در پاسخ‌های سیستم فراهم می‌کند. با اتکا به این روش افزایش ارتباط و انسجام در گفتگو ایجاد شده است که با نرخ موفقیت بالاتر و معیارهای تعامل این پیشرفت نشان داده شده است.
- پرداختن به مشکل شروع سرد:
این سیستم علاوه بر ژانرهای دریافتی مورد علاقه کاربر نوپا، فیلتر مشارکتی مبتنی بر آیتم را برای مدیریت مشکل شروع سرد با استفاده از داده‌های کاربران مشابه پیاده‌سازی کرده است.
این رویکرد با موفقیت شکاف را برای کاربران جدید پر می‌کند و از تعاملات معنی‌دار حتی با حداقل داده‌های اولیه اطمینان حاصل می‌کند. این عملکرد جهت حل مشکل شروع سرد در سیستم نشان می‌دهد که فیلتر کردن مشارکتی می‌تواند فراتر از سیستم‌های توصیه‌گسترش یابد تا شخصی‌سازی گفتگو را بهبود بخشد.

- آموزش چند شات:

این تکنیک‌ها را برای مدیریت مؤثر سناریوهای نادیده، به حداقل رساندن نیاز به داده‌های گسترده و ویژه کار، به کار گرفت. به همین علت امکان استقرار سریع سیستم‌های گفتگو در حوزه‌های جدید بدون آموزش مجدد فراهم آمده است.

۲.۱.۴.۵ حریم خصوصی و هوش مصنوعی اخلاقی

- حق فراموش شدن:

در این رساله مکانیسم‌هایی برای انطباق با حق فراموشی استفاده شد که به کاربران اجازه می‌دهد بدون تأثیر بر عملکرد سیستم، درخواست حذف داده‌های خود را داشته باشند.

این یکی از پیاده‌سازی‌های سیستم‌های گفتگوی وظیفه محور است که انطباق حق فراموشی را با حفظ عملکرد عملیاتی می‌کند. با ایجاد این مهم، اعتماد کاربر جهت استفاده از سیستم افزایش یافته و با قوانین جهانی حفظ حریم خصوصی داده‌ها هماهنگ می‌شود.

- متعادل کردن حریم خصوصی و شخصی سازی:

روش‌های توسعه‌یافته برای ایجاد تعادل بین حریم خصوصی و شخصی‌سازی با اطمینان از اینکه داده‌های کاربر حذف شده عملکرد کلی سیستم را به خطر نمی‌اندازد. این تعادل امکان شخصی‌سازی حفظ حریم خصوصی در سیستم‌های هوش مصنوعی را در کنار قابلیت شخصی‌سازی کردن نتایج نشان داد.

۳.۱.۴.۵ معیارها و چارچوب ارزیابی

معیارهای ارزیابی جامع:

یک چارچوب ارزیابی قوی با استفاده از گنجی، تمایز، میزان موفقیت، میزان تکمیل کار، امتیاز تعامل کاربر و همچنین دقت توصیه شخصی و تطابق تنوع نمایه معرفی شدند. معیارهای فوق مجموعه ای جامع از معیارها را معرفی کرد که به طور خاص برای ارزیابی سیستم‌های گفتگوی وظیفه محور شخصی سازی شده و سازگار طراحی شده است. این معیارها روشی استاندارد برای ارزیابی عملکرد سیستم‌های گفتگوی وظیفه محور فراتر از معیارهای سنتی ارائه می‌کند.

۴.۱.۴.۵ تکنیک‌ها و روش‌های بدیع

- تنظیم سریع به عنوان یک روش اصلی:

یک جایگزین سبک وزن و در عین حال قدرتمند برای تنظیم دقیق، تنظیم سریع برای دستیابی به شخصی‌سازی و سازگاری محوری بود.

استفاده از این روش، کارآمدی تنظیم سریع در تنظیم پویا دیالوگ‌ها بدون متحمل شدن هزینه‌های محاسباتی بالا را به نمایش گذاشت. همچنین تنظیم سریع به عنوان یک رویکرد قابل دوام برای سیستم‌های گفتگوی وظیفه محور ایجاد شد.

- رویکرد ترکیبی برای شخصی‌سازی:

ترکیبی از پروفایل کاربری، فیلترکردن مشارکتی و مدل‌های زبانی برای ایجاد یک سیستم ترکیبی که از نقاط قوت هر جزء استفاده می‌کند. این ترکیب روش‌ها و نتایج ارزیابی به خوبی نشان داد که چگونه مدل‌های ترکیبی می‌توانند از رویکردهای مستقل در شخصی‌سازی و رضایت کاربر بهتر عمل کنند.

- ادغام هوش مصنوعی اخلاقی:

به نگرانی‌های مربوط به حریم خصوصی و اخلاقی از طریق راه‌حل‌های نوآورانه پرداخته و استاندارد جدیدی برای شیوه‌های هوش مصنوعی اخلاقی در سیستم‌های گفتگو ایجاد می‌کند.

این تحقیق با پرداختن به چالش‌های قدیمی در شخصی‌سازی، سازگاری و رعایت حریم خصوصی، شکاف‌های حیاتی در توسعه سیستم‌های گفتگوی وظیفه‌محور را پر می‌کند. همچنین یک نقشه راه برای ادغام شیوه‌های هوش مصنوعی اخلاقی در سیستم‌های گفتگو ارائه کرد و تنظیم سریع به عنوان یک تکنیک اصلی برای سیستم‌های تطبیقی و مقیاس‌پذیر ایجاد شد.

۵.۵ نتایج پژوهش

۱.۵.۵ بهبود شخصی‌سازی

روش پیشنهادی با استفاده از پروفایل‌های کاربری پویا، توانست به طور مداوم ترجیحات کاربر را از تعاملات استخراج کند و پاسخ‌ها را در زمان واقعی تنظیم کند. این رویکرد منجر به افزایش رضایت کاربر شد، که با نمرات تعامل بالاتر مشهود از این بهبود است.

همچنین با استفاده از تنظیم سریع به عنوان یک جایگزین سبک‌وزن برای تنظیم دقیق، عملکرد سیستم بهبود بخشید شد. این روش به سیستم اجازه داد تا حتی با داده‌های محدود، پاسخ‌های دقیق و مرتبط ارائه دهد. نتایج نشان داد که تنظیم سریع می‌تواند هزینه‌های محاسباتی را کاهش دهد، در حالی که کیفیت تعاملات حفظ شود.

ارتقای سیستم گفتگوی وظیفه‌گرا از طریق تنظیم سریع و پروفایل‌سازی کارفصل ۵: جمع‌بندی و پیشنهادهایی برای ادامه پژوهش

ترکیب فیلتر مشارکتی مبتنی بر آیتم و تحلیل احساسات منجر به تولید پاسخ‌هایی شد که نه تنها دقیق، بلکه غنی از تنوع واژگانی بودند. این ترکیب به طور قابل توجهی معیارهای تمایز ۰.۲۶ برای دیستینکت-۱ و ۰.۵۸ برای دیستینکت-۲ را بهبود بخشید.

۲.۵.۵ حل مشکل شروع سرد

سیستم با استفاده از فیلتر مشارکتی مبتنی بر آیتم، مشکل شروع سرد را به طور مؤثری تری حل کرده است. این رویکرد از داده‌های کاربران مشابه برای ارائه توصیه‌های دقیق به کاربران جدید استفاده کرد. نتایج نشان داد که این روش توانست نرخ موفقیت کار را برای کاربران تازه‌وارد بهبود بخشد و تعاملات معناداری را از همان ابتدا ایجاد کند.

۳.۵.۵ ارزیابی جامع

معیارهای ارزیابی مختلفی مورد بحث قرار گرفت. این سیستم با استفاده از معیارهایی مانند گیجی، تمایز، میزان موفقیت، نرخ تکمیل کار و میزان درگیری کاربر مورد ارزیابی قرار گرفت.

- گیجی: مقدار گیجی ۸.۸۴ نشان داد که روش پیشنهادی توانست پاسخ‌های منسجم و مرتبط با زمینه تولید کند. این مقدار کمتر از مدل‌های موجود در مقالات مشابه است، که نشان‌دهنده اطمینان بیشتر مدل در پیش‌بینی‌ها است.

- تمایز: مقادیر تمایز ۰.۲۶ برای دیستینکت-۱ و ۰.۵۸ برای دیستینکت-۲ نشان داد که روش پیشنهادی قادر است پاسخ‌هایی با تنوع واژگانی بالاتر تولید کند. این نتیجه حاصل ترکیب فیلتر مشارکتی و تحلیل احساسات است.

- امتیاز تعامل کاربر: امتیاز تعامل کاربر ۹۱.۹۷ نشان داد که کاربران از تعامل با سیستم رضایت داشتند. این نتیجه به طور مستقیم ناشی از شخصی‌سازی و رعایت حریم خصوصی بود که با انطباق پویای پروفایل‌های کاربر و نرخ تکمیل کار بهبود یافته است.

- میزان موفقیت کار: در میان پرس‌وجوهای مختلف، این سیستم در مقایسه با سیستم‌های گفتگوی وظیفه‌محور ذکر شده، هشت الی هفده درصد پیشرفت در موفقیت کار به دست آورد. تجربه کاربری شخصی‌سازی شده به طور قابل توجهی به این موفقیت کمک کرد.

- نرخ تکمیل کار: نرخ تکمیل کار ۹۳.۸۷ نشان داد که سیستم توانست تعاملات کاربر را به طور کامل مدیریت کند و به اهداف کاربر برسد.

۶.۵ پیشنهادهایی برای تحقیقات آینده

این بخش مسیرهای بالقوه‌ای را برای کاوش بیشتر، بر اساس مبانی و یافته‌های این تحقیق بیان می‌کند. پیشنهادها زیر زمینه‌هایی را برای بهبود، گسترش و نوآوری در سیستم‌های گفتگوی وظیفه‌محور، شخصی‌سازی و هوش مصنوعی اخلاقی برجسته می‌کنند.

۱.۶.۵ پیشبرد تکنیک‌های شخصی‌سازی

۱.۱.۶.۵ پروفایل کاربری پیشرفته

- پروفایل کاربری عمیق

تحقیقات آینده می‌تواند تکنیک‌های پیچیده‌تر پروفایل‌سازی کاربر را بررسی کند، و همچنین با بهره‌بردن از داده‌های چندوجهی مانند صدا، ویدیو یا فعالیت رسانه‌های اجتماعی کاربر، درک بهتری از ترجیحات کاربر ایجاد کند. با استفاده از این روش‌ها شخصی‌سازی برای هر کاربر را فراتر از داده‌های صرفاً متنی خواهد برد و نتیجه را بهبود می‌بخشد.

- ترجیحات زمانی و متنی

علاوه بر جنبه‌های متنوع پروفایل کاربری می‌توان از اینکه چگونه ترجیحات کاربر در طول زمان تغییر می‌کند یا بر اساس زمینه‌های موقعیتی متفاوت است نیز جهت بهبود و ارتقای پروفایل کاربری استفاده کرد. به عنوان مثال باید مدل‌های پویا را پیاده‌سازی کرد که از رفتار کاربر در بازه‌های زمانی مختلف یا در طول سناریوهای خاص یاد می‌گیرند و ترجیحات وی را به‌روز می‌کنند.

۲.۱.۶.۵ فیلتر مشارکتی و ترکیبی

می‌توان با کاوش روش‌های ترکیبی که فیلتر مشارکتی را با مدل‌های مبتنی بر یادگیری عمیق ترکیب می‌کند، مشکلات شروع سرد را به طور مؤثرتری مدیریت کرد. به عنوان مثال می‌توان با استفاده از تکنیک‌های مبتنی بر نمودار ارتباطات پنهان بین کاربران و آیتم‌ها را به طور مؤثرتر و بهتر شناسایی کرد.

۲.۶.۵ گسترش چارچوب‌های ارزیابی

- معیارهای جدید

همچنین می‌توان با تعریف معیارهای جدید، اندازه‌گیری میزان درک و پاسخ سیستم به احساسات کاربر را بیشتر و بهتر بررسی کرد. به عنوان مثال تعریف امتیاز درگیری عاطفی بر اساس احساسات و حالات عاطفی در پاسخ‌ها که سیستم با توجه به حال عاطفی کاربر پاسخ‌های متناسب به وی بدهد.

- معیارهای خاص دامنه

معیارهای ارزیابی برای حوزه‌های خاص (به عنوان مثال، دقت برای توصیه‌های پزشکی، ارتباط با توصیه‌های فیلم). در کارهای آتی می‌توان به تاثیر عمیق معیارهای دامنه خاص بر رضایت کاربر تمرکز کرد و آنرا بهبود داد.

۳.۶.۵ یکپارچه سازی مدل‌های پیشرفته

- ارتقاء مدل زبانی

با گنجاندن مدل‌های زبانی پیشرفته‌تر که پتانسیل آن‌ها را برای درک بهتر، تولید و شخصی‌سازی بیشتر است به طور حتمی نتایج بهتری در پی خواهد بود. ولی چالش استفاده از این مدل‌های زبانی حفظ تعادل هزینه محاسباتی با بهبود عملکرد سیستم خواهد بود.

- ادغام چندوجهی

ترکیب روش واکاوی متن با سایر روش‌های سیستم‌های توصیه مانند دیالوگ‌های مبتنی بر تصاویر، صدا و ویدئو برای تعاملات بیشتر با کاربر نیز می‌تواند جزو کارهای آتی قرار بگیرد. به عنوان مثال توصیه فیلم‌های دارای تریلر یا صحنه بر اساس ترجیحات کاربر می‌تواند در ارائه پیشنهادهای بهتر به کاربر موثر باشد.

پیشنهادهای ذکر شده در بالا، پتانسیل قابل توجهی را برای توسعه بیشتر در سیستم‌های گفتگوی وظیفه‌محور، شخصی‌سازی و همچنین حفظ حریم خصوصی نشان می‌دهد. با کاوش در آن‌ها، محققان آینده می‌توانند بر روی این کار برای افزایش رضایت کاربر، سازگاری سیستم و استقرار هوش مصنوعی اخلاقی کار کنند.

۷.۵ محدودیت‌ها و چالش‌ها

این بخش به طور انتقادی محدودیت‌ها و مشکلاتی را که در طول توسعه و ارزیابی سیستم گفتگوی وظیفه‌محور با نمایه‌های شخصی‌شده و تنظیم سریع مواجه می‌شود، بررسی می‌کند. محدودیت‌ها حوزه‌هایی را برجسته می‌کنند که بر نتایج تأثیر گذاشتند و بینش‌هایی را در مورد چالش‌هایی که باید برای بهبود بیشتر مورد توجه قرار گیرند، ارائه می‌دهند.

۱.۷.۵ محدودیت داده‌ها

محدودیت‌های مجموعه داده به شرح زیر است.

- تولید داده‌های سفارشی

به دلیل عدم وجود مجموعه داده‌های مکالمه‌ای که از قبل برای توصیه‌های فیلم طراحی شده‌اند، زمان و تلاش قابل توجهی برای ایجاد مجموعه‌ای که داده‌های مکالمه را تقلید می‌کند، صرف شد. داده‌های تولید شده، اگرچه مؤثر هستند، ممکن است فاقد تنوع و عمق مکالمات در دنیای واقعی باشند به دلیل آنکه در نهایت این مکالمات ساختی و با استفاده از قالب و الگوهای از پیش تعیین‌شده هستند که نمی‌توانند با تنوع مکالمات واقعی مقایسه گردد. با بهبود و ارتقای این مجموعه داده، پاسخ‌های متنوع‌تر و با ترکیب کلمات بهتر ایجاد خواهد شد.

- حجم داده محدود برای تنظیم دقیق

حجم داده‌های تولیدشده برای تنظیم دقیق مدل زبانی در مقایسه با مقیاس داده‌های مورد استفاده برای آموزش مدل‌های زبانی بزرگ محدود بود و همین باعث کاهش تعمیم‌پذیری و سازگاری مدل و عدم اجرای عملیات تنظیم دقیق بر روی مدل شده است.

۲.۷.۵ محدودیت‌های محاسباتی

برای استفاده از مدل‌های زبانی آموزش آنها و اجرای تکنیک‌های مختلف، سخت‌افزار عضو جدایی ناپذیر از این عملیات است.

- محدودیت‌های منابع سخت افزاری

اتکا به پردازنده‌های گرافیکی، اندازه مدل، اندازه دسته‌ای و تکرارهای آموزشی را محدود می‌کرد. به عنوان مثال به دلیل داشتن منابع سخت‌افزاری محدودتر، اجبار به استفاده از مدل‌های زبانی با پارامترهای کمتر به جای مدل‌های پیشرفته‌تر مانند جی‌پی‌تی ۴ باعث عدم دسترسی به نتایج بهتر شد.

- محدودیت‌های زمانی

چرخه‌های تمرین و تنظیم دقیق به دلیل محدودیت‌های زمانی غیرعملی بود که بر بهینه‌سازی و آزمایش‌های پارامتر تأثیر گذاشت.

۳.۷.۵ چالش‌های پروفایل کاربری

- مشکل شروع سرد

برای کاربرانی که تازه با سیستم شروع به کار می‌کنند، داده‌های تاریخی محدود است و می‌بایست توصیه‌های شخصی‌سازی شده را در ابتدا دقیق‌تر کرد تا برای این دسته کاربران نیز نتایج قابل قبولی ارائه شود. با استفاده از فیلتر مشارکتی و استفاده از اولویت‌های پیش‌فرض ژانر تا حدی این مشکل را برطرف شد.

- تحول تنظیمات کاربر در مرور زمان اگر در سیستم اعمال نشود باعث کاهش رضایت کاربر خواهد شد. تکنیک‌های پروفایل پویا برای انطباق با تغییر سلیقه کاربر در طول زمان تلاش کردند تا به حل این مشکل بیایند. لذا با ترکیب مدل‌های پروفایل کاربر پویا با قابلیت‌های یادگیری افزایشی و دریافت بازخورد مناسب از کاربر و به‌روزرسانی ترجیحات وی می‌توان از این مشکل جلوگیری کرد.

۴.۷.۵ نگرانی‌های حفظ حریم خصوصی

پیاده‌سازی حق فراموشی در سیستم‌های گفتگو دارای پیچیدگی‌هایی است. اگرچه حق فراموشی اجرا شد، فرآیند حذف ایمن داده‌های کاربر بدون تأثیر بر مدل جهانی نیازمند تلاش قابل توجهی بود. همچنین می‌توان با کاوش در رویکردهای غیرمتمرکز برای افزایش حریم خصوصی داده‌ها این پیاده‌سازی را به صورت موثرتر پیاده‌سازی کرد و آن را بهبود داد.

۵.۷.۵ چالش‌های ارزیابی

معیارهای ارزیابی سیستم‌های گفتگو به طور کلی ماهیت ذهنی دارند. معیارهایی مانند رضایت کاربر و امتیازات تعامل به بازخورد ذهنی بستگی دارد که ممکن است بین کاربران متفاوت باشد. که این ماهیت ذهنی

مشکل در نتیجه‌گیری قابل اجرا جهانی را در پی خواهد داشت. همچنین معیارهای مرسوم دیگر نیازمند یک جواب خاص یا جواب طلایی جهت مقایسه جواب نهایی مدل با آن جواب طلایی بودند ولی در سیستم‌های گفتگو که با مدل‌های زبانی کار می‌کنند ممکن است جواب مدل درست باشد ولی از جواب طلایی که مبنای امتیازدهی است متفاوت باشد. به همین علت باید معیارهای جامع‌تر که هم معجزا از پاسخ طلایی و هم مقداری خارج از ماهیت ذهنی کاربران باشد مانند نرخ تکمیل کار یا نرخ کلیک یا میزان درگیر بودن کاربر در مکالمه ایجاد کرد.

۶.۷.۵ محدودیت‌های مدل

اندازه و معماری مدل با توجه به استفاده از مدل زبانی با پارامترهای کمتر انتخاب شد. در حالی که مدل زبانی مورد استفاده برای محدوده این پروژه کافی بود، عملکرد و درک متنی آن نسبت به مدل‌های بزرگتر مانند جی‌پی‌تی ۴ یا لا‌ما ۳ پایین‌تر بود. استفاده از مدل با پارامترهای کمتر منجر به پاسخ‌های کم‌تر و کوتاه‌تر انسجام در نتیجه نتایج ناکارآمدتر خواهد شد.

۷.۷.۵ چالش‌های تنظیم سریع

پاسخ‌های نهایی مدل و نتایج ارزیابی آن به کیفیت تنظیم سریع بسیار وابسته است. همچنین عملکرد مدل‌های تنظیم‌شده سریع به کیفیت درخواست‌های ورودی بسیار حساس بود. به طور مثال دستورات بد ساخته‌شده منجر به خروجی‌های مدل غیربهبوده شد. علاوه بر آن علیرغم بهبودهایی که از طریق تنظیم سریع انجام شد، این مدل قابلیت‌های محدودی را در سناریوهای شات صفر نشان داد. با استفاده از رویکردهای فرایادگیری برای بهبود سازگاری می‌توان این مشکل را به حداقل رساند.

۸.۷.۵ شخصی‌سازی پاسخ پویا

تنظیم پویای پاسخ‌ها بر اساس بازخورد کاربر در حال تکامل، چالش‌هایی را در حفظ انسجام و ارتباط پاسخ ایجاد می‌کند. برای بهبود عملکرد این بخش باید طراحی حلقه‌های بازخورد بلندمدت برای پاسخ‌های تطبیقی بهبود یافته و به طور موثرتر در سیستم پیاده‌سازی شوند. محدودیت‌ها و چالش‌هایی که بیان شد، بر پیچیدگی‌های ساخت سیستم‌های گفتگوی وظیفه‌محور با ویژگی‌های شخصی‌سازی و حفظ حریم خصوصی بالا تأکید می‌کند. پرداختن به این محدودیت‌ها در کارهای آینده، توسعه

ارتقای سیستم گفتگوی وظیفه‌گرا از طریق تنظیم سریع و پروفایل سازی کارفصل ۵: جمع‌بندی و پیشنهادهایی برای ادامه پژوهش

سیستم‌های گفتگوی قوی‌تر، سازگارتر و کاربر محور را ممکن می‌سازد.

واژه‌نامه

- [1] Abdalla, Hassan I, Amer, Ali A, Amer, Yasmeeen A, Nguyen, Loc, and Al-Maqaleh, Basheer. Boosting the item-based collaborative filtering model with novel similarity measures. *International Journal of Computational Intelligence Systems*, 16(1):123, 2023.
- [2] Azzam, Fatima, Kayed, Mohammed, and Ali, Abdelmgied. A model for generating a user dynamic profile on social media. *Journal of King Saud University-Computer and Information Sciences*, 34(10):9132–9145, 2022.
- [3] Bocklisch, Tom, Werkmeister, Thomas, Varshneya, Daksh, and Nichol, Alan. Task-oriented dialogue with in-context learning. *arXiv preprint arXiv:2402.12234*, 2024.
- [4] Camilleri, Mark Anthony. Artificial intelligence governance: Ethical considerations and implications for social responsibility. *Expert systems*, 41(7):e13406, 2024.
- [5] Chen, Jiaoyan, Geng, Yuxia, Chen, Zhuo, Pan, Jeff Z, He, Yuan, Zhang, Wen, Horrocks, Ian, and Chen, Huajun. Zero-shot and few-shot learning with knowledge graphs: A comprehensive survey. *Proceedings of the IEEE*, 111(6):653–685, 2023.
- [6] Chung, Willy, Cahyawijaya, Samuel, Wilie, Bryan, Lovenia, Holy, and Fung, Pascale. Instructtods: Large language models for end-to-end task-oriented dialogue systems. *arXiv preprint arXiv:2310.08885*, 2023.
- [7] Corecco, Nathan, Piatti, Giorgio, Lanzendörfer, Luca, Fan, Flint Xiaofeng, and Wattenhofer, Roger. An llm-based recommender system environment. *arXiv preprint arXiv:2307.04567*, 2024.
- [8] Dwivedi, Pulkit and Islam, Benazir. An item-based collaborative filtering approach for movie recommendation system. in *2023 10th International Conference on Computing for Sustainable Global Development (INDIACom)*, pp. 153–158. IEEE, 2023.

- [9] Elahi, Mehdi, Kholgh, Danial Khosh, Kiarostami, Mohammad Sina, Oussalah, Mourad, and Saghari, Soroush. Hybrid recommendation by incorporating the sentiment of product reviews. *Information Sciences*, 625:738–756, 2023.
- [10] Elangovan, Aparna, Liu, Ling, Xu, Lei, Bodapati, Sravan, and Roth, Dan. Considers-the-human evaluation framework: Rethinking human evaluation for generative large language models. *arXiv preprint arXiv:2405.18638*, 2024.
- [11] Es, Shahul, James, Jithin, Espinosa-Anke, Luis, and Schockaert, Steven. Ragas: Automated evaluation of retrieval augmented generation. *arXiv preprint arXiv:2309.15217*, 2023.
- [12] Fan, Wenqi. Recommender systems in the era of large language models (llms). *IEEE Transactions on Knowledge and Data Engineering*, pp. 1–20, 2024.
- [13] Hu, Songbo, Wang, Xiaobin, Yuan, Zhangdie, Korhonen, Anna, and Vulić, Ivan. Dialight: Lightweight multilingual development and evaluation of task-oriented dialogue systems with large language models. *arXiv preprint arXiv:2401.02208*, 2024.
- [14] Jabeen, Saffana, Iqbal, Zeshan, and Nida, Nudrat. User profiling through social media analytics.
- [15] Kasahara, Tomohito, Kawahara, Daisuke, Tung, Nguyen, Li, Shengzhe, Shinzato, Kenta, and Sato, Toshinori. Building a personalized dialogue system with prompt-tuning. *arXiv preprint arXiv:2206.05399*, 2022.
- [16] Li, Jiwei, Galley, Michel, Brockett, Chris, Gao, Jianfeng, and Dolan, Bill. A diversity-promoting objective function for neural conversation models. *arXiv preprint arXiv:1510.03055*, 2015.
- [17] Madotto, Andrea, Lin, Zhaojiang, Winata, Genta Indra, and Fung, Pascale. Few-shot bot: Prompt-based learning for dialogue systems. *arXiv preprint arXiv:2110.08118*, 2021.
- [18] Na, Clara, Magnusson, Ian, Jha, Ananya Harsh, Sherborne, Tom, Strubell, Emma, Dodge, Jesse, and Dasigi, Pradeep. Scalable data ablation approximations for language models through modular training and merging. *arXiv preprint arXiv:2410.15661*, 2024.
- [19] Nag, Shubhadip, Dalui, Sayantan, Ghosh, Sagnik, Pal, Ranjan, Pal, Antara, et al. A knowledge based approach for user profiling from the multilingual texts in the social media platforms. in *2023 International Conference on Intelligent and Innovative Technologies in Computing, Electrical and Electronics (IITCEE)*, pp. 750–754. IEEE, 2023.
- [20] Pandelea, Vlad. Towards resource-aware dialogue systems and sentiment analysis. 2024.

- [21] Peterson, Jacob. User profiling in recommender systems. 2021.
- [22] Samarinas, Chris, Promthaw, Pracha, Nijasure, Atharva, Zeng, Hansi, Killingback, Julian, and Zamani, Hamed. Simulating task-oriented dialogues with state transition graphs and large language models. *arXiv preprint arXiv:2404.14772*, 2024.
- [23] Sekuli, Ivan, Terragni, Silvia, Guimares, Victor, Khau, Nghia, Guedes, Bruna, Filipavicius, Modestas, Manso, Andr Ferreira, and Mathis, Roland. Reliable llm-based user simulator for task-oriented dialogue systems. *arXiv preprint arXiv:2402.13374*, 2024.
- [24] Shanaz, Fathima. The potential of using twitter as a data source for user profiling in news recommendation. *Int J Innov Res ComputCommun Eng. IJIRCCE*, 8(4), 2020.
- [25] Singh, Ramni Harbir, Maurya, Sargam, Tripathi, Tanisha, Narula, Tushar, and Srivastav, Gaurav. Movie recommendation system using cosine similarity and knn. *International Journal of Engineering and Advanced Technology*, 9(5):556–559, 2020.
- [26] Xu, Zhichao, Gupta, Ashim, Li, Tao, Bentham, Oliver, and Srikumar, Vivek. Beyond perplexity: Multi-dimensional safety evaluation of llm compression. *arXiv preprint arXiv:2407.04965*, 2024.
- [27] Yu, Jifan, Zhang, Xiaohan, Xu, Yifan, Lei, Xuanyu, Guan, Xinyu, Zhang, Jing, Hou, Lei, Li, Juanzi, and Tang, Jie. Xdai: A tuning-free framework for exploiting pre-trained language models in knowledge grounded dialogue generation. in *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, pp. 4422–4432, 2022.
- [28] Yuan, Hongli and Hernandez, Alexander A. User cold start problem in recommendation systems: A systematic review. *IEEE access*, 11:136958–136977, 2023.
- [29] Zhang, Dawen, Finckenberg-Broman, Pamela, Hoang, Thong, Pan, Shidong, Xing, Zhenchang, Staples, Mark, and Xu, Xiwei. Right to be forgotten in the era of large language models: Implications, challenges, and solutions. *AI and Ethics*, pp. 1–10, 2024.

ارتقای سیستم گفتگوی وظیفه‌گرا از طریق تنظیم سریع و پروفایل‌سازی کارفصل ۵: جمع‌بندی و پیشنهادهایی برای ادامه پژوهش

ارتقای سیستم گفتگوی وظیفه‌گرا از طریق تنظیم سریع و پروفایل‌سازی کارفصل ۵: جمع‌بندی و پیشنهادهایی برای ادامه پژوهش